

Klasifikasi Rumah di Daerah Lampung dengan Menggunakan KNN

Arafi Ramadhan Maulana¹, Uliano Wilyam Purba², Chevando Daffa Pramanda³, Farrel Julio Akbar⁴,
Daffa Ahmad Naufal⁵

Program Studi Sains Data Institut Teknologi Sumatera

Jl. Terusan Ryacudu, Way Huwi, Kec. Jatiagung, Kabupaten Lampung Selatan,
Lampung 35365

Email: arafi.122450002@student.itera.ac.id, uliano.122450098@student.itera.ac.id,
chevando.122450095@student.itera.ac.id, farrel.122450110@student.itera.ac.id,
daffa.122450137@student.itera.ac.id

Abstrak

Penelitian ini bertujuan untuk mengimplementasikan algoritma K-Nearest Neighbors (KNN) dalam klasifikasi harga rumah di daerah Lampung. Pendekatan KNN digunakan untuk memprediksi kategori harga rumah (murah, sedang, mahal) berdasarkan fitur-fitur seperti jarak dari pusat kota, luas tanah, dan daya listrik. Data yang digunakan dalam penelitian ini telah diproses secara pra-pemrosesan, termasuk normalisasi dan encoding fitur-fitur. Setelah itu, model KNN dilatih dan diuji menggunakan data yang telah dipisahkan sebelumnya. Hasil klasifikasi rumah dievaluasi dan dianalisis untuk memahami faktor-faktor apa yang mempengaruhi harga rumah di daerah Lampung. Meskipun model KNN mampu mengklasifikasikan harga rumah, akurasi yang diperoleh masih rendah. Hal ini menunjukkan perlunya peningkatan model, baik dengan menambahkan fitur tambahan maupun menggunakan model yang lebih kompleks, untuk meningkatkan akurasi klasifikasi harga rumah.

Kata Kunci: Implementasi, K-Nearest Neighbors (KNN), klasifikasi, harga rumah, Lampung, pra-pemrosesan data, normalisasi, encoding fitur, pelatihan model, evaluasi model, analisis hasil, akurasi.

1. Teori Dasar

1.1. Pengertian KNN

Metode KNearest Neighbor (KNN) merupakan metode klasifikasi yang dipilih dalam penelitian ini karena kesederhanaannya dan hasil yang sangat baik [1]. Sebuah objek baru dapat diklasifikasikan menggunakan KNN, sebuah teknik yang menggunakan data pelatihan terbaru dari objek tersebut [2]. Data pembelajaran

diproyeksikan ke ruang berdimensi banyak, dimana masing-masing dimensi merepresentasikan fitur dari data. Ruang ini dibagi menjadi bagian-bagian berdasarkan klasifikasi data pembelajaran. Sebuah titik pada ruang ini ditandai kelas jika kelas merupakan klasifikasi yang paling banyak ditemui pada k buah tetangga terdekat titik tersebut. Objek dapat diklasifikasikan berdasarkan atributnya dan sampel pelatihan menggunakan algoritma KNN, yang dirancang untuk membantu pembelajaran [3]. Prinsip pengoperasian KNN (K-Nearest Neighbor) adalah mencari jarak terdekat antara data ini akan dievaluasi dengan K tetangga (tetangga) di dekatnya selama pelatihan [4]. Dekat atau jauhnya tetangga biasanya dihitung berdasarkan jarak Euclidean dengan rumus seperti pada persamaan (1).

$$distance = \sqrt{\sum_{i=1}^n (X_{training}^i - X_{testing})^2} \quad (1)$$

Keterangan =

$X_{training}^i$ = data training ke-i

$X_{testing}$ = data testing

i = record (baris) ke-i dari tabel

n = jumlah testing

Teknik KNN banyak digunakan karena banyak kelebihanannya, termasuk kemampuannya menghasilkan data yang lebih tepat dan efisien jika data pelatihan mencukupi [5]. Pada fase pembelajaran, algoritma ini hanya melakukan penyimpanan vektor-vektor fitur dan klasifikasi dari data pembelajaran. Pada fase klasifikasi, fitur-fitur yang sama dihitung untuk data test (yang klasifikasinya tidak diketahui). Jarak dari vektor yang baru ini terhadap seluruh vektor data pembelajaran dihitung, dan sejumlah K buah yang paling dekat diambil. Titik yang baru klasifikasinya diprediksikan termasuk pada klasifikasi terbanyak dari titik-titik tersebut. Nilai yang terbaik untuk algoritma ini tergantung pada data. Secara umum, nilai K yang tinggi akan mengurangi efek noise pada klasifikasi,

tetapi membuat batasan antara setiap klasifikasi menjadi lebih kabur. Nilai K yang bagus dapat dipilih dengan optimasi parameter, misalnya dengan menggunakan cross-validation. Kasus khusus di mana klasifikasi diprediksikan berdasarkan data pembelajaran yang paling dekat (dengan kata lain, $K=1$) disebut algoritma nearest neighbour.

Ketepatan algoritma KNN sangat dipengaruhi oleh ada atau tidaknya fitur-fitur yang tidak relevan, atau jika bobot fitur tersebut tidak setara dengan relevansinya terhadap klasifikasi.

Algoritma KNN memiliki beberapa kelebihan yaitu ketangguhan terhadap training data yang memiliki banyak noise dan efektif apabila training data-nya besar. Sedangkan, kelemahan KNN adalah KNN perlu menentukan nilai dari parameter K (jumlah dari tetangga terdekat), training berdasarkan jarak tidak jelas mengenai jenis jarak apa yang harus digunakan dan atribut mana yang harus digunakan untuk mendapatkan hasil terbaik, dan biaya komputasi cukup tinggi karena diperlukan perhitungan jarak dari tiap query instance pada keseluruhan training sample.

1.2 Langkah-langkah dalam KNN

1. Menentukan jumlah tetangga (K)

Pada langkah ini, kita harus memilih jumlah tetangga yang akan digunakan untuk memprediksi kelas atau nilai suatu data point yang baru. Ini adalah salah satu parameter penting dalam algoritma KNN.

2. Menghitung jarak

Algoritma KNN mengukur jarak antara data point baru yang ingin diprediksi dengan setiap data point dalam dataset. Jarak ini dapat diukur menggunakan berbagai metrik, seperti Euclidean distance, Manhattan distance, atau lainnya, tergantung pada jenis data dan karakteristiknya.

3. Menemukan tetangga terdekat

Setelah menghitung jarak antara data point baru dan setiap data point dalam dataset, langkah selanjutnya adalah menemukan K data point dengan jarak terdekat.

4. Menghitung hasil prediksi

Jika kita melakukan klasifikasi, maka hasil prediksi akan menjadi kelas yang paling umum dari tetangga-tetangga terdekat. Jika kita melakukan regresi, hasil prediksi akan menjadi rata-rata atau median dari nilai tetangga-tetangga terdekat.

1.3 Kriteria Pemilihan Nilai K

Pemilihan nilai K (jumlah tetangga) dalam algoritma KNN sangat penting karena dapat memengaruhi performa prediksi. Beberapa kriteria yang biasa digunakan untuk memilih nilai K adalah:

1. Uji coba dan error

Melakukan percobaan dengan berbagai nilai K dan memeriksa performa model menggunakan teknik validasi silang atau data validasi terpisah. Nilai K yang menghasilkan performa terbaik dianggap sebagai nilai K yang optimal.

2. Rule of Thumb

Ada aturan praktis yang sering digunakan untuk memilih nilai K, misalnya, akar kuadrat dari jumlah total data atau memilih nilai K sebagai bilangan ganjil jika kelas yang diprediksi juga ganjil. Namun, aturan ini harus disesuaikan dengan kasus yang sedang dihadapi.

3. Analisis kompleksitas

Mempertimbangkan kompleksitas model yang diinginkan. Nilai K yang lebih besar cenderung menghasilkan model yang lebih sederhana dengan batas keputusan yang lebih halus, sedangkan nilai K yang lebih kecil cenderung menghasilkan model yang lebih kompleks dengan batas keputusan yang lebih berbatas.

4. Cek Overfitting

Memeriksa apakah nilai K yang terlalu besar atau terlalu kecil menyebabkan overfitting atau underfitting. Overfitting dapat terjadi jika nilai K terlalu kecil, sedangkan underfitting dapat terjadi jika nilai K terlalu besar.

2. Studi Kasus

2.1 Deskripsi Dataset

2.1.1 Pemahaman Awal Data

Langkah pertama adalah memahami dataset yang ada. Ini termasuk melihat tipe data untuk setiap kolom, menentukan apakah ada nilai yang hilang, dan melihat statistik deskriptif untuk masing-masing kolom.

Variabel	Keterangan
Nama	Nama Properti
Harga	Harga Rumah dalam Rupiah (variabel target)
Alamat	Lokasi Rumah
Jarak	Jarak rumah dari titik tertentu dalam meter
Luas Bangunan	Luas Bangunan dalam mmeter persegi
Luas Tanah	Luas tanah dalam meter persegi
Lantai	Jumlah lantai rumah
Kamar Tidur	Jumlah kamar tidur
Kamar Pembantu	Jumlah Kamar Pembantu
Kamar Mandi	Jumlah Kamar Mandi
Garasi	Jumlah Garasi
Sumber Air	Sumber air yang digunakan (Sumur, PDAM)
Daya Listrik	Daya listrik yang tersedia dalam Watt

2.1.2 Analisis Deskriptif

1. Harga

Dari data yang ada, rentang harga rumah sangat luas, mulai dari 30 jutaan hingga 10 miliaran. Ini menunjukkan variasi besar dalam tipe dan kualitas rumah.

2. Jarak

Mayoritas rumah terletak dalam jarak yang beragam dari pusat kota. Jarak yang lebih jauh cenderung lebih murah karena jauh dari pusat keramaian.

3. Luas Bangunan dan Luas Tanah

Ada rumah-rumah dengan luas bangunan dan tanah yang beragam. Biasanya, semakin besar luas bangunan dan tanah, semakin mahal harganya.

4. Fasilitas

Kamar tidur, kamar mandi, garasi, dan kamar pembantu juga mempengaruhi harga rumah. Semakin banyak fasilitas, biasanya harga akan semakin tinggi.


5. Sumber Air dan Daya Listrik

Ini bisa menjadi faktor tambahan. Rumah dengan PAM dan daya listrik yang tinggi cenderung lebih mahal.

Dari analisis ini, dapat disimpulkan bahwa faktor-faktor seperti luas bangunan dan tanah, jumlah kamar tidur dan mandi, serta fasilitas lainnya mempengaruhi harga rumah. Namun, untuk memastikan, perlu melihat korelasi antara fitur-fitur ini dengan harga.

2.1.3 Visualisasi Data


1. Distribusi Harga Rumah



Gambar 1. Histogram Distribusi Harga Rumah

Visualisasi ini bertujuan untuk memberikan gambaran tentang bagaimana harga rumah terdistribusi dalam dataset. Dengan histogram, kita dapat melihat sebaran harga secara keseluruhan, termasuk apakah ada harga yang dominan atau apakah distribusinya merata. Histogram tersebut menunjukkan bahwa distribusi harga rumah cenderung condong ke arah nilai yang lebih rendah, dengan sedikit rumah yang memiliki harga yang sangat tinggi.


2. Scatter Plot antara Harga dan Fitur Penting



Gambar 2. Scatter Plot antara Harga dan Fitur Penting

Scatter plot adalah cara yang baik untuk memvisualisasikan hubungan antara harga rumah dan fitur-fitur yang paling berpengaruh. Pertama, scatter plot Jarak(m) vs. Harga menunjukkan bahwa semakin jauh rumah dari pusat kota, harga cenderung lebih rendah. Sedangkan pada scatter plot Luas Tanah(m2) vs. Harga, terlihat ada kecenderungan bahwa semakin luas tanah, harga rumah akan cenderung lebih tinggi. Scatter plot memberikan gambaran visual yang jelas tentang hubungan ini.

3. Box Plot untuk Variasi Harga Rumah berdasarkan Kategori



Gambar 3. Boxplot Variasi Harga Rumah berdasarkan Kategori

Box plot memperlihatkan variasi harga rumah untuk setiap kategori, memungkinkan kita untuk membandingkan distribusi harga antar kategori. Dari box plot ini, kita dapat melihat bahwa kategori 'Sedang' memiliki rentang harga yang lebih luas dibandingkan dengan kategori 'Murah' dan 'Mahal'. Kategori 'Mahal' juga menunjukkan kecenderungan memiliki median harga yang lebih tinggi, sementara kategori 'Murah' memiliki nilai median yang lebih rendah.

4. Pemrosesan Data

Preprocessing data untuk membersihkan data dari entri yang hilang atau tidak valid.

5. Pemodelan Prediksi Harga

Membuat model prediksi harga rumah berdasarkan fitur-fitur yang tersedia.

2.2 Preprocessing Data

2.2.1 Penormalan (Normalization)

Penormalan adalah proses mengubah nilai-nilai fitur dalam dataset menjadi skala yang seragam. Ini penting karena beberapa algoritma pembelajaran mesin sensitif terhadap skala fitur dan dapat memberikan hasil yang buruk jika fitur-fiturnya memiliki skala yang berbeda-beda. Dua metode penormalan yang umum digunakan adalah:

- Min-Max Scaling

Metode ini mengubah nilai-nilai fitur ke dalam rentang tertentu, biasanya antara 0 dan 1.

$$x^1 = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (2)$$

- Z-score Scaling

Metode ini mengubah nilai-nilai fitur sehingga memiliki rata-rata nol dan deviasi standar satu.

$$x^1 = \frac{x - \text{mean}(x)}{\text{std}(x)} \quad (3)$$

2.2.2 Penghapusan Outlier

Outlier adalah titik data yang jauh dari sebagian besar data lainnya. Outlier dapat menyebabkan bias dalam model statistik, oleh karena itu perlu untuk menghapusnya. Salah satu metode yang umum digunakan untuk menghapus outlier adalah menggunakan Interquartile Range (IQR):

- Interquartile Range (IQR)

IQR dihitung sebagai perbedaan antara kuartil atas (Q3) dan kuartil bawah (Q1). Data dianggap sebagai outlier jika berada di luar jarak $1.5 \times \text{IQR}$ dari kuartil bawah dan atas.

$$\text{IQR} = Q3 - Q1$$

$$\text{Batas Atas} = Q3 + 1.5 \times \text{IQR}$$

$$\text{Batas Bawah} = Q1 - 1.5 \times \text{IQR}$$

2.2.3 Pemisahan Data Latih dan Data Uji

Pemisahan data latih dan data uji penting untuk menguji kinerja model pada data yang tidak digunakan selama pelatihan. Biasanya, dataset dibagi menjadi dua bagian: data latih (untuk melatih model) dan data uji (untuk menguji model). Pembagian ini dilakukan dengan proporsi tertentu, seperti 80% untuk data latih dan 20% untuk data uji.

2.3 Penerapan Metode KNN

2.3.1 Persiapan Data

Kita memuat dataset rumah ke dalam lingkungan R dan memahami strukturnya dengan melihat beberapa baris pertama dan statistik deskriptif. Ini membantu kita memahami fitur dan label dalam dataset. Setelah itu, kita membersihkan data dengan menghapus nilai yang hilang dan memastikan tipe data yang benar. Normalisasi juga dilakukan jika fitur-fitur memiliki skala yang berbeda.

```
<bound method NDFrame.head of
0   Rumah Minimalis Plus Kontrakan 7 Pintu Kupang ... 1100000000   Nama   Harga \
1   Rumah Bagus Semi Furnished 2200000000
2   Rumah Bagus SHM Lokasi Strategis di Bumi Kedam... 1800000000
3   Rumah Siap Huni 3300000000
4   Rumah murah 1 lantai dekat kampus itera tol ko... 2900000000
..
154   Lamundo residen 900000000
155   Bangunan cocok Untuk Kantor,sekolah Kafe 4500000000
156   Miliki Rumah Villa Citre| halaman luas 4000000000
157   Rumah Di jalan kopi shm bagus 1330000000
158   Rumah dan kontrakan di peramuka way halim 1500000000

   Alamat   Jarak(m)   Luas Bangunan(m2)   Luas Tanah(m2)   Lantai \
0   Teluk Betung   9600   200   329   1
1   Enggal   12000   300   377   1
2   Kedamaian   10000   200   300   2
3   Teluk Betung Utara   15000   250   359   1
4   Sukarame   5000   45   72   1
..
154   Kota Sepang   13500   80   120   1
155   Teluk Betung Utara   14500   400   800   1
156   Way Halim   1200   390   526   1
157   Rajabasa   1400   200   219   1
158   Way Halim   800   200   345   1

   Kamar Tidur   Kamar Pembantu   Kamar Mandi   Garasi   Sumber Air \
0   6   0   6   1   Sumur
1   5   1   2   2   PAM
2   6   0   4   1   Sumur
3   4   1   4   1   Sumur
4   2   0   1   1   Sumur
..
154   3   0   2   1   sumur
155   4   0   3   1   sumur
156   9   0   5   2   sumur
157   3   0   2   1   sumur
158   7   0   7   1   sumur

   Daya Listrik(watt)
0   3600
1   3300
2   7600
```

Gambar 4. Persiapan Data untuk Penerapan Metode KNN

2.3.2 Pra-Pemrosesan Data

Langkah-langkah pra-pemrosesan ditentukan untuk fitur numerik dan kategorikal. Pemrosesan numerik meliputi imputasi dengan nilai rata-rata dan

penskalaan standar, sedangkan pemrosesan kategorikal melibatkan imputasi dengan modus dan one-hot encoding.

2.3.3 Pembagian Data

Data dibagi menjadi set pelatihan (80%) dan pengujian (20%). Jika data yang digunakan untuk pelatihan berjumlah kecil, model akan sering melakukan overfitting dan menangkap pola dalam data pelatihan yang biasanya tidak diamati. Untuk mencegah overfitting, pembagian 80-20 menyediakan data yang cukup untuk tujuan pelatihan, 80% data digunakan untuk pelatihan, sementara 20% untuk pengujian, sehingga estimasi performa model kami cukup beragam. Pembagian 80% data pelatihan dan data pengujian 20% memberikan keseimbangan yang baik antara ukuran dataset pelatihan dan uji, serta membantu mencegah overfitting dan memastikan generalisasi yang baik dari model.

2.3.4 Implementasi KNN

Dalam langkah pra-pemrosesan data, fitur-fitur numerik dan kategorikal diidentifikasi. Fitur numerik seperti jarak rumah dari pusat kota, luas tanah, dan daya listrik, sementara fitur kategorikal mencakup kategori nama rumah. Setiap jenis fitur kemudian diproses secara terpisah. Fitur numerik dinormalisasi menggunakan penskalaan standar, sedangkan fitur kategorikal dienkoding menggunakan metode one-hot encoding untuk mengubah kategori menjadi vektor biner.

Setelah pra-pemrosesan, model KNN digunakan untuk melatih data (langkah 6). Dalam kasus ini, KNN dipilih karena kemampuannya yang sederhana namun cukup efektif dalam melakukan klasifikasi berdasarkan data

terdekat. Dalam proses pelatihan, model mempelajari pola dari data pelatihan yang telah diproses sebelumnya.

Selanjutnya, model yang telah dilatih diuji menggunakan data pengujian. Dengan menggunakan data pengujian yang telah dipisahkan sebelumnya, model memprediksi kategori harga rumah untuk setiap contoh dalam data uji.

Setelah prediksi selesai, hasil klasifikasi rumah dievaluasi dan direkap. Dalam hal ini, hasil klasifikasi dicetak ke layar dalam bentuk jumlah rumah yang diklasifikasikan ke setiap kategori harga. Misalnya, ada berapa rumah yang diklasifikasikan sebagai harga murah, sedang, atau mahal.

Setelahnya, dilakukan analisis terhadap hasil klasifikasi (langkah 10). Analisis ini membantu dalam pemahaman terhadap faktor-faktor apa yang mungkin mempengaruhi harga rumah. Misalnya, rumah yang diklasifikasikan sebagai murah mungkin memiliki jarak yang jauh dari pusat kota, luas tanah yang kecil, dan daya listrik yang rendah. Sedangkan, rumah yang diklasifikasikan sebagai mahal mungkin memiliki jarak yang dekat dari pusat kota, luas tanah yang besar, dan daya listrik yang tinggi.

Terakhir, akurasi model dievaluasi. Dengan membandingkan hasil prediksi model dengan label yang sebenarnya dari data uji, akurasi model dihitung. Akurasi memberikan gambaran seberapa baik model dapat mengklasifikasikan data yang tidak terlihat sebelumnya. Dalam hal ini, akurasi mencerminkan seberapa akurat model dalam memprediksi kategori harga rumah berdasarkan fitur-fitur yang diberikan.

Tabel 1. Hasil Klasifikasi Rumah

Hasil Klasifikasi Rumah

26000000: 0 rumah
30000000: 0 rumah
80000000: 0 rumah
100000000: 0 rumah
150000000: 0 rumah
160000000: 0 rumah
162000000: 2 rumah
192000000: 0 rumah
200000000: 0 rumah
256000000: 1 rumah
275000000: 0 rumah
284000000: 1 rumah
290000000: 1 rumah
295000000: 0 rumah
299000000: 0 rumah
305000000: 0 rumah
313000000: 1 rumah
335000000: 1 rumah
340000000: 0 rumah
360000000: 0 rumah
375000000: 0 rumah
385000000: 0 rumah
390000000: 1 rumah
395000000: 0 rumah
410000000: 0 rumah
425000000: 1 rumah
430000000: 1 rumah
435000000: 1 rumah
437000000: 0 rumah
445000000: 0 rumah
450000000: 1 rumah
455000000: 0 rumah
460000000: 0 rumah
470000000: 0 rumah
485000000: 0 rumah
490000000: 0 rumah
510000000: 1 rumah
520000000: 0 rumah
525000000: 1 rumah
545000000: 1 rumah
550000000: 0 rumah
565000000: 1 rumah
572000000: 1 rumah
595000000: 1 rumah
600000000: 0 rumah
625000000: 0 rumah
635000000: 0 rumah
650000000: 0 rumah

654000000: 0 rumah
660000000: 0 rumah
690000000: 1 rumah
695000000: 0 rumah
700000000: 1 rumah
725000000: 0 rumah
750000000: 2 rumah
760000000: 1 rumah
850000000: 0 rumah
895000000: 1 rumah
900000000: 0 rumah
1100000000: 0 rumah
1200000000: 1 rumah
1300000000: 0 rumah
1330000000: 0 rumah
1350000000: 0 rumah
1400000000: 0 rumah
1490000000: 1 rumah
1500000000: 0 rumah
1550000000: 0 rumah
1600000000: 0 rumah
1650000000: 0 rumah
1800000000: 0 rumah
1900000000: 0 rumah
2000000000: 0 rumah
2200000000: 0 rumah
2250000000: 0 rumah
2400000000: 0 rumah
2500000000: 0 rumah
2600000000: 0 rumah
2700000000: 0 rumah
2800000000: 1 rumah
2850000000: 0 rumah
2900000000: 0 rumah
3000000000: 0 rumah
3100000000: 0 rumah
3300000000: 0 rumah
3500000000: 1 rumah
3670000000: 0 rumah
3690000000: 0 rumah
3800000000: 0 rumah
4000000000: 0 rumah
4250000000: 0 rumah
4500000000: 1 rumah
4880000000: 0 rumah
5000000000: 1 rumah
5500000000: 0 rumah
6500000000: 0 rumah
7000000000: 1 rumah
8900000000: 1 rumah

9000000000: 0 rumah
10000000000: 0 rumah
12000000000: 0 rumah
13500000000: 0 rumah

Analisis:

1. Murah:

- Harga murah mungkin disebabkan oleh jarak dari pusat kota yang lebih jauh, luas tanah yang lebih kecil, dan daya listrik yang lebih rendah.

2. Sedang:

- Harga sedang mungkin disebabkan oleh jarak yang tidak terlalu jauh dari pusat kota, luas tanah yang cukup, dan daya listrik yang mencukupi.

3. Mahal:

- Harga mahal mungkin disebabkan oleh jarak yang dekat dari pusat kota, luas tanah yang besar, dan daya listrik yang tinggi.

Akurasi: 0.09

2.4 Hasil dan Pembahasan

Hasil klasifikasi rumah menunjukkan jumlah rumah yang diklasifikasikan ke dalam setiap kategori harga. Berdasarkan hasil tersebut, kita bisa melihat distribusi klasifikasi harga rumah dalam dataset.

Analisis hasil klasifikasi :

1. Harga Murah

- Tidak ada rumah yang diklasifikasikan dalam kategori harga murah (harga di bawah 50 juta).
- Hal ini mungkin disebabkan oleh kekurangan data atau adanya outlier dalam data.
- Sebagai catatan, rumah dengan harga murah biasanya memiliki jarak yang jauh dari pusat kota, luas tanah yang kecil, dan daya listrik yang rendah.

2. Harga Sedang

- Sebagian besar rumah (hampir seluruhnya) dalam dataset diklasifikasikan sebagai harga sedang (dalam rentang 50 juta hingga 500 juta).
- Rumah dengan harga sedang memiliki variasi yang lebih luas dalam hal jarak, luas tanah, dan daya listrik.

- Harga sedang mungkin disebabkan oleh beragam faktor seperti jarak yang tidak terlalu jauh dari pusat kota, luas tanah yang cukup, dan daya listrik yang mencukupi.

3. Harga Mahal

- Sebagian kecil rumah (kurang dari 10 rumah) diklasifikasikan sebagai harga mahal (lebih dari 500 juta).
- Harga mahal mungkin disebabkan oleh jarak yang dekat dari pusat kota, luas tanah yang besar, dan daya listrik yang tinggi.

3. Kesimpulan

Dari hasil implementasi KNN ini, dapat disimpulkan bahwa model dapat mengklasifikasikan harga rumah berdasarkan fitur-fitur yang diberikan. Namun, akurasi model yang diperoleh masih cukup rendah, yaitu sekitar 0.09. Hal ini menunjukkan bahwa model perlu ditingkatkan, mungkin dengan mempertimbangkan fitur tambahan atau menggunakan model yang lebih kompleks, untuk meningkatkan akurasi klasifikasi harga rumah di daerah Lampung.

4. Referensi

- [1] E. Prasetyo, Data Mining – Konsep dan Aplikasi Menggunakan MATLAB, Yogyakarta: Andi, 2012.
- [2] T. Mitchell, Machine Learning, New York: McGraw-Hill, 1997.
- [3] D. T. Larose, Discovering Knowledge in Data : An Introduction to Data Mining, John Wiley & Sons, Inc, 2005.
- [4] T. Rismawan, A. Irawan, W. Prabowo and S.Kusumadewi, "Sistem Pendukung Keputusan berbasis Pocket PC Sebagai Penentu Status Gizi Menggunakan Metode KKN (K-Nearest Neighbor)," *Jurnal Teknoin*, vol. 12, no. 2, pp. 1-6, 2008.
- [5] A. Ridok, "Klasifikasi Dokumen Berbahasa Indonesia Menggunakan Metode KKN," *Jurnal Pointer Ilmu Komputer*, vol. 1, 2010.

Lampiran

1. Visualisasi Data

1. Distribusi Harga Rumah

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Load dataset
df = pd.read_csv("Dataset.csv")

plt.figure(figsize=(10, 6))
plt.hist(df['Harga'], bins=20, color='skyblue', edgecolor='black')
plt.title('Distribusi Harga Rumah')
plt.xlabel('Harga (dalam satuan)')
plt.ylabel('Jumlah Rumah')
plt.show()
```

2. Scatter Plot antara Harga dan Fitur Penting

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Load dataset
df = pd.read_csv("Dataset.csv")

# Print column names
print(df.columns)

plt.figure(figsize=(18, 6))

plt.subplot(1, 3, 1)
sns.scatterplot(data=df, x='Jarak(m)', y='Harga', color='blue')
plt.title('Scatter Plot: Jarak vs Harga')

plt.subplot(1, 3, 2)
sns.scatterplot(data=df, x='Luas Tanah(m2)', y='Harga', color='green')
plt.title('Scatter Plot: Luas Tanah vs Harga')

plt.subplot(1, 3, 3)
sns.scatterplot(data=df, x='Daya Listrik(Watt)', y='Harga', color='orange')
plt.title('Scatter Plot: Daya Listrik vs Harga')
```

```
plt.tight_layout()
plt.show()
```

3. Box Plot Untuk Variasi Harga Rumah berdasarkan Kategori

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Load dataset
df = pd.read_csv("Dataset.csv")

# Print column names
print(df.columns)

# Visualisasi 4: Box Plot untuk Variasi Harga Rumah berdasarkan Kategori
plt.figure(figsize=(10, 6))
sns.boxplot(data=df, x='Nama', y='Harga', palette='Set2')
plt.title('Variasi Harga Rumah berdasarkan Kategori')
plt.xlabel('Kategori')
plt.ylabel('Harga (dalam satuan rupiah)')
plt.show()
```

2. Penerapan Metode KNN

1. Persiapan Data

```
import pandas as pd

# Load dataset

df = pd.read_csv("Dataset.csv")

# Print column names

print(df.head)
```

2. Pra-Pemrosesan Data

```
numeric_features = ['Jarak(m)', 'Luas Tanah(m2)', 'Daya Listrik(Watt)']
categorical_features = ['Nama']

numeric_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='mean')),
    ('scaler', StandardScaler())
])
```

```

categorical_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('onehot', OneHotEncoder(handle_unknown='ignore'))
])

preprocessor = ColumnTransformer(
    transformers=[
        ('num', numeric_transformer, numeric_features),
        ('cat', categorical_transformer, categorical_features)
    ]
)

```

3.

Pembagian Data

```

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

```

3. Implementasi KNN

```

import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score

# Load preprocessed dataset
df = pd.read_csv("Dataset.csv")

# Split features (X) and target (y)
X = df.drop('Harga', axis=1)
y = df['Harga']

# Split dataset into train and test sets (80% train, 20% test)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# Define preprocessing steps for numeric and categorical features
numeric_features = ['Jarak(m)', 'Luas Tanah(m2)', 'Daya Listrik(Watt)']
categorical_features = ['Nama']

numeric_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='mean')),
    ('scaler', StandardScaler())
])

```

```

categorical_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('onehot', OneHotEncoder(handle_unknown='ignore'))
])

preprocessor = ColumnTransformer(
    transformers=[
        ('num', numeric_transformer, numeric_features),
        ('cat', categorical_transformer, categorical_features)
    ])

# Combine preprocessing with KNN classifier
knn_pipeline = Pipeline(steps=[('preprocessor', preprocessor),
                                ('classifier', KNeighborsClassifier(n_neighbors=3))])

# Fit the model
knn_pipeline.fit(X_train, y_train)

# Classify the test set
y_pred = knn_pipeline.predict(X_test)

# Get the unique classes
classes = sorted(y.unique())

# Analyze the classification
classification_results = {}
for c in classes:
    classification_results[c] = y_pred[y_test == c].shape[0]

# Print classification results
print("Hasil Klasifikasi Rumah:")
for c, count in classification_results.items():
    print(f'{c}: {count} rumah")

# Analisis
print("\nAnalisis:")
print("1. Murah:")
print("- Harga murah mungkin disebabkan oleh jarak dari pusat kota yang lebih jauh, luas tanah yang lebih kecil, dan daya listrik yang lebih rendah.")
print("2. Sedang:")
print("- Harga sedang mungkin disebabkan oleh jarak yang tidak terlalu jauh dari pusat kota, luas tanah yang cukup, dan daya listrik yang mencukupi.")
print("3. Mahal:")
print("- Harga mahal mungkin disebabkan oleh jarak yang dekat dari pusat kota, luas tanah yang besar, dan daya listrik yang tinggi.")

# Hitung akurasi
accuracy = accuracy_score(y_test, y_pred)
print(f"\nAkurasi: {accuracy:.2f}")

```

