

KLASIFIKASI RUMAH DI DAERAH LAMPUNG MENGUNAKAN KNN

Oleh: Kelompok 4

ITERA | Sains Data | 2024

Teori Dasar

PENGERTIAN KNN

Algoritma K-Nearest Neighbor(KNN) adalah sebuah metode untuk melakukan klasifikasi terhadap objek berdasarkan data pembelajaran yang jaraknya paling dekat dengan objek tersebut

Teori Dasar

LANGKAH-LANGKAH DALAM KNN

1. Menentukan jumlah tetangga (K)
2. Menghitung jarak
3. Menemukan tetangga terdekat
4. Menghitung hasil prediksi

Teori Dasar

KRITERIA PEMILIHAN NILAI K

1. Uji coba dan error
2. Rule of Thumb
3. Analisis Kompleksitas
4. Cek Overfitting

Studi Kasus

Deskripsi Dataset

Variabel	Keterangan
Nama	Nama Properti
Harga	Harga Rumah dalam Rupiah (variabel target)
Alamat	Lokasi Rumah
Jarak	Jarak rumah dari titik tertentu dalam meter
Luas Bangunan	Luas Bangunan dalam mmeter persegi
Luas Tanah	Luas tanah dalam meter persegi
Lantai	Jumlah lantai rumah
Kamar Tidur	Jumlah kamar tidur
Kamar Pembantu	Jumlah Kamar Pembantu
Kamar Mandi	Jumlah Kamar Mandi
Garasi	Jumlah Garasi
Sumber Air	Sumber air yang digunakan (Sumur, PDAM)
Daya Listrik	Daya listrik yang tersedia dalam Watt

Studi Kasus

Head and Tail Dataset

```
<bound method NDFrame.head of
0  Rumah Minimalis Plus Kontrakan 7 Pintu Kupang ... 1100000000
1  Rumah Bagus Semi Furnished 2200000000
2  Rumah Bagus SHM Lokasi Strategis di Bumi Kedam... 1800000000
3  Rumah Siap Huni 3300000000
4  Rumah murah 1 lantai dekat kampus itera tol ko... 2900000000
..
154  Lamundo residen 900000000
155  Bangunan cocok Untuk Kantor,sekolah Kafe 4500000000
156  Miliki Rumah Villa Citre| halaman luas 4000000000
157  Rumah Di jalan kopi shm bagus 1330000000
158  Rumah dan kontrakan di peramuka way halim 1500000000


      Alamat  Jarak(m)  Luas Bangunan(m2)  Luas Tanah(m2)  Lantai  \
0  Teluk Betung  9600  200  329  1
1  Enggal  12000  300  377  1
2  Kedamaian  10000  200  300  2
3  Teluk Betung Utara  15000  250  359  1
4  Sukarame  5000  45  72  1
..
154  Kota Sepang  13500  80  120  1
155  Teluk Betung Utara  14500  400  800  1
156  Way Halim  1200  390  526  1
157  Rajabasa  1400  200  219  1
158  Way Halim  800  200  345  1

      Kamar Tidur  Kamar Pembantu  Kamar Mandi  Garasi  Sumber Air  \
0  6  0  6  1  Sumur
1  5  1  2  2  PAM
2  6  0  4  1  Sumur
3  4  1  4  1  Sumur
4  2  0  1  1  Sumur
..
154  3  0  2  1  sumur
155  4  0  3  1  sumur
156  9  0  5  2  sumur
157  3  0  2  1  sumur
158  7  0  7  1  sumur

      Daya Listrik(Watt)
0  3600
1  3300
2  7600
```


Studi Kasus

Visualisasi Data




Studi Kasus

Visualisasi Data



Studi Kasus

Visualisasi Data



Studi Kasus

Preprocessing Data

Penormalan (Normalization)

Penormalan adalah proses mengubah nilai-nilai fitur dalam dataset menjadi skala yang seragam.

Min-Max Scaling

$$x^{1} = (x - \min \llbracket (x) \rrbracket) / (\max(x) - \min(x))$$

Z-score Scaling

$$x^{1} = (x - \text{mean} \llbracket (x) \rrbracket) / (\text{std}(x))$$

Studi Kasus

Preprocessing Data Penghapusan Outlier

Penghapusan Outlier, salah satu metode yang umum digunakan untuk menghapus outlier adalah menggunakan Interquartile Range (IQR):

- Interquartile Range (IQR)

IQR dihitung sebagai perbedaan antara kuartil atas (Q3) dan kuartil bawah (Q1). Data dianggap sebagai outlier jika berada di luar jarak $1.5 * IQR$ dari kuartil bawah dan atas.

$$IQR = Q3 - Q1$$

$$\text{Batas Atas} = Q3 + 1.5 * IQR$$

$$\text{Batas Bawah} = Q1 - 1.5 * IQR$$

Studi Kasus

Preprocessing Data

Pemisahan Data Latih dan Data Uji

Pemisahan data latih dan data uji penting untuk menguji kinerja model pada data yang tidak digunakan selama pelatihan.

Studi Kasus

Penerapan Metode KNN

Persiapan Data

memuat dataset rumah ke dalam lingkungan R dan memahami strukturnya dengan melihat beberapa baris pertama dan statistik deskriptif. Ini membantu kita memahami fitur dan label dalam dataset.

Pembagian Data

pembagian data mengacu pada proses membagi dataset menjadi bagian-bagian yang lebih kecil atau kategori-kategori tertentu untuk analisis lebih lanjut.

Pra-Pemrosesan Data

pra-pemrosesan ditentukan untuk fitur numerik dan kategorikal.

Implementasi KNN

Setelah pra-pemrosesan, model KNN digunakan untuk melatih data dengan mempelajari pola dari data pelatihan yang telah diproses sebelumnya. Selanjutnya, model yang telah dilatih diuji menggunakan data pengujian untuk memprediksi kategori harga rumah. Hasil klasifikasi rumah dievaluasi dan direkap dengan mencetak jumlah rumah yang diklasifikasikan ke setiap kategori harga. Analisis terhadap hasil klasifikasi dilakukan untuk memahami faktor-faktor yang mempengaruhi harga rumah, seperti jarak dari pusat kota, luas tanah, dan daya listrik. Terakhir, akurasi model dievaluasi dengan membandingkan hasil prediksi model dengan label sebenarnya dari data uji, memberikan gambaran seberapa baik model dapat mengklasifikasikan data yang tidak terlihat sebelumnya berdasarkan fitur-fitur yang diberikan.

Studi Kasus

Hasil dan Pembahasan

Harga Murah

Harga Sedang

Harga Mahal

Kesimpulan

Dari hasil implementasi KNN ini, dapat disimpulkan bahwa model dapat mengklasifikasikan harga rumah berdasarkan fitur-fitur yang diberikan. Namun, akurasi model yang diperoleh masih cukup rendah, yaitu sekitar 0.09. Hal ini menunjukkan bahwa model perlu ditingkatkan, mungkin dengan mempertimbangkan fitur tambahan atau menggunakan model yang lebih kompleks, untuk meningkatkan akurasi klasifikasi harga rumah di daerah Lampung.

Code

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score

# Load preprocessed dataset
df = pd.read_csv("Dataset.csv")

# Split features (X) and target (y)
X = df.drop('Harga', axis=1)
y = df['Harga']

# Split dataset into train and test sets (80% train, 20% test)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
                                                    random_state=42)

# Define preprocessing steps for numeric and categorical features
numeric_features = ['Jarak(m)', 'Luas Tanah(m2)', 'Daya Listrik(Watt)']
categorical_features = ['Nama']

numeric_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='mean')),
    ('scaler', StandardScaler())
])

categorical_transformer = Pipeline(steps=[
    ('imputer', SimpleImputer(strategy='most_frequent')),
    ('onehot', OneHotEncoder(handle_unknown='ignore'))
])

preprocessor = ColumnTransformer(
    transformers=[
        ('num', numeric_transformer, numeric_features),
        ('cat', categorical_transformer, categorical_features)
    ])

# Combine preprocessing with KNN classifier
knn_pipeline = Pipeline(steps=[('preprocessor', preprocessor),
                                ('classifier', KNeighborsClassifier(n_neighbors=3))])
```


Code

```
# Fit the model
knn_pipeline.fit(X_train, y_train)

# Classify the test set
y_pred = knn_pipeline.predict(X_test)

# Get the unique classes
classes = sorted(y.unique())

# Analyze the classification
classification_results = {}
for c in classes:
    classification_results[c] = y_pred[y_test == c].shape[0]

# Print classification results
print("Hasil Klasifikasi Rumah:")
for c, count in classification_results.items():
    print(f'{c}: {count} rumah')

# Analisis
print("\nAnalisis:")
print("1. Murah:")
print("- Harga murah mungkin disebabkan oleh jarak dari pusat kota yang lebih jauh, luas tanah yang lebih kecil, dan daya listrik yang lebih rendah.")
print("2. Sedang:")
print("- Harga sedang mungkin disebabkan oleh jarak yang tidak terlalu jauh dari pusat kota, luas tanah yang cukup, dan daya listrik yang mencukupi.")
print("3. Mahal:")
print("- Harga mahal mungkin disebabkan oleh jarak yang dekat dari pusat kota, luas tanah yang besar, dan daya listrik yang tinggi.")

# Hitung akurasi
accuracy = accuracy_score(y_test, y_pred)
print(f"\nAkurasi: {accuracy:.2f}")
```