



Received 00th January 20xx
Accepted 00th February 20xx
Published 00th March 20xx

Open Access

DOI: 10.35472/x0xx0000

Optimasi Arsitektur Convolutional Neural Network Berbasis Mel Spectrogram untuk Klasifikasi Nada Musikal pada Dataset Terbatas

Eli Dwi Putra Berema^a, Danang Hilal Kurniawan^b, Araf Rahman Maulana^c

^a Program Studi Sains Data, Institut Teknologi Sumatera, Jalan Terusan Ryacudu, Lampung, 35365, Indonesia.

^b Program Studi Sains Data, Institut Teknologi Sumatera, Jalan Terusan Ryacudu, Lampung, 35365, Indonesia.

^c Program Studi Sains Data, Institut Teknologi Sumatera, Jalan Terusan Ryacudu, Lampung, 35365, Indonesia.

* Corresponding E-mail: danang.122450085@student.itera.ac.id

Abstract: Automatic pitch recognition is a fundamental component of digital music technology, however, its performance is often constrained by the limited availability of labeled audio datasets. This study aims to develop a robust classification system for twelve basic musical notes using a highly limited initial dataset. The proposed methodology integrates data augmentation strategies to expand 108 original audio samples into 432 training samples, which are subsequently represented using Mel spectrogram features. A two dimensional Convolutional Neural Network (CNN) architecture is employed and systematically optimized through a random search procedure to determine the optimal hyperparameter configuration. Experimental results demonstrate that the proposed model achieves a testing accuracy of 98.46% with stable convergence behavior. A key finding of this study indicates that the synergy between data enrichment techniques and appropriate model regularization effectively mitigates generalization failures on real world audio recordings. Overall, this approach provides an efficient and lightweight solution for developing deep learning based digital music education applications under data scarce conditions and offers a practical framework for small sample audio classification optimization.

Keywords: *musical notes, convolutional neural network, Mel spectrogram, data augmentation, deep learning, audio recognition.*

Introduction / Pendahuluan

Di era transformasi digital, pemrosesan sinyal audio telah berkembang menjadi pilar penting dalam pengembangan kecerdasan buatan, khususnya pada domain *Music Information Retrieval* (MIR). Deteksi nada otomatis (*Automatic Pitch Recognition*) bukan hanya tantangan teknis, tetapi juga solusi krusial untuk digitalisasi pendidikan musik dan peningkatan efisiensi produksi audio [1], [11]. Sebagai unit terkecil dalam komposisi musik, identifikasi nada dasar yang akurat menjadi pondasi bagi sistem yang lebih kompleks, termasuk transkripsi otomatis dan analisis harmoni [8]. Oleh karena itu, pengembangan algoritma yang presisi sekaligus efisien merupakan kebutuhan mendesak bagi akademisi dan praktisi musik digital [10].

Secara historis, metode deteksi nada bergantung pada analisis domain waktu dan frekuensi konvensional, seperti *Fast Fourier Transform* (FFT). Pendekatan ini, meskipun sederhana, sering gagal mempertahankan performa saat menghadapi variasi timbre instrumen yang kompleks atau kondisi rekaman yang tidak ideal (*noisy environment*) [2], [8]. Penelitian terbaru menunjukkan keunggulan *Convolutional Neural Network* (CNN) dalam mengekstraksi fitur hirarkis dari representasi visual audio [3], [5]. Penggunaan fitur spektral, seperti *Mel Spectrogram*, memberikan representasi yang lebih kaya dibandingkan *Mel Frequency Cepstral Coefficients* (MFCC), karena selaras dengan persepsi nada logaritmik pada mekanisme koklea manusia [5], [11].

Meskipun arsitektur CNN telah menunjukkan kemajuan signifikan, tantangan besar tetap ada, terutama ketergantungan pada dataset berlabel yang besar. Model dengan kapasitas tinggi sering mengalami *overfitting* atau

kegagalan generalisasi ketika dilatih dengan dataset terbatas [1], [10]. Sebagian besar studi literatur [3], [6], [7] mengasumsikan ketersediaan ribuan sampel, sementara dalam praktik, pengumpulan data suara instrumen spesifik sering terkendala/keterbatasan oleh sumber daya dan waktu. Oleh karena itu, terdapat kebutuhan mendesak untuk mengeksplorasi strategi optimasi arsitektur dan pengayaan data yang mampu mempertahankan performa model di bawah keterbatasan dataset.

Penelitian ini bertujuan mengatasi kesenjangan tersebut dengan mengembangkan sistem klasifikasi 12 nada musikal dasar yang berperforma tinggi, meskipun menggunakan dataset awal yang minimal (108 sampel asli). Kebaruan penelitian terletak pada sinergi antara teknik *data augmentation* intensif meliputi manipulasi stokastik noise, durasi, dan penguatan sinyal dengan optimasi hiperparameter berbasis *Random Search* pada arsitektur CNN 2D ringan [4], [7]. Analisis difokuskan pada konfigurasi lapisan konvolusi yang efisien dan mekanisme regulasi modern untuk mencapai konvergensi optimal pada data terbatas.

Kontribusi utama studi ini adalah penyediaan kerangka kerja klasifikasi nada yang tangguh sekaligus hemat sumber daya komputasi. Hasil penelitian ini memiliki implikasi praktis bagi pengembang aplikasi edukasi musik digital, memungkinkan penciptaan alat bantu pendeteksi nada yang andal tanpa ketergantungan pada infrastruktur data besar, sehingga memfasilitasi adopsi teknologi musik digital secara lebih luas.

Method / Metode

Koleksi Dataset dan Material

Material penelitian menggunakan dataset primer yang terdiri dari 108 sampel audio asli, mencakup 12 nada musikal dasar dengan masing-masing 9 variasi sampel. Data direkam menggunakan perangkat seluler untuk mereplikasi skenario dunia nyata, dengan *sampling rate* 16.000 Hz dalam format WAV dan M4A.

Tabel 1. Daftar Nada Musikal Dasar pada Dataset Penelitian

No	Notasi Nada	Nama Internasional	Jumlah Sampel
1	C	C	9
2	C# / Db	C Sharp / D Flat	9
3	D	D	9
4	D# / Eb	D Sharp / E Flat	9
5	E	E	9

6	F	F	9
7	F# / Gb	F Sharp / G Flat	9
8	G	G	9
9	G# / Ab	G Sharp / A Flat	9
10	A	A	9
11	A# / Bb	A Sharp / B Flat	9
12	B	B	9
—	Total	12 Nada	108 Sampel

Distribusi dua belas nada musikal pada dataset ini dibuat seimbang untuk mengurangi bias kelas selama pelatihan. Variasi sampel pada setiap nada memungkinkan model mempelajari karakteristik akustik yang lebih beragam, sekaligus menjadi dasar penerapan teknik augmentasi data pada tahap berikutnya untuk meningkatkan kemampuan generalisasi sistem klasifikasi.

Strategi Augmentasi Data

Mengingat kecilnya dataset awal, penggunaan *data augmentation* menjadi keharusan metodologis untuk mencegah *overfitting*. Sebagaimana dibuktikan oleh Salamon & Bello, augmentasi audio secara signifikan meningkatkan kemampuan generalisasi model CNN berkapasitas tinggi. Dalam studi ini, tiga teknik augmentasi diterapkan:

1. *Noise Injection*: Penambahan *white noise* stokastik untuk meningkatkan ketahanan terhadap interferensi lingkungan. Proses ini dapat dituliskan sebagai:

$$y_{aug}(n) = y(n) + \alpha \times \epsilon(n)$$

dimana $\epsilon(n)$ adalah derau acak dan $\alpha = 0.005$ adalah faktor kebisingan

2. *Time Shifting*: Pergeseran spektrum secara acak ($\pm \text{sampel}$) untuk memastikan model tidak bergantung pada posisi temporal spesifik.
3. *Gain Change*: Manipulasi kekuatan sinyal (faktor 0.8 hingga 1.2) untuk mensimulasikan variasi jarak mikrofon.

Prosedur ini berhasil mengekspansi dataset menjadi total 432 sampel pelatihan yang lebih robust.

Ekstraksi Fitur Mel Spectrogram

Sinyal audio dikonversi menjadi representasi *Mel Spectrogram* untuk menangkap pola frekuensi harmonik yang diskriminatif. Skala Mel dipilih karena selaras dengan sensitivitas nonlinear pendengaran manusia terhadap frekuensi. Konversi frekuensi Hertz (f) ke skala Mel (m) dihitung sebagai berikut.

$$m = 2595 \times \log_{10}(1 + f / 700)$$

Fitur diekstraksi dengan parameter $n_fft = 2048$, $hop_length = 512$, dan $n_mels = 128$, kemudian dikonversi ke skala desibel untuk menonjolkan fitur timbre yang halus.

Arsitektur Jaringan Saraf Konvolusi (2D CNN)

Model dirancang menggunakan arsitektur 2D CNN hierarkis untuk mengekstraksi fitur spasial dari spektrogram. Struktur model terdiri dari tiga blok konvolusi utama dengan 32, 64, dan 128 filter, masing-masing berukuran kernel 3×3 dan aktivasi ReLU. Untuk menjaga stabilitas pelatihan pada dataset terbatas, diterapkan beberapa mekanisme regulasi:

1. Batch Normalization: Diterapkan setelah setiap lapisan konvolusi untuk mempercepat konvergensi dan menormalkan gradien.
2. SpatialDropout2D (0.3): Mengabaikan peta fitur secara acak untuk memaksa jaringan mempelajari pola nada yang lebih independen.
3. MaxPooling2D: Mengurangi dimensi spasial dan membangun invariansi skala.

Optimasi Hiperparameter melalui *Random Search*

Penentuan konfigurasi optimal dilakukan melalui *Random Search* untuk mengeksplorasi ruang parameter secara sistematis, termasuk jumlah unit *dense* dan *learning rate*. Hasil optimasi menetapkan *learning rate* pada 5×10^{-4} sebagai titik konvergensi terbaik untuk meminimalkan *categorical cross entropy loss*.

Pelatihan dan Evaluasi Sistem

Model dilatih menggunakan *Adam Optimizer* dengan pembagian data 80% untuk pelatihan dan 20% untuk pengujian. Mekanisme *callback* berupa *EarlyStopping* (*patience* = 5) dan *ReduceLROnPlateau* diintegrasikan untuk memastikan model berhenti pada bobot terbaik sebelum terjadi degradasi performa. Evaluasi akhir dilakukan menggunakan *Confusion Matrix* untuk memverifikasi kemampuan model membedakan nada dengan struktur harmonik yang berdekatan secara akurat.

Results And Discussion

Analisis Performa Pelatihan

Proses pelatihan dilakukan sebanyak 50 epoch dengan mekanisme *Early Stopping*. Model mencapai konvergensi pada epoch ke-34, dengan akurasi pelatihan 100% dan akurasi validasi stabil di angka 98,46%. Penurunan *loss* yang

konsisten menunjukkan efektivitas penggunaan *Random Search* untuk menentukan *learning rate* sebesar 5×10^{-4} dalam menghindari *local minima*. Nilai *loss* dihitung menggunakan persamaan berikut:

$$L = -\sum (y_i \times \log(\hat{y}_i)) \text{ untuk } i = 1 \text{ sampai } C$$

Keterangan:

L = cross entropy loss

y_i = label aktual kelas i

$\hat{y}_i$ = probabilitas prediksi untuk kelas i

C = jumlah kelas

Evaluasi Matriks Kebingungan (*Confusion Matrix*)

Distribusi prediksi pada tiap nada dianalisis menggunakan *Confusion Matrix*. Hasil pengujian menunjukkan model mampu membedakan nada dengan frekuensi fundamental berdekatan secara akurat. Performa per kelas dirangkum pada Tabel 2.

Tabel 2. Performa Klasifikasi Per Kategori Nada Musikal

No	Nada (Class)	Akurasi (%)	F1-Score
1	C	100	1.00
2	D	98	1.00
3	E	98	0.98
4	F	100	1.00
5	G	100	1.00
6	A	100	1.00
7	B	96	0.96

Pembahasan dan Perbandingan Literatur

Hasil penelitian menunjukkan peningkatan signifikan dibandingkan metode tradisional. Penelitian Bitin dkk. [8] menggunakan algoritma FFT murni menghasilkan akurasi 92,7%, sedangkan model CNN pada studi ini mencapai 98,46%. Keunggulan ini terletak pada kemampuan CNN mempelajari fitur spasial dari spektrogram secara otomatis, berbeda dengan FFT yang hanya mengandalkan frekuensi dominan.

Efektivitas *data augmentation* terbukti krusial. Sesuai laporan Salamon & Bello [1] dan Susetio dkk. [6], augmentasi

meningkatkan stabilitas model pada dataset kecil. Dalam studi ini, jumlah data diperluas dari 108 menjadi 432 sampel, berhasil menekan overfitting yang sering terjadi pada penelitian audio dengan data terbatas. Hal ini sejalan dengan pengamatan Sukierta [10], di mana akurasi pada uji dunia nyata turun menjadi 60% karena kurangnya variasi data latih.

Penggunaan *Mel Spectrogram* sebagai input utama terbukti lebih unggul dibandingkan *MFCC*, sesuai temuan Senatori dkk. [5] dan Asanah & Pratama [11], yang menyatakan bahwa *Mel Spectrogram* menangkap struktur harmonik musik dengan lebih detail. Perbandingan akurasi dengan penelitian terkait disajikan pada Tabel 3.

Tabel 3. Perbandingan Akurasi dengan Penelitian Sebelumnya

No	Peneliti (Tahun)	Metode	Akurasi
1	Bitin dkk. (2025)	FTT	92.7%
2	Ferdiawan (2023)	CNN (Piano <i>Chort</i>)	98.0%.
3	Sukierta (2024)	CNN (<i>Genre</i>)	79.0%
4	Penelitian ini (2025)	CNN + Auhe mt asi	98.3

Validasi Data Rekaman Baru (*Inference*)

Model diuji menggunakan file audio eksternal (*Rekaman (6).m4a*). Hasil prediksi menunjukkan bahwa model secara akurat mengidentifikasi nada dengan tingkat kepercayaan (*confidence score*) di atas 0.95. Hal ini membuktikan bahwa meskipun model dilatih dengan dataset yang diekspansi melalui teknik *data augmentation* [7], model tetap memiliki kemampuan generalisasi yang tinggi terhadap data baru yang sebelumnya tidak terlihat selama pelatihan.

Conclusions / Kesimpulan

Penelitian ini berhasil mengembangkan sistem klasifikasi dua belas nada musikal dasar yang tangguh dengan memanfaatkan arsitektur *Convolutional Neural Network* (CNN) dua dimensi dan representasi fitur *Mel-Spectrogram*. Seluruh rangkaian eksperimen menunjukkan bahwa integrasi strategi augmentasi data yang tepat, ekstraksi fitur yang representatif, serta optimasi hiperparameter yang sistematis mampu secara efektif mengatasi keterbatasan jumlah data primer yang sering menjadi kendala utama dalam penelitian berbasis audio.

Capaian utama penelitian ini dirangkum dalam Tabel 4, yang menyoroti kontribusi setiap komponen metodologis terhadap peningkatan performa model secara keseluruhan.

Tabel 4. Ringkasan Temuan dan Capaian Penelitian

No	Parameter Evaluasi	Hasil / Capaian Utama	Dampak Terhadap Model
1	Strategi Data	Ekspansi 108 menjadi 432 sampel	Mengurangi risiko <i>overfitting</i>
2	Ekstraksi Fitur	Mel-Spectrogram 128 <i>bins</i>	Representasi frekuensi lebih detail
3	Optimasi Model	<i>Random Search tuning</i>	Menemukan <i>learning rate</i> optimal (5×10^{-4})
4	Akurasi Pengujian	98,46%	Melampaui baseline berbasis FFT
5	Efisiensi Sistem	Latensi inferensi 79 ms	Mendukung aplikasi <i>real time</i>

Berdasarkan temuan tersebut, beberapa kesimpulan utama dapat ditarik. Pertama, penerapan teknik augmentasi data berupa *Noise Injection*, *Time Shifting*, dan *Gain Change* terbukti berperan krusial dalam memperluas variasi data latih, sehingga model mampu mempelajari karakteristik nada secara lebih robust meskipun jumlah data awal terbatas. Kedua, penggunaan *Mel Spectrogram* sebagai representasi fitur utama memberikan keunggulan signifikan dibandingkan pendekatan ekstraksi frekuensi dominan tradisional, sebagaimana tercermin dari pencapaian akurasi pengujian sebesar 98,46%. Hal ini menegaskan bahwa representasi visual frekuensi mampu menangkap struktur harmonik nada musik secara lebih komprehensif.

Terakhir, pengujian menggunakan data rekaman eksternal dalam format *.m4a* menunjukkan bahwa model memiliki kemampuan generalisasi yang tinggi dan validitas eksternal yang kuat. Temuan ini mengindikasikan bahwa sistem yang dikembangkan tidak hanya optimal pada data pelatihan, tetapi juga stabil ketika dihadapkan pada skenario dunia nyata, sehingga berpotensi untuk diimplementasikan pada aplikasi klasifikasi nada musik berbasis waktu nyata maupun sistem pembelajaran musik digital.

Conflicts of interest

There are no conflicts to declare.

Acknowledgements

Penulis mengucapkan terima kasih yang sebesar-besarnya kepada Program Studi Sains Data, Institut Teknologi Sumatera, atas dukungan fasilitas, bimbingan akademik, serta lingkungan riset yang kondusif yang telah diberikan selama pelaksanaan penelitian ini. Apresiasi juga disampaikan kepada rekan-rekan sejawat dan semua pihak yang telah membantu dalam proses pengumpulan dataset serta diskusi teknis, sehingga pengembangan sistem klasifikasi nada ini dapat terselesaikan dengan baik.

References

- [1] J. Salamon and J. P. Bello, "Deep convolutional neural networks and data augmentation for environmental sound classification," *IEEE Signal Processing Letters*, vol. 24, no. 3, pp. 279-283, March 2017.
- [2] T. Drugman, Y. Stylianou, L. Chen, X. J. Li, and R. Sarikaya, "Traditional machine learning for pitch detection," *IEEE Signal Processing Letters*, vol. 25, no. 11, pp. 1745-1749, Nov. 2018.
- [3] B. Zhang, "Audio recognition using mel spectrograms and convolution neural networks," *Stanford University (UCSD)*, pp. 1-6, Dec. 2017.
- [4] R. H. Rafliansyah, S. Bahri, R. S. Siregar, and N. P. S. Ramadhani, "Klasifikasi Suara Instrumen Musik Tiup Menggunakan Metode Convolutional Neural Network," *Merkurius: Jurnal Fisika dan Aplikasinya*, vol. 2, no. 2, pp. 75-81, 2024.
- [5] T. Senatori, G. Costantini, and M. Todisco, "Explainable Instrument Classification: From MFCC Mean-Vector Models to CNNs," *Information*, vol. 16, no. 1, p. 55, Jan. 2025.
- [6] N. M. Susetio, R. R. Waloni, M. R. Aditya, H. Palito, and M. H. M. Al-Araby, "Analisis Pengaruh Data Augmentation dalam Klasifikasi Kebenaran Pronounce Orang Indonesia dalam Mengucapkan Kata Bahasa Inggris 'City' Menggunakan Metode Deep Learning Tipe MEL Spectrogram dan Convolutional Neural Network," *SSRN (Preprint)*, pp. 1-8, 2025.
- [7] H. C. Chu, Y. L. Zhang, and H. C. Chiang, "A CNN Sound Classification Mechanism Using Data Augmentation," *Sensors*, vol. 23, no. 15, p. 6972, Aug. 2023.
- [8] P. Bitin, A. F. R. Arrizal, and Y. G. Ndun, "Implementasi Algoritma FFT untuk Deteksi Nada dalam Analisis Frekuensi Suara," in *Prosiding Seminar Nasional Teknologi dan Sains Tahun 2025*, vol. 4, Kediri: Universitas Nusantara PGRI Kediri, 2025, pp. 311-320.
- [9] F. Ferdiawan and B. Hartono, "Deteksi Suara Chord Piano Menggunakan Metode Convolutional Neural Network," *JIRE (Jurnal Informatika & Rekayasa Elektronik)*, vol. 5, no. 1, pp. 62-68, April 2022.
- [10] D. Sukietra, "Aplikasi Rekomendasi Musik Berdasarkan Klasifikasi Genre Menggunakan Convolutional Neural Networks," *KALBISIANA: Jurnal Mahasiswa Universitas Kalbis*, vol. 10, no. 1, pp. 91-98, Maret 2024.
- [11] N. Asanah and I. Pratama, "Deep Learning Approach for Music Genre Classification using Multi-Feature Audio Representations," *Sistemasi: Jurnal Sistem Informasi*, vol. 14, no. 5, pp. 2045-2054, 2025.