



Received 27th May 2025
Accepted 27th May 2025
Published -

Open Access

DOI: N/A

Pemanfaatan Ekosistem Hadoop untuk Analisis Data Ekspor Bahan Pangan di Indonesia

Abit Ahmad Oktarian^{*a}, Renisha Putri Giani^{*b},
Arrafi Ramadhan Maulana^{*c}, Nurul Alfajar Gumel^{*d}

^aPROGRAM STUDI SAINS DATA, FAKULTAS SAINS, INSTITUT TEKNOLOGI SUMATERA

^bPROGRAM STUDI SAINS DATA, FAKULTAS SAINS, INSTITUT TEKNOLOGI SUMATERA

^cPROGRAM STUDI SAINS DATA, FAKULTAS SAINS, INSTITUT TEKNOLOGI SUMATERA

^dPROGRAM STUDI SAINS DATA, FAKULTAS SAINS, INSTITUT TEKNOLOGI SUMATERA

* Corresponding E-mail: abit.122450042@student.itera.ac.id

Abstract: This project aims to develop a data analysis system for food commodity exports in Indonesia, specifically for rice, utilizing the Hadoop ecosystem. The system integrates various core components such as HDFS, YARN, HBase, Hive, and Spark to process data from ingestion to analytical aggregation. The data used in this study was sourced from the official website of the Ministry of Agriculture, subsequently processed through a three-layered approach (Bronze, Silver, and Gold) based on a batch processing data lake architecture. The aggregation process successfully generated summary reports of total export volume and value by province and month, providing crucial outputs for strategic analysis. The results demonstrate the system's capability to handle and transform raw data into meaningful information, aligning with the research objective of providing strategic insights to support decision-making in the export sector.

Keywords: Hadoop, Agricultural Export, Rice, Big Data, HDFS

Abstrak: Proyek ini bertujuan untuk membangun sistem analisis data ekspor bahan pangan di Indonesia, khususnya beras, memanfaatkan ekosistem Hadoop. Sistem ini mengintegrasikan berbagai komponen seperti HDFS, YARN, HBase, Hive, dan Spark untuk melakukan pemrosesan data dari tahap ingesti hingga agregasi analitik. Data yang digunakan pada penelitian ini adalah data yang diambil dari situs resmi Kementerian Pertanian, yang kemudian diproses melalui tiga lapisan utama (Bronze, Silver, dan Gold) dengan pendekatan data lake berbasis batch processing. Proses agregasi berhasil menghasilkan ringkasan total volume dan nilai ekspor berdasarkan provinsi dan bulan, yang merupakan *output* penting untuk analisis strategis. Hasilnya menunjukkan bahwa sistem mampu menangani dan mengubah data mentah menjadi informasi yang lebih berarti, sejalan dengan tujuan penelitian untuk menyediakan *insight* strategis dalam mendukung pengambilan keputusan di bidang ekspor.

Kata Kunci : Hadoop, Ekspor Pertanian, Beras, Big Data, HDFS

Pendahuluan

Ekspor bahan pangan memainkan peranan penting dalam perekonomian Indonesia. Banyak sektor yang bergantung pada hasil ekspor pangan untuk meningkatkan perekonomian nasional, namun dengan volume data ekspor yang semakin besar dan kompleks, pemrosesan data secara manual menjadi kurang efisien. Pertanian adalah salah satu sektor di mana teknologi big data seperti Hadoop memberikan dampak yang signifikan. Dari data iklim hingga

hasil produksi, alat big data memungkinkan pemrosesan data pertanian dalam skala yang belum pernah tercapai sebelumnya. Di negara-negara seperti Indonesia, di mana pertanian memainkan peran sentral dalam perekonomian, penerapan analitik big data dapat membantu mengoptimalkan rute perdagangan, memperbaiki perkiraan produksi, dan meningkatkan strategi ekspor (dikutip dan diterjemahkan dari Data Type and Data Sources for Agricultural Big Data and Machine Learning, 2022). Salah satu teknologi yang banyak digunakan untuk mengelola dan



menganalisis data besar adalah Hadoop. Teknologi ini memungkinkan pemrosesan data dalam jumlah besar dengan cara yang lebih efisien, yang sangat penting dalam konteks ekonomi makro. Sebagai contoh, di Asia, termasuk Indonesia, bank sentral telah memanfaatkan teknologi big data untuk menganalisis data perdagangan dan kebijakan ekspor. Hal ini memungkinkan pengambilan keputusan yang lebih tepat terkait dengan inflasi, kebijakan ekspor, dan neraca perdagangan. Dengan demikian, adopsi alat seperti Hadoop telah meningkatkan kemampuan untuk memproses dataset besar, menjadikannya sangat penting dalam mendukung keputusan ekonomi (dikutip dan diterjemahkan dari Big Data in Asian Central Banks, 2023).

Pemanfaatan teknologi big data seperti Hadoop dapat memberikan solusi untuk analisis data yang lebih cepat dan efisien. Hadoop menawarkan ekosistem yang terdiri dari HDFS, MapReduce, Hive, dan HBase yang memungkinkan pemrosesan data dalam jumlah besar dengan lebih efektif. Framework MapReduce dari Hadoop telah banyak digunakan dalam menganalisis dataset besar, terutama di sektor-sektor yang memerlukan pemrosesan data cepat dan pengambilan keputusan. Untuk analisis ekspor, alat seperti MapReduce dari Hadoop dapat memproses dataset kompleks, seperti volume perdagangan dan harga komoditas, yang memungkinkan wawasan secara real-time terhadap fluktuasi ekspor pertanian, membantu pembuat kebijakan dan pelaku bisnis untuk beradaptasi dengan perubahan pasar (dikutip dan diterjemahkan dari Data Analytics for Pandemic Management using MapReduce and Hadoop, 2023).

Proyek ini bertujuan untuk membangun sistem analisis data ekspor bahan pangan di Indonesia dengan memanfaatkan ekosistem Hadoop dan teknologi *Big Data* terkait. Sistem ini akan mengelola data ekspor dalam volume besar secara efisien melalui pendekatan *data lake* berbasis *batch processing*. Dengan menggunakan berbagai komponen seperti HDFS, MapReduce, Apache Hive, Apache Spark, dan HBase, sistem dapat melakukan proses pengumpulan, pembersihan, transformasi, dan analisis data secara terstruktur. Hasil analisis diharapkan dapat memberikan

wawasan yang mendalam terkait pola ekspor, tren harga, dan volume ekspor bahan pangan yang dapat digunakan oleh pemangku kepentingan untuk pengambilan keputusan strategis.

Metode

Metodologi proyek ini mengadopsi pendekatan Waterfall, yang terdiri dari tahapan-tahapan terstruktur dan berurutan.

1. Analisis Kebutuhan (Requirement Analysis)

Tahapan ini bertujuan untuk memahami permasalahan tidak optimalnya pemanfaatan data ekspor bahan pangan karena data yang tersebar di berbagai sumber dan format yang tidak seragam. Stakeholder utama yang diidentifikasi meliputi Kementerian Pertanian, BPS, eksportir komoditas, analis data perdagangan, dan instansi pemerintah terkait ekspor. Output utama yang didefinisikan adalah statistik volume dan nilai ekspor per negara dan provinsi, tren harga, serta visualisasi berbasis data yang siap untuk analisis kebijakan. Atribut data yang diidentifikasi meliputi provinsi asal, negara tujuan, volume ekspor, nilai ekspor, harga satuan, dan periode waktu (bulan dan tahun).

Kebutuhan fungsional proyek ini mencakup:

- Mengumpulkan data ekspor bahan pangan dari sumber resmi Kementan.
- Menyimpan data mentah dalam Hadoop HDFS (Bronze Layer).
- Membersihkan dan menormalkan data (format tanggal, *missing value*).
- Mengubah format file dari CSV ke Parquet untuk efisiensi.
- Mengelompokkan data berdasarkan negara tujuan dan tahun ekspor.
- Menghitung total volume dan nilai ekspor per negara dan provinsi.
- Menyediakan kemampuan *query* data dengan Hive SQL.
- Menyediakan visualisasi hasil ekspor (grafik tren dan perbandingan).
- Menyimpan subset data pada HBase untuk akses *real-time*.
- Menyusun *pipeline batch processing* secara berkala (mingguan/bulanan).
- Mendokumentasikan seluruh alur dan konfigurasi sistem.

Kebutuhan non-fungsional yang ditetapkan meliputi:

- Sistem dapat diskalakan secara horizontal jika volume data meningkat.
- Sistem tersedia dengan minimal *downtime* (*high availability*).
- Sistem menjamin keamanan akses berdasarkan *role* (admin, analis, dll.).
- *Pipeline batch* harus dapat dipulihkan jika terjadi kegagalan proses.
- Sistem dapat dipindahkan ke *host/VM* lain menggunakan Docker.
- Data disimpan dalam format efisien (Parquet/ORC) untuk hemat *storage*.
- Semua proses dan skema disimpan dalam dokumentasi proyek.

2. Perancangan Sistem: Arsitektur dan Desain (System Design)

Arsitektur data yang digunakan adalah Medallion Architecture (*Batch Processing* dengan *Data Lake*).

- Bronze Layer: Menyimpan data mentah (raw) langsung dari sumber eksternal tanpa transformasi, menggunakan HDFS dan Bash Script/curl/API, dengan format CSV/JSON/TSV. Tujuannya adalah sebagai arsip permanen data asli.
- Silver Layer: Data yang telah dibersihkan (parsing tanggal, *handling null*, validasi skema, normalisasi format) menggunakan Apache Hive dan Spark SQL, dengan format Parquet/ORC. Digunakan untuk *query* analitik, laporan, visualisasi, dan *machine learning* (ML).
- Gold Layer: Data yang telah diolah dan digabungkan (agregasi volume, harga, dan ringkasan statistik) menggunakan Apache Hive dan Spark SQL, dengan format Parquet/ORC. Digunakan untuk *query* analitik, laporan, visualisasi, dan ML.

Desain Infrastruktur Kluster Lokal (Hadoop Cluster) mencakup:

- Hadoop Namenode (1 node): Node master untuk HDFS, menyimpan metadata file.
- Hadoop Datanode (2 node): Node worker untuk menyimpan blok data.
- Resource Manager (YARN) (1 node): Mengatur alokasi *resource* dan menjadwalkan *job* Spark/MapReduce.

- NodeManager (2 node): Menjalankan *task* dari *job* Spark atau MapReduce pada masing-masing node.
- Apache HiveServer2 (1 node): *Engine* SQL untuk *query* data dari Hive (via CLI atau BI tools).
- Apache Spark Master (1 node): Koordinator utama eksekusi *job* Spark *batch*.
- Apache Spark Worker (2 node): Eksekusi *job batch processing* (ETL & analitik).
- Apache Hive Metastore (1 node): *Metadata store* untuk Hive *schema* & tabel.
- Apache HBase (1 node): *NoSQL store* untuk akses cepat terhadap subset data tertentu.
- Apache Ambari (1 node): Monitoring kluster Hadoop dan semua layanan.
- Apache Superset (1 node): Visualisasi hasil analitik dari data Gold layer.

Teknologi Apache Projects yang digunakan meliputi:

- Hadoop HDFS: Menyimpan data dalam skala besar secara terdistribusi (bronze, silver, gold).
- Apache Spark: Melakukan transformasi, pembersihan, dan agregasi data.
- Apache Hive: Menyediakan SQL *interface* untuk analitik data.
- Apache HBase: Menyimpan data terstruktur berbasis *key-value* untuk akses *real-time*.
- Apache Ambari: Monitoring status node dan *resource* di dalam kluster.
- Apache Superset: Menampilkan data visualisasi dari hasil analitik Hive atau Gold Layer.
- Docker & WSL2: Menyediakan lingkungan lokal kluster untuk pengembangan Hadoop Stack.

Orkestrasi alur kegiatan sistem:

1. Ambil file dari situs ekspor pertanian (Bronze Layer, Bash Script, curl).
2. Simpan file mentah ke HDFS (Bronze Layer, HDFS CLI).
3. Validasi dan *cleansing* (null, format tanggal, duplikasi) (Silver Layer, Apache Spark, Hive Metastore).
4. Transformasi ke format kolumnar (Parquet) (Silver Layer, Spark + HDFS).
5. Agregasi OLAP (per bulan, negara, nilai ekspor) (Gold Layer, Spark SQL/Hive).
6. Simpan hasil ke direktori Gold dan *refresh* tabel Hive (Gold Layer, HDFS, Hive).

7. Visualisasi analitik dan ekspor ke *dashboard* (Analytics Layer, Apache Superset/Jupyter Notebook).
8. Monitoring performa dan klaster (Seluruh *layer*, Apache Ambari).

3. Implementasi (Implementation)

Bagian ini menjelaskan bagaimana arsitektur dan desain sistem diimplementasikan menjadi sebuah sistem nyata menggunakan ekosistem Hadoop dan Apache *tools* dalam lingkungan lokal berbasis Docker dan WSL2.

Lingkungan Implementasi:

- OS: Ubuntu Server 22.04 (via Docker Container - WSL2 Host).
- Host OS: Windows 11 + Docker Desktop.
- Cluster: Hadoop *pseudo-distributed cluster* (multi-container via Docker Compose).
- Orkestrasi: Bash Script, Crontab, (opsional: Apache Airflow).
- Core Tools: Hadoop HDFS, Apache Spark, Apache Hive, Apache HBase, Apache Superset.
- Penyimpanan: HDFS sebagai *distributed file system*.
- Format Data: CSV (bronze), Parquet (silver), Parquet/ORC (gold).

Struktur Direktori Sistem:

- /opt/bigdata/:
 - docker-compose.yml: File konfigurasi *docker-compose* untuk klaster.
 - data/:
 - bronze/: Folder penyimpanan data mentah (raw data).
 - silver/: Folder penyimpanan data bersih dan terstruktur.
 - gold/: Folder penyimpanan data agregasi dan analitik.
 - scripts/:
 - ingest.sh: Skrip bash untuk pengambilan dan upload data ke Bronze Layer.
 - etl_spark.py: Skrip PySpark untuk pembersihan dan agregasi data.
 - logs/: Folder *log* untuk penyimpanan catatan proses *pipeline* dan *job*.

Tahapan Implementasi Pipeline Batch:

1. Bronze Layer (Ingestion): Mengunduh data ekspor bahan pangan dari API resmi dan mengunggahnya ke HDFS di lapisan Bronze menggunakan *bash script* secara berkala.
2. Silver Layer (Cleansing & Normalization): Menjalankan *job* Apache Spark untuk membaca data mentah di Bronze Layer, membersihkan data, dan menyimpan hasil ke Silver Layer dalam format Parquet.
3. Gold Layer (Aggregation & Analytics): Menggunakan Spark untuk melakukan agregasi data dan menyimpan hasilnya ke Gold Layer.
4. Implementasi Query dan Visualisasi: Membuat tabel Hive yang menunjuk ke data Gold Layer untuk memudahkan *query* dan analisis.
5. Pengembangan ETL: Meng-upload file mentah ke HDFS, menjalankan *job* Spark untuk proses *cleansing* dan *parsing* data ke Silver Layer, melakukan agregasi data menggunakan Spark ke Gold Layer, serta membuat dan *update* tabel Hive pada Gold Layer untuk analitik.
6. Dashboard dan Monitoring: Mengimport data hasil agregasi ke dalam *dashboard* visualisasi seperti Apache Superset atau Jupyter + PyHive untuk eksplorasi data interaktif. Monitoring klaster dan *job* menggunakan Spark UI dan Apache Ambari UI. Log file disimpan secara otomatis di direktori /logs/ dalam *container* Docker untuk *audit* dan *debugging*.

Output Implementasi:

- Data mentah ekspor: /data/bronze/.
- Data bersih (normalized): /data/silver/.
- Ringkasan nilai ekspor (OLAP): /data/gold/.
- Tabel Hive (*ekspor summary*): Hive Metastore.
- Visualisasi ekspor: Apache Superset / Jupyter Dashboard.

4. Penerapan (Deployment)

Sistem yang dibangun diimplementasikan pada lingkungan lokal berbasis Docker VM yang mensimulasikan klaster Hadoop untuk kebutuhan *batch processing data lake*.

Strategi Deployment:

1. Setup Environment: Instalasi Docker Desktop dan konfigurasi Ubuntu VM di bawah Windows dengan WSL2. Menyiapkan klaster Hadoop lokal menggunakan *docker-compose*.

2. Build & Configure: Menyusun file *docker-compose.yml* dan menjalankan *service* Hadoop, Spark, Hive, HBase, Superset. Konfigurasi meliputi pengaturan *resource*, jaringan *container*, dan integrasi antar layanan.
3. Data Ingestion: Menggunakan skrip bash dengan perintah *curl* untuk mengambil data mentah dari sumber resmi secara otomatis, dijalankan secara berkala dengan *cron job*, kemudian mengunggah data ke direktori Bronze Layer di HDFS.
4. Spark Transformation: Menjalankan *job* Spark *batch* yang bertugas melakukan pembersihan (*cleansing*) dan *deploy job* Spark untuk transformasi data dari Bronze → Silver dan agregasi Silver → Gold.
5. Hive Integration: Definisikan tabel Hive berdasarkan data Gold layer untuk analisis SQL. Membuat dan mengelola tabel Hive dari hasil *output* Spark pada Gold Layer, sehingga data siap untuk *query* analitik dan integrasi.
6. Visualisasi: Menjalankan Apache Superset, koneksikan ke Hive Metastore, dan buat menampilkan visualisasi/*dashboard* data ekspor berbasis hasil analisis.

Teknologi Deployment:

- Docker: Virtualisasi semua layanan klaster *Big Data* dalam *container* terpisah.
- Docker Compose: Orkestrasi multi-*container* (Hadoop, Hive, Spark, HBase, Superset).
- Bash + Crontab: Menjadwalkan *ingestion* data ke HDFS.
- Spark Submit: Menjalankan *job* ETL *batch* (pembersihan & agregasi).
- Hive Metastore: Menyimpan *metadata* tabel Hive dan skema analitik.
- Apache Superset: Menyajikan data dalam bentuk *dashboard* visual interaktif.

5. Pengujian (Testing)

Tahap pengujian bertujuan untuk memastikan bahwa setiap komponen dalam *pipeline* pemrosesan data mulai dari *ingestion*, transformasi, agregasi, hingga visualisasi berjalan dengan baik, akurat, dan dapat diandalkan. Pengujian dilakukan secara menyeluruh menggunakan kombinasi uji unit, integrasi, performa, dan validasi *end-to-end*.

Teknologi Deployment:

- Unit Test: Memastikan *script* individual seperti *etl_spark.py* dan *ingest.sh* berjalan sesuai fungsi dan tanpa *error*.
- Integration Test: Memvalidasi integrasi alur data dari tahap *ingestion* → penyimpanan di HDFS → pemrosesan dengan Spark → *query* menggunakan Hive.
- Data Quality Test: Memeriksa kualitas data, termasuk deteksi nilai kosong (*missing values*), duplikasi data, dan konsistensi format pada setiap lapisan data.
- Performance Test: Mengukur waktu eksekusi proses *ingestion* dan *job* Spark *batch* untuk memastikan *pipeline* berjalan efisien dan sesuai SLA.
- End-to-End Test: Melakukan simulasi alur data penuh mulai dari pengambilan data, transformasi, agregasi, hingga tampilan visualisasi di *dashboard* Apache Superset.

6. Analitik (Analytics)

Analisis lanjutan dilakukan terhadap data ekspor bahan pangan yang telah diproses hingga mencapai Gold Layer. Pada tahap ini, digunakan Apache Spark MLlib untuk membangun model prediktif dan menghasilkan wawasan berbasis *machine learning*. Hasil analisis dan model disimpan dalam Hive untuk memudahkan akses dan integrasi lebih lanjut. Untuk eksplorasi data dan visualisasi hasil prediksi atau segmentasi, digunakan Jupyter Notebook, VSCode, serta Apache Superset.

Tujuan Analitik Machine Learning (ML):

- Memprediksi volume ekspor untuk bulan atau tahun berikutnya berdasarkan pola dan tren historis.
- Mengelompokkan negara tujuan ekspor berdasarkan pola pembelian menggunakan teknik *clustering*.
- Menilai faktor penting yang memengaruhi variasi volume ekspor menggunakan metode *feature importance* berbasis pohon keputusan.

Tahapan Analisis:

- Load Data: Membaca data dari Gold Layer menggunakan Spark SQL dan format Parquet/ORC.

- Preprocessing: Normalisasi fitur numerik dengan MinMaxScaler, *encoding* fitur kategorikal seperti komoditas dan negara_tujuan, serta penanganan *missing/null value* jika ditemukan.
- Splitting Data: Membagi data menjadi 80% untuk pelatihan (*training*) dan 20% untuk pengujian (*testing*) menggunakan fungsi *randomSplit*.
- Modeling: Melatih model prediksi (*regresi*) dan *clustering* berdasarkan algoritma yang dipilih.
- Evaluasi: Menggunakan metrik evaluasi seperti: RMSE dan MAE untuk regresi, dan Silhouette Score untuk *clustering*.
- Saving Model: Menyimpan model yang telah dilatih ke direktori /models/ menggunakan fungsi *model.save("path")* agar bisa digunakan kembali.
- Inference: Menjalankan prediksi pada data baru dan menyimpan hasilnya ke tabel analitik Hive atau folder khusus di Gold Layer untuk keperluan visualisasi dan laporan.

Hasil dan Pembahasan

1. Konfigurasi Lingkungan dan Inisialisasi Layanan Hadoop

Sistem analisis data dibangun di atas platform Docker, yang memfasilitasi pembuatan lingkungan Hadoop pseudo-distributed. Berdasarkan log eksekusi, kontainer Docker dengan *bigdata-spark* berhasil dibangun dan dijalankan. Di dalam kontainer ini, berbagai layanan inti Hadoop dan ekosistemnya berhasil diinisialisasi, antara lain:


- HDFS: NameNode dan DataNode.
- YARN: ResourceManager dan NodeManager.
- HBase: HMaster.
- Hive: Metastore service (terindikasi dari log startup dan upaya koneksi via beeline).
- Spark: Spark shell berhasil dijalankan untuk pemrosesan data interaktif.

Proses inisialisasi ini dari log startup layanan Starting Rylid database server mysqld, Starting resourcemanager, Starting nodemanagers, Starting namenodes on, Starting datanodes, running master, dan Starting Metastore Server.


2. Pengembangan dan Eksekusi Skrip PySpark dengan Visual Studio Code (VSCode)

Untuk melakukan transformasi dan analisis data pada Silver dan Gold Layer, sistem ini memanfaatkan Apache Spark dengan bahasa pemrograman Python (PySpark). Pengembangan, pengujian, dan eksekusi skrip PySpark dilakukan menggunakan Visual Studio Code (VSCode). Pendekatan ini memungkinkan fleksibilitas dalam pengembangan dan iterasi cepat skrip sebelum diterapkan pada skala yang lebih besar atau diotomatisasi.

Eksekusi skrip PySpark dilakukan secara manual dari terminal yang terintegrasi dalam VSCode, yang terhubung dengan *engine* Spark. Gambar 1 dan Gambar 2 menunjukkan antarmuka VSCode dengan skrip PySpark yang digunakan dalam penelitian ini.



Gambar 1. untuk analisis_volume.py



Gambar 2. untuk linear_regression_model.py


- analisis_volume.py: Untuk melakukan agregasi data, menghitung total volume dan nilai ekspor per provinsi dan per bulan. Output dari skrip ini adalah data yang siap untuk Gold Layer.

- `linear_regression_model.py`: Untuk membangun model *machine learning* (regresi linear) guna melakukan analisis prediktif terhadap data ekspor.

Penggunaan VSCode sebagai alat bantu utama mempermudah proses *debugging* dan visualisasi alur kerja pengembangan skrip PySpark.


3. Implementasi Tahapan Pipeline

Sesuai dengan rancangan arsitektur Medallion (Bronze, Silver, Gold), data ekspor bahan pangan diproses melalui beberapa tahapan:



Gambar 3. Bronze Layer

- Data mentah diekspor, direpresentasikan oleh file `Book1.csv`, dan berhasil disalin ke dalam lingkungan pemrosesan (kontainer Docker). Perintah `docker cp "D:\bigdata-spark\Book1.csv"` menunjukkan keberhasilan penyalinan data ke direktori `/tmp/` di dalam kontainer. Ini mensimulasikan tahap ingesti data mentah ke HDFS sebagaimana dijelaskan dalam metodologi.



Gambar 4. Silver Layer

- Pada tahap ini, Apache Spark dengan bahasa pemrograman Python (PySpark) digunakan untuk memproses data dari Bronze Layer. Data CSV (`Book1.csv`) dibaca menggunakan Spark, dan skema data berhasil diinferensi secara otomatis.
- Data kemudian diagregasi menggunakan PySpark untuk menghasilkan *insight* analitik, sesuai dengan tujuan Gold Layer. Skrip analisis `volume.py`

mengeksekusi logika agregasi ini. Dua jenis agregasi utama dilakukan:

1. Agregasi berdasarkan Provinsi: Menghitung total Volume (Kg) dan Nilai (US\$) untuk setiap provinsi

Provinsi	Total_Volume_Kg	Total_Nilai_US\$
DKI Jakarta	435689.56	262281.33
Jawa Tengah	31308.0	55806.06
Kalimantan Barat	200.0	153.6
Nusa Tenggara Timur	50.0	33.9
Jawa Timur	6.88	68.0


2. Agregasi berdasarkan Bulan: Menghitung total Volume (Kg) dan Nilai (US\$) untuk setiap bulan.

Bulan	Total_Volume_Kg	Total_Nilai_USD
April	425000.00	240000.0
Oktober	19143.0	36394.24
Juli	17495.0	22136.31
Juni	2682.78	10767.4
Maret	1041.18	3934.25
September	902.0	2340.6
Mei	543.6	1308.9

Februari	443.44	1428.0
Desember	3.44	34.0
November	0.0	0.0
Januari	0.0	0.0
Agustus	0.0	0.0

4. Integrasi Visual


Record Count menurut Provinsi dan Bulan



Gambar 5. Record Count menurut Provinsi dan Bulan

Grafik menunjukkan bahwa jumlah record di setiap provinsi dari Januari hingga Oktober tersebar merata, dengan masing-masing bulan menyumbang satu record per provinsi. Hal ini mengindikasikan bahwa pencatatan data dilakukan secara konsisten setiap bulan di seluruh provinsi, tanpa adanya ketimpangan jumlah data antar waktu maupun wilayah.


Kategori menurut Record Count



Gambar 6. Kategori Count menurut Provinsi dan Bulan

Diagram lingkaran tersebut menunjukkan bahwa sebagian besar record berasal dari kategori Bulan (70,6%), sementara sisanya berasal dari kategori Provinsi (29,4%). Ini mengindikasikan bahwa data lebih banyak dikelompokkan atau tercatat berdasarkan waktu (bulan) dibandingkan berdasarkan wilayah (provinsi), yang bisa menunjukkan fokus analisis atau pencatatan lebih dominan pada dimensi temporal daripada spasial.


Record Count dan Bulan_Index menurut Kategori



Gambar 7. Record Count dan Bulan_Index menurut kategori

Grafik tersebut menunjukkan bahwa kategori Bulan memiliki jumlah record yang lebih tinggi (sekitar 12) dibandingkan kategori Provinsi, yang tidak memiliki batang sama sekali (0 record). Selain itu, nilai Bulan_Index untuk kategori Bulan juga jauh lebih tinggi dibandingkan Provinsi. Hal ini mengindikasikan bahwa data atau aktivitas lebih banyak tercatat dan terfokus pada aspek waktu (bulanan) dibandingkan wilayah (provinsi), baik dari segi jumlah data maupun indeks yang dihitung.

Provinsi menurut Record Count



Gambar 8. Provinsi menurut Record Count

Diagram donat tersebut menunjukkan bahwa distribusi record berdasarkan provinsi bersifat merata, di mana masing-masing dari lima provinsi (Jawa Timur, Kalimantan Barat, Nusa Tenggara Timur, Jawa Tengah, dan DKI Jakarta) menyumbang 20% dari total record. Hal ini mengindikasikan bahwa tidak ada dominasi provinsi tertentu dalam jumlah data, serta menunjukkan distribusi data yang seimbang antar wilayah.

Kesimpulan

Penelitian ini berhasil merancang dan mengimplementasikan sistem analisis data ekspor bahan pangan di Indonesia dengan memanfaatkan ekosistem Hadoop. Sistem yang dibangun di atas platform Docker ini mampu menjalankan berbagai komponen inti seperti HDFS, YARN, HBase, Hive, dan Spark untuk melakukan pemrosesan data dari tahap ingesti hingga agregasi analitik.

Implementasi arsitektur Medallion (Bronze, Silver, dan Gold) menunjukkan bahwa data mentah ekspor (Book1.csv) dapat diolah secara bertahap. Pada Bronze Layer, data mentah berhasil diingest ke dalam lingkungan pemrosesan. Selanjutnya, pada Silver dan Gold Layer, Apache Spark dengan PySpark, yang dikembangkan dan dieksekusi melalui Visual Studio Code, digunakan untuk membaca, menginferensi skema, dan melakukan agregasi data. Proses agregasi berhasil menghasilkan ringkasan total volume dan nilai ekspor berdasarkan provinsi dan bulan, yang merupakan output penting untuk analisis strategis.

Meskipun ditemui beberapa tantangan teknis seperti kesalahan konfigurasi port pada Docker dan kebutuhan manajemen dependensi library Python untuk analisis machine learning lebih lanjut, sistem secara keseluruhan menunjukkan kapabilitas dalam mengolah dan menyajikan data ekspor. Hasil agregasi data membuktikan bahwa sistem mampu menangani dan mengubah data mentah menjadi informasi yang lebih berarti, sejalan dengan tujuan penelitian untuk menyediakan insight strategis dalam mendukung pengambilan keputusan di bidang ekspor. Pengembangan lebih lanjut dapat difokuskan pada otomatisasi pipeline data, integrasi tool visualisasi secara penuh, dan penyempurnaan lingkungan untuk analisis machine learning yang lebih kompleks.

Konflik Kepentingan

Para penulis menyatakan bahwa tidak ada konflik kepentingan terkait dengan publikasi artikel ini.

Ucapan Terima Kasih

Penulis mengucapkan terima kasih kepada semua pihak yang telah mendukung dan berkontribusi dalam penyelesaian penelitian ini, serta secara khusus kepada Bapak Ardika Satria atas bimbingan yang telah diberikan.

Referensi

JURNAL YANG TERBIT SECARA PERIODIK

- [1] Liu, J., Li, L., & Zhang, X. (2022). Data type and data sources for agricultural big data and machine learning. *Sustainability*, 14(23), 16131. <https://doi.org/10.3390/su142316131>.

ARTIKEL DARI PUBLISHED CONFERENCE PROCEEDINGS

- [2] Kumar, A., & Gupta, R. (2023). Data analytics for pandemic management using MapReduce and Hadoop. *Procedia Computer Science*, 2023, 12. <https://doi.org/10.1016/j.procs.2023.12.101>

MAKALAH KERJA

- [3] Cornelli, G., Doerr, S., Gambacorta, L., & Tissot, B. (2022). Big data in Asian central banks. IFC Working Papers No. 21. Bank for

International Settlements.
https://www.bis.org/ifc/publ/ifcb50_18.pdf.

DATA (DIAKSES DARI WEBSITE LEMBAGA PEMERINTAHAN)

- [4] Kementerian Pertanian Republik Indonesia. (n.d.). Ekspor komoditi pertanian menurut provinsi asal. Sistem Informasi Ekspor Pertanian. Diakses dari <https://app3.pertanian.go.id/eksim/eksporProvAsal.php>