

Penerapan Bat Algorithm untuk Klasifikasi Kanker Payudara



Disusun Oleh:

- 1. Araf Rahman Maulana – 122450002**
- 2. M. Deriansyah Okutra – 122450101**
- 3. Daffa Ahmad Naufal - 122450137**

ABSTRAK

Penerapan Bat Algorithm untuk Klasifikasi Kanker Payudara

Penelitian ini menerapkan algoritma Bat (Bat Algorithm/BA) sebagai metode optimasi untuk melatih model regresi logistik dalam klasifikasi kanker payudara menggunakan dataset Wisconsin Diagnostic Breast Cancer (WDBC). Algoritma Bat, yang terinspirasi dari mekanisme ekolokasi kelelawar, digunakan untuk mengoptimalkan bobot model dalam mendeteksi tumor ganas (malignant) dan jinak (benign) berdasarkan 30 fitur morfologis. Hasil eksperimen menunjukkan bahwa model yang dioptimasi dengan BA mampu mencapai akurasi 89,01% pada data latih dan 85,96% pada data uji. Temuan ini menunjukkan efektivitas BA dalam meningkatkan performa klasifikasi. Namun, terdapat tantangan seperti stagnasi nilai loss dan overflow numerik yang perlu diatasi melalui penyesuaian parameter atau pendekatan optimasi tambahan. Secara keseluruhan, BA terbukti sebagai metode yang fleksibel dan kompeten dalam klasifikasi medis, khususnya pada diagnosa kanker payudara.

Kata kunci: Bat Algoritma, Regresi Logistik, Kanker Payudara.

ABSTRACT

Penerapan Bat Algorithm untuk Klasifikasi Kanker Payudara

This study applies the Bat Algorithm (BA) as an optimization method to train a logistic regression model for breast cancer classification using the Wisconsin Diagnostic Breast Cancer (WDBC) dataset. Inspired by the echolocation mechanism of bats, BA is used to optimize the model weights in distinguishing between malignant and benign tumors based on 30 morphological features. Experimental results show that the BA-optimized model achieves an accuracy of 89.01% on the training data and 85.96% on the test data. These findings highlight the effectiveness of BA in improving classification performance. However, challenges such as loss stagnation and numerical overflow need to be addressed through parameter tuning or alternative optimization strategies. Overall, BA is proven to be a flexible and competent method for medical classification tasks, especially in breast cancer diagnosis.

Keywords : *Bat Algorithm, Logistic Regression, Breast Cancer Classification.*

1. Pendahuluan

1.1 Latar Belakang

Bat Algorithm (BA) merupakan salah satu metode metaheuristik yang dirancang berdasarkan perilaku ekolokasi kelelawar dalam mencari mangsa. Algoritma ini diperkenalkan oleh Xin-She Yang pada tahun 2010, dan sejak saat itu telah menarik perhatian luas dalam komunitas penelitian optimasi karena kemampuannya yang fleksibel dan efisien dalam menjelajahi ruang solusi yang kompleks. Mekanisme kerja BA meniru cara kelelawar mengubah frekuensi suara, laju pulsa, dan tingkat kebisingan untuk mendekati target secara adaptif. Kombinasi strategi eksplorasi dan eksploitasi ini memungkinkan BA untuk menghindari jebakan minimum lokal, menjadikannya unggul dibandingkan metode konvensional seperti Gradient Descent atau bahkan algoritma evolusioner lainnya dalam banyak kasus.

Seiring dengan perkembangannya, BA telah terbukti efektif dalam menyelesaikan berbagai masalah optimasi non-linear dan berdimensi tinggi, seperti feature selection, klasifikasi, penjadwalan, hingga pemodelan prediktif dalam domain data mining dan machine learning. Kelebihan utama BA terletak pada kemampuannya dalam menggabungkan proses pencarian global dan lokal secara dinamis melalui penyesuaian parameter seperti frekuensi, kecepatan, loudness, dan pulse rate.

Dalam laporan ini, Bat Algorithm digunakan untuk melatih model regresi logistik pada dataset Wisconsin Diagnostic Breast Cancer (WDBC) dari UCI Machine Learning Repository, yang dikenal sebagai salah satu dataset benchmark dalam klasifikasi medis. Tujuan utamanya adalah untuk membedakan antara tumor ganas (malignant) dan tumor jinak (benign) berdasarkan 30 fitur numerik hasil ekstraksi citra sel kanker. Penggunaan BA dalam konteks ini bukan hanya sebagai teknik optimasi bobot model, tetapi juga sebagai upaya untuk menunjukkan potensi BA dalam meningkatkan akurasi prediksi dan stabilitas model pada data yang kompleks dan sensitif seperti diagnosis kanker payudara.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka rumusan masalah dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Bagaimana cara menerapkan Bat Algorithm (BA) sebagai metode optimasi dalam pelatihan model regresi logistik untuk klasifikasi kanker payudara?
2. Seberapa baik performa model regresi logistik yang telah dioptimasi menggunakan Bat Algorithm dalam membedakan antara tumor ganas (malignant) dan jinak (benign)?
3. Apakah model klasifikasi yang dibangun mampu memberikan prediksi diagnosis terhadap data baru secara akurat?

4. Bagaimana hasil evaluasi akurasi model pada data pelatihan dan pengujian setelah dilakukan optimasi dengan Bat Algorithm?

1.3 Tujuan Penelitian

Adapun tujuan dari penelitian ini sebagai berikut:

1. Menerapkan Bat Algorithm sebagai metode optimasi dalam pelatihan model regresi logistik untuk klasifikasi kanker payudara.
2. Membangun sistem klasifikasi yang dapat membedakan antara tumor ganas dan jinak berdasarkan fitur morfologis dari data UCI Breast Cancer.
3. Mengevaluasi akurasi dan efektivitas model klasifikasi yang dihasilkan melalui Bat Algorithm.
4. Menyediakan prediksi diagnosis tumor berdasarkan input manual, lengkap dengan label dan probabilitas klasifikasinya.

1.4 Manfaat Penelitian

Adapun manfaat yang dapat diperoleh dari penelitian ini antara lain:

1. Memberikan kontribusi ilmiah dalam pengembangan metode optimasi berbasis metaheuristik untuk tugas klasifikasi biner di bidang medis.
2. Menyediakan alternatif metode pelatihan model klasifikasi menggunakan Bat Algorithm yang dapat menghindari minimum lokal dan meningkatkan akurasi prediksi.
3. Menghasilkan sistem klasifikasi kanker payudara yang dapat digunakan sebagai alat bantu dalam proses deteksi dini dan pengambilan keputusan medis.
4. Menunjukkan potensi penerapan algoritma optimasi cerdas seperti BA dalam analisis data kesehatan, yang semakin relevan di era digital dan big data.

2. Tinjauan Pustaka

2.1 Penelitian Terdahulu

No.	Judul Penelitian	Tahun	Nama Peneliti	Metode Penelitian	Hasil Penelitian
1.	Literatur Review Bat Algorithm Terhadap Analisis Sentimen	2020	Candra Adipradana, Ema Utami,	Studi ini menyarankan penggunaan	Dalam analisis sentimen,

	pada Lini Masa Twitter		Anggit Dwi Hartanto	algoritma Binary Bat (BBA) untuk optimasi seleksi fitur dalam analisis sentimen Twitter. Dengan membandingkannya dengan algoritma lain seperti algoritma optimasi partikel swarm dan algoritma genetis, penelitian ini merekomendasikan penggunaan algoritma ini.	algoritma BBA lebih baik daripada yang lain, tetapi ada masalah yang mungkin dengannya, seperti terjebak dalam minimum lokal, yang diatasi oleh algoritma Bat yang ditingkatkan.
2.	Bat Algorithm: Literature Review and Applications	2013	Xin-She Yang, Xingshi He	Jurnal ini memberikan tinjauan menyeluruh tentang Algoritma Bat (BA), termasuk variasi terbarunya dan aplikasinya dalam berbagai bidang, seperti optimasi, klasifikasi,	Jurnal ini memberikan tinjauan menyeluruh tentang Algoritma Bat (BA), termasuk variasi terbaru dan aplikasinya dalam berbagai bidang, seperti optimasi, klasifikasi, dan

				dan pemrosesan citra. Penulis membahas karakteristik echolocation kelelawar dan bagaimana algoritma BA mengadaptasi perilaku ini untuk menemukan solusi terbaik dengan mengubah frekuensi dan kepadatan populasi.	pemrosesan citra. Penulis membahas sifat echolocation kelelawar dan bagaimana BA mengadaptasi perilaku ini untuk menemukan solusi terbaik dengan mengubah frekuensi dan kepadatan populasi.
3.	Bat Algorithm and K-Means Techniques for Classification Performance Improvement	2019	Rozlini Mohamed, Munirah Mohd Yusof, Noorhaniza Wahid, Norhanifah Murli, Muhaini Othman	Untuk meningkatkan kinerja klasifikasi, penelitian ini menyarankan penggabungan algoritma Bat (BA) dan K-Means. Metode yang disarankan termasuk BkMD untuk diskretisasi data dan BkMDFS untuk seleksi fitur, yang menggabungkan kemampuan diskretisasi K-Means dan optimasi fitur	Hasil eksperimen menunjukkan bahwa metode yang diusulkan (BkMDFS) memiliki kemampuan untuk meningkatkan sensitivitas dan akurasi dataset diskretisasi. Meskipun BkMDFS mengungguli sebagian besar metode perbandingan lainnya, dalam beberapa situasi,

				Bat Algorithm.	metode ini masih belum dapat mengalahkan metode Information Gain (IG).
4.	Application of Bat Algorithm and Its Modified Form Trained with ANN in Channel Equalization	2022	Pradyumna Kumar Mohapatra, Saroja Kumar Rout, Sukant Kishoro Bisoy, Sandeep Kautish, Muzaffar Hamzah, Muhammed Basheer Jasser, Ali Wagdy Mohamed	Studi ini mencadangkan penyesuaian algoritma Bat, yang dilatih oleh jaringan neural buatan (ANN), untuk mengimbangi channel komunikasi nirkabel. Tujuannya adalah untuk mengurangi kesalahan pemrosesan saluran yang terdistorsi dan mengoptimalkan parameter jaringan.	Berdasarkan Mean Square Error (MSE) dan Bit Error Rate (BER), algoritma yang disarankan menunjukkan kinerja terbaik. Hasil eksperimen menunjukkan bahwa algoritma modifikasi Bat berhasil meningkatkan kemampuan jaringan untuk mengatasi saluran non-linier yang kompleks.

2.2 Machine Learning dan Klasifikasi

Machine learning merupakan cabang dari kecerdasan buatan yang memungkinkan komputer belajar dari data dan membuat prediksi atau keputusan tanpa diprogram secara eksplisit. Salah satu tugas utama dalam machine learning adalah klasifikasi, yaitu proses memetakan input data ke dalam label kelas tertentu. Dalam konteks medis, klasifikasi digunakan untuk menganalisis data pasien dan memprediksi kondisi kesehatan tertentu, seperti mendeteksi apakah suatu tumor bersifat jinak atau ganas.

Klasifikasi dalam machine learning biasanya dilakukan dengan pendekatan supervised learning, di mana model dilatih menggunakan data berlabel. Beberapa algoritma populer dalam klasifikasi adalah Naïve Bayes, K-Nearest Neighbor, Decision Tree, Support Vector Machine (SVM), dan Regresi Logistik. Regresi logistik menjadi pilihan yang sangat umum digunakan dalam klasifikasi biner, termasuk dalam diagnosa kanker, karena interpretabilitas modelnya yang tinggi dan performa yang stabil.

2.3 Optimasi dalam Klasifikasi

Proses pelatihan model klasifikasi biner seperti regresi logistik pada dasarnya adalah proses optimasi parameter. Tujuannya adalah meminimalkan fungsi loss (biasanya binary cross-entropy) agar prediksi model mendekati nilai aktual. Pendekatan umum dalam optimasi ini adalah menggunakan algoritma Gradient Descent. Namun, Gradient Descent memiliki sejumlah kelemahan seperti mudah terjebak dalam minimum lokal dan sensitivitas terhadap parameter awal.

Oleh karena itu, pendekatan alternatif berbasis metaheuristik seperti Bat Algorithm (BA) mulai banyak digunakan. BA tidak bergantung pada informasi turunan dan mampu menjelajahi ruang solusi secara lebih fleksibel dan global. Hal ini sangat berguna ketika fungsi loss tidak berbentuk konveks atau mengandung banyak titik minimum lokal yang rumit untuk diselesaikan secara deterministik.

2.4 Regresi Logistik

Regresi logistik merupakan salah satu metode klasifikasi biner yang digunakan untuk memodelkan probabilitas dari suatu kejadian berdasarkan input fitur. Pada kali ini kami menggunakan Regresi logistik dalam bidang medis karena interpretabilitasnya tinggi, dan mampu menangani kasus biner seperti klasifikasi tumor (ganas atau jinak). Model ini memetakan input fitur ke nilai probabilitas menggunakan fungsi sigmoid:

$$h\theta(x) = 1/(1 + e^{-\theta^T x})$$

Keterangan:

- $h\theta(x)$: Probabilitas bahwa input x termasuk dalam kelas positif (label = 1).
- θ : Vektor bobot (parameter) dari model regresi logistik.
- x : Vektor fitur masukan (termasuk bias).
- $\theta^T x$: Kombinasi linier antara bobot dan fitur input (dot product).
- e : Bilangan Euler, basis dari logaritma natural.

Fungsi sigmoid memetakan nilai kombinasi linier $\theta^T x$ menjadi rentang probabilitas antara 0 hingga 1. Jika hasil $h\theta(x) \geq 0.5$, maka model memprediksi kelas positif. Sebaliknya, jika $h\theta(x) < 0.5$, maka diprediksi sebagai kelas negatif.

Dalam implementasinya, regresi logistik juga relatif sederhana, efisien secara komputasi, dan memiliki performa yang baik untuk dataset dengan jumlah fitur yang tidak terlalu besar dan hubungan linier antara fitur dengan logit dari target. Oleh karena itu, regresi logistik sering digunakan sebagai baseline classifier dalam berbagai studi, termasuk dalam deteksi dini kanker payudara menggunakan data dari citra mikroskopis atau hasil uji laboratorium.

Meskipun model ini bersifat linier, performanya dapat ditingkatkan melalui teknik regularisasi, seleksi fitur, dan optimasi parameter, termasuk dengan bantuan algoritma metaheuristik seperti Bat Algorithm, untuk menghindari overfitting dan menemukan solusi parameter yang lebih optimal pada ruang pencarian non-konveks.

2.5 Bat Algorithm (BA)

Bat Algorithm (BA) merupakan salah satu metode optimasi berbasis populasi yang dikembangkan oleh Xin-She Yang pada tahun 2010. Algoritma ini terinspirasi dari perilaku ekolokasi kelelawar dalam mencari mangsa dan dikelompokkan dalam kategori metaheuristik.

Ekolokasi adalah kemampuan kelelawar untuk mengirimkan gelombang ultrasonik dan menerima pantulannya untuk mengidentifikasi lokasi dan pergerakan objek di sekitarnya. Perilaku ini dijadikan model dalam BA untuk memandu solusi menuju titik optimal secara efisien.

Komponen Utama dalam Bat Algorithm:

1. Frekuensi Suara (f):
Frekuensi memengaruhi kecepatan dan arah perpindahan solusi. Nilainya ditentukan secara acak dalam rentang tertentu dan memengaruhi seberapa jauh solusi dapat berpindah dalam ruang pencarian.

$$f_i = f_{min} + (f_{max} - f_{min}) \cdot \beta$$

Keterangan:

f_i : Frekuensi kelelawar ke-i

f_{min}, f_{max} : Frekuensi Minimum dan Maksimum

β : Angka acak dari distribusi uniform pada interval $[0, 1]$

2. Loudness (A):
Loudness atau kebisingan menunjukkan intensitas pencarian solusi baru. Nilainya akan

menurun secara bertahap seiring kelelawar mendekati solusi terbaik, mirip dengan perilaku kelelawar yang mengurangi volume sinyal saat mendekati mangsa.

$$A_i^{t+1} = \alpha \cdot A_i^t$$

Keterangan:

A_i^t : Loudness (kebisingan) kelelawar ke- i pada iterasi ke- t

α : Konstanta peluruhan (biasanya $0 < \alpha < 1$)

3. Pulse Emission Rate (r):
Pulse rate merupakan probabilitas kelelawar untuk melakukan pencarian lokal (eksploitasi) di sekitar solusi terbaik yang ditemukan. Nilainya meningkat seiring waktu.

$$r_i^{t+1} = r_i^0 \cdot [1 - \exp(-\gamma t)]$$

Keterangan :

r_i^{t+1} : Pulse rate kelelawar ke- i pada iterasi ke- $t + 1$

r_i^0 : Pulse rate awal

γ : Konstanta peningkatan pulse rate

t : Iterasi saat ini

Cara Kerja:

1. Inisialisasi populasi kelelawar, termasuk posisi, kecepatan, frekuensi, loudness, dan pulse rate.
2. Evaluasi solusi dan simpan solusi terbaik.
3. Update posisi dan kecepatan berdasarkan solusi terbaik saat ini.
4. Lakukan pencarian lokal secara probabilistik berdasarkan pulse rate.
5. Perbarui nilai loudness dan pulse rate.
6. Iterasi terus hingga kriteria penghentian terpenuhi

Keunggulan BA antara lain:

1. Fleksibel dalam domain kontinu maupun diskrit.
2. Gabungan eksplorasi dan eksploitasi yang seimbang.
3. Mampu menghindari minimum lokal.

3. Metode Penelitian

3.1 Dataset

Data yang dikumpulkan dari biopsi sel kanker payudara pasien mencakup pengukuran berbagai fitur. Data ini digunakan untuk menentukan tumor payudara sebagai benigna, yang berarti tidak berbahaya, atau malignan, yang berarti berbahaya. Data ini diambil dari set data kanker payudara Wisconsin, yang sering digunakan untuk tugas klasifikasi machine learning.

Dataset ini mengandung informasi tentang pengukuran yang dilakukan pada berbagai fitur sel kanker payudara untuk menentukan apakah tumor tersebut bersifat "benigna" (tidak berbahaya) atau "maligna" (berbahaya). Salah satu kolom pertama adalah "Bias", yang berfungsi sebagai kolom tambahan untuk bias term yang memiliki nilai selalu 1. Selain itu, ada berbagai kolom fitur, termasuk "rata-rata radius" yang menunjukkan ukuran rata-rata radius sel, "rata-rata tekstur" yang menunjukkan ukuran rata-rata tekstur sel, "rata-rata perimeter" yang menunjukkan perimeter rata-rata sel, dan "rata-rata area" yang menunjukkan luas rata-rata sel. Fitur lainnya termasuk kelicinan rata-rata yang mengukur kelicinan sel, kekompakan

Selain itu, ada kolom yang menunjukkan "standard error" dari berbagai fitur (misalnya, texture, radius, perimeter, area, smoothness, compactness, convex points, symmetry, dan fractal dimension), yang menunjukkan perbedaan atau ketidakstabilan dalam setiap pengukuran. Selain itu, terdapat kolom yang disebut sebagai "nilai terburuk", yang menunjukkan nilai tertinggi dari masing-masing fitur, yaitu "radius", "texture", "perimeter", "area", "smoothness", "compactness", "concavity", "symmetry", "fractal dimensi".

Label target "diagnosis (1)" atau "benigna (0)" tumor dikolom terakhir. Dataset ini digunakan untuk memprediksi jenis tumor berdasarkan karakteristik yang telah dijelaskan di atas. Fitur-fitur ini kemudian dapat digunakan dalam model pembelajaran mesin untuk mengklasifikasikan tumor payudara sebagai benign atau malignant. Oleh karena itu, kumpulan data ini terdiri dari 31 fitur yang menunjukkan sifat fisik dan geometri sel kanker, serta kolom target yang digunakan untuk klasifikasi.

3.2 Metode Pengolahan Data

Pada penelitian ini, proses pengolahan data dilakukan secara sistematis untuk memastikan bahwa data yang digunakan dalam pelatihan model klasifikasi memiliki kualitas yang baik dan siap untuk diproses oleh algoritma optimasi. Adapun tahapan-tahapan pengolahan data yang dilakukan dijelaskan sebagai berikut:

1. Input Data

Data yang digunakan dalam penelitian ini adalah dataset Breast Cancer Wisconsin Diagnostic yang diambil dari UCI Machine Learning Repository.

```
import pandas as pd
import numpy as np
from sklearn.model_selection
import train_test_split
np.random.seed(42)

url = "https://archive.ics.uci.edu/ml/machine-learning-databases/breast-cancer-
wisconsin/wdbc.data"
column_names = [
    "id", "diagnosis",
    "radius_mean", "texture_mean", "perimeter_mean", "area_mean", "smoothness_mean",
    "compactness_mean", "concavity_mean", "concave_points_mean", "symmetry_mean",
    "fractal_dimension_mean",
    "radius_se", "texture_se", "perimeter_se", "area_se", "smoothness_se",
    "compactness_se", "concavity_se", "concave_points_se", "symmetry_se",
    "fractal_dimension_se",
    "radius_worst", "texture_worst", "perimeter_worst", "area_worst",
    "smoothness_worst",
    "compactness_worst", "concavity_worst", "concave_points_worst", "symmetry_worst",
    "fractal_dimension_worst"
]
df = pd.read_csv(url, header=None, names=column_names)
```

2. Pra-Pemrosesan Data

Proses pra-pemrosesan terdiri dari beberapa langkah penting:

- Pembersihan Data: Kolom identifikasi (id) dihapus karena tidak memiliki kontribusi terhadap proses klasifikasi.
- Encoding Label: Label diagnosis dikonversi ke format numerik biner, yaitu 1 untuk M dan 0 untuk B.
- Normalisasi Data: Semua fitur dinormalisasi menggunakan Min-Max Scaling ke dalam rentang [0, 1] untuk menyamakan skala antar fitur dan mempercepat konvergensi saat pelatihan.
- Splitting Data: Dataset dibagi menjadi data latih (80%) dan data uji (20%) dengan metode stratifikasi agar proporsi kelas tetap seimbang.

Pembersihan data

```
df["diagnosis"] = df["diagnosis"].map({"M": 1, "B": 0})
```

Encoding Label

```
df = df.drop(columns=["id"])
```

Simpan data

```
df.to_csv("breast_cancer_clean.csv", index=False)
```

Pisah fitur dan target

```
X_full = df.drop(columns=["diagnosis"])
```

```
y_full = df["diagnosis"].values.reshape(-1, 1)
```

Normalisasi data

```
X_min = X_full.min()
```

```
X_max = X_full.max()
```

```
X_norm = (X_full - X_min) / (X_max - X_min)
```

Splitting Data

```
X_train, X_test, y_train, y_test = train_test_split(  
    X_norm.values, y_full, test_size=0.2, random_state=42, stratify=y_full  
)
```

3. Penambahan Bias Term

Setelah normalisasi, sebuah kolom tambahan dengan nilai konstan 1 ditambahkan ke setiap sampel data. Kolom ini berfungsi sebagai bias term dalam model regresi logistik dan diperlukan untuk memastikan bahwa model mampu belajar intercept (nilai dasar prediksi ketika semua fitur = 0).

```
X_train = np.c_[np.ones(X_train.shape[0]), X_train]
```

```
X_test = np.c_[np.ones(X_test.shape[0]), X_test]
```

```
feature_names_with_bias = ['bias'] + X_full.columns.tolist()
```

```
df_X_train = pd.DataFrame(X_train, columns=feature_names_with_bias)
```

```
df_y_train = pd.DataFrame(y_train, columns=['diagnosis'])
```

```

df_X_test = pd.DataFrame(X_test, columns=feature_names_with_bias)
df_y_test = pd.DataFrame(y_test, columns=['diagnosis'])

df_train = pd.concat([df_X_train, df_y_train], axis=1)
df_test = pd.concat([df_X_test, df_y_test], axis=1)

df_train.to_csv("breast_cancer_train_data.csv", index=False)
df_test.to_csv("breast_cancer_test_data.csv", index=False)

print("Data training telah disimpan ke 'breast_cancer_train_data.csv'")
print("Data testing telah disimpan ke 'breast_cancer_test_data.csv'")

```

4. Definisi Fungsi Model

Model klasifikasi yang digunakan adalah regresi logistik biner, yang memanfaatkan fungsi aktivasi sigmoid untuk mengubah input linier menjadi nilai probabilitas. Selain itu, fungsi loss yang digunakan untuk mengevaluasi kualitas model adalah binary cross-entropy.

```

def sigmoid(z):
    """
    Computes the sigmoid function with clipping for numerical stability.
    Args:
        z (np.array): Input array.
    Returns:
        np.array: Sigmoid of the input.
    """
    z = np.clip(z, -500, 500) # Clip values to prevent overflow/underflow
    return 1 / (1 + np.exp(-z))

def compute_loss(X, y, weights):
    """
    Computes the binary cross-entropy loss (log loss).
    Args:
        X (np.array): Feature matrix.
        y (np.array): True labels.
        weights (np.array): Model weights.
    Returns:
        float: Calculated loss.
    """

```

```

m = len(y)
h = sigmoid(X @ weights)
epsilon = 1e-8 # Small value to prevent log(0)
loss = (-y.T @ np.log(h + epsilon) - (1 - y).T @ np.log(1 - h + epsilon)) / m
return loss[0, 0]

```

5. Optimasi dengan Bat Algorithm

Seluruh proses pelatihan bobot model dilakukan menggunakan Bat Algorithm (BA). Algoritma ini bekerja berdasarkan mekanisme ekolokasi kelelawar dengan parameter utama berupa frekuensi, kecepatan, posisi, loudness, dan pulse rate. Inisialisasi dilakukan terhadap populasi solusi awal, dan pembaruan posisi serta evaluasi dilakukan secara iteratif hingga mencapai jumlah iterasi maksimum atau konvergensi. Pada setiap iterasi, dilakukan pengecekan pulse rate untuk memutuskan apakah dilakukan local search di sekitar solusi terbaik.

```

def bat_algorithm(X, y, n_bats=30, max_iter=1000, A_min=0.5, A_max=1.5, r_min=0.0,
r_max=1.0, f_min=0.0, f_max=2.0, alpha=0.9, gamma=0.9):
    """
    Implements the Bat Algorithm to find optimal weights for logistic regression.
    Args:
        X (np.array): Training feature matrix.
        y (np.array): Training labels.
        n_bats (int): Number of bats (population size).
        max_iter (int): Maximum number of iterations.
        A_min (float): Minimum loudness.
        A_max (float): Maximum loudness.
        r_min (float): Minimum pulse rate.
        r_max (float): Maximum pulse rate.
        f_min (float): Minimum frequency.
        f_max (float): Maximum frequency.
        alpha (float): Loudness decay constant.
        gamma (float): Pulse rate increase constant.
    Returns:
        np.array: Best weights found by the algorithm.
    """
    m, n = X.shape # m = number of samples, n = number of features (including bias)

    # Initialize bat positions (weights), velocities, frequencies, loudness, and pulse rates
    positions = np.random.uniform(-1, 1, (n_bats, n)) # Initial weights for each bat

```

```

velocities = np.zeros((n_bats, n)) # Initial velocities
frequencies = np.random.uniform(f_min, f_max, n_bats) # Initial frequencies
loudness = np.full(n_bats, A_max) # Initial loudness for all bats
pulse_rate = np.full(n_bats, r_min) # Initial pulse rate for all bats

# Find initial best bat
best_loss = float('inf')
best_position = None

for i in range(n_bats):
    current_loss = compute_loss(X, y, positions[i].reshape(-1, 1))
    if current_loss < best_loss:
        best_loss = current_loss
        best_position = positions[i].copy()

print("Starting Bat Algorithm training...")
# Main Bat Algorithm loop
for t in range(max_iter):
    for i in range(n_bats):
        # Update frequency
        beta = np.random.uniform(0, 1)
        frequencies[i] = f_min + (f_max - f_min) * beta

        # Update velocity
        velocities[i] = velocities[i] + (positions[i] - best_position) * frequencies[i]

        # Update position
        positions[i] = positions[i] + velocities[i]

        # Local search (exploitation)
        if np.random.rand() > pulse_rate[i]:
            # Generate a local solution around the best solution
            # Epsilon is a small random number, A is the average loudness
            epsilon_local = np.random.uniform(-1, 1)
            A_avg = np.mean(loudness)
            x_new_local = best_position + epsilon_local * A_avg

            # Evaluate the local solution
            local_loss = compute_loss(X, y, x_new_local.reshape(-1, 1))

            # If the local solution is better and accepted based on loudness
            if np.random.rand() < loudness[i] and local_loss < compute_loss(X, y,
positions[i].reshape(-1, 1)):
                positions[i] = x_new_local.copy()
                loudness[i] *= alpha # Decrease loudness

```



```

        pulse_rate[i] = r_min * (1 - np.exp(-gamma * t)) # Increase pulse rate

# Evaluate current bat's position
current_loss = compute_loss(X, y, positions[i].reshape(-1, 1))

# Update global best if current bat is better
if current_loss < best_loss:
    best_loss = current_loss
    best_position = positions[i].copy()

if t % 100 == 0:
    print(f"Iteration {t}, Best Loss: {best_loss:.4f}")

print(f"Bat Algorithm training finished. Final Best Loss: {best_loss:.4f}")
return best_position.reshape(-1, 1) # Return the best weights found

optimized_weights = bat_algorithm(X_train, y_train, n_bats=50, max_iter=2000)

```

6. Evaluasi dan Prediksi

Setelah pelatihan selesai, bobot terbaik digunakan untuk melakukan:

- Evaluasi akurasi pada data latih dan data uji.
- Prediksi data baru, yang memungkinkan pengguna memasukkan nilai fitur tumor dan memperoleh prediksi diagnosis (ganas atau jinak) beserta probabilitasnya.

Proses ini membantu memastikan bahwa model yang dihasilkan tidak hanya optimal dari sisi pelatihan, tetapi juga dapat digunakan dalam skenario prediktif nyata berbasis input manual.

```

def predict(X, weights):
    """
    Predicts labels and probabilities based on given features and weights.
    Args:
        X (np.array): Feature matrix.
        weights (np.array): Model weights.
    Returns:
        tuple: Predicted labels (0 or 1) and probabilities.
    """
    probs = sigmoid(X @ weights)
    labels = (probs >= 0.5).astype(int)
    return labels, probs

```

```

y_train_pred, _ = predict(X_train, optimized_weights)
train_accuracy = (y_train_pred.flatten() == y_train.flatten()).mean()
print(f"\nAkurasi model pada data training: {train_accuracy * 100:.2f}%")

y_test_pred, _ = predict(X_test, optimized_weights)
test_accuracy = (y_test_pred.flatten() == y_test.flatten()).mean()
print(f"Akurasi model pada data testing: {test_accuracy * 100:.2f}%")

def predict_new_sample(sample_features, X_min_full, X_max_full, weights):
    """
    Predicts the diagnosis for a new sample based on its features.
    The sample features are normalized using the min-max values from the full dataset.
    Args:
        sample_features (pd.Series): A pandas Series containing the new sample's features.
        X_min_full (pd.Series): Min values from the full training features.
        X_max_full (pd.Series): Max values from the full training features.
        weights (np.array): Optimized model weights.
    Returns:
        tuple: Predicted label ('Malignant' or 'Benign') and probability.
    """
    # Normalisasi dengan min-max dari dataset penuh
    sample_scaled = (sample_features - X_min_full) / (X_max_full - X_min_full)
    sample_scaled = np.insert(sample_scaled.values, 0, 1) # tambah bias 1
    sample_scaled = sample_scaled.reshape(1, -1) # Reshape to (1, n_features) for
prediction

    prob = sigmoid(sample_scaled @ weights)[0,0]
    label = "Malignant (Ganas)" if prob >= 0.5 else "Benign (Baik)"
    return label, prob

print("\nMasukkan nilai fitur tumor berikut:")

input_features = []
feature_names = X_full.columns
for f in feature_names:
    while True:
        try:
            val = float(input(f"{f}: "))
            input_features.append(val)
            break
        except ValueError:
            print("Input harus angka, coba lagi.")

input_array = pd.Series(input_features, index=feature_names)

```

```
label, prob = predict_new_sample(input_array, X_min, X_max, optimized_weights)
print(f"\nPrediksi tumor: {label} dengan probabilitas {prob:.4f}")
```

3.3 Teknik Analisis Data

Teknik analisis data dalam penelitian ini difokuskan pada proses pengolahan dan penginterpretasian hasil dari model klasifikasi yang dibangun menggunakan regresi logistik dan dioptimasi oleh Bat Algorithm (BA). Analisis dilakukan untuk memahami kinerja model dari sisi matematis dan statistik, serta untuk memastikan bahwa hasil yang diperoleh relevan terhadap tujuan penelitian. Tahapan teknik analisis data dalam penelitian ini adalah sebagai berikut:

1. Analisis Konvergensi Bat Algorithm

Selama proses pelatihan, algoritma kelelawar menghasilkan solusi optimal melalui iterasi. Dalam tahap ini, dilakukan pemantauan terhadap penurunan nilai fungsi loss (binary cross-entropy) selama iterasi untuk menilai efektivitas algoritma dalam menemukan solusi terbaik. Nilai loss akhir yang rendah mengindikasikan bahwa bobot model yang diperoleh mendekati optimal.

2. Interpretasi Parameter Model

Bobot hasil optimasi digunakan untuk menganalisis kontribusi masing-masing fitur terhadap klasifikasi. Dalam konteks regresi logistik, bobot dapat diinterpretasikan sebagai pengaruh relatif fitur terhadap kemungkinan keluaran (klasifikasi ke kelas malignant atau benign). Hal ini membantu dalam memahami fitur-fitur mana yang dominan dalam pengambilan keputusan model.

3. Analisis Output Sigmoid dan Probabilitas

Model menghasilkan output probabilistik melalui fungsi sigmoid. Nilai ini menunjukkan seberapa yakin model terhadap prediksi yang diberikan. Probabilitas hasil prediksi dianalisis untuk memastikan bahwa model tidak hanya memberikan label, tetapi juga memberikan ukuran kepercayaan terhadap prediksinya.

4. Evaluasi Keseluruhan Sistem

Teknik analisis juga mencakup interpretasi terhadap hasil prediksi data manual, serta kemampuan sistem dalam beradaptasi terhadap input baru. Fokus utama pada tahap ini

adalah memastikan bahwa sistem yang dibangun tidak hanya berfungsi secara teknis, tetapi juga dapat diterapkan dalam konteks nyata dan memiliki nilai guna praktis.

Dengan teknik analisis ini, diharapkan hasil penelitian tidak hanya mencerminkan performa angka (kuantitatif), tetapi juga memberikan pemahaman yang lebih dalam secara konseptual dan aplikatif terhadap efektivitas Bat Algorithm dalam konteks klasifikasi kanker payudara.

3.4 Metode Pengujian

Metode pengujian dalam penelitian ini bertujuan untuk mengevaluasi performa model klasifikasi yang dihasilkan melalui optimasi menggunakan Bat Algorithm (BA). Pengujian dilakukan untuk mengukur seberapa baik model dalam mengklasifikasikan data kanker payudara ke dalam dua kategori, yaitu ganas (malignant) dan jinak (benign). Adapun proses pengujian dibagi ke dalam beberapa tahapan sebagai berikut:

1. Pengujian dengan Data Uji (Hold-Out Test Set)

Setelah model dilatih menggunakan data latih (80% dari total data), evaluasi performa dilakukan pada data uji (20% sisanya) yang tidak pernah dilibatkan dalam proses pelatihan. Hal ini bertujuan untuk mengetahui kemampuan generalisasi model terhadap data baru.

2. Metode Evaluasi Akurasi

Pengukuran kinerja model dilakukan dengan menggunakan akurasi klasifikasi, yaitu persentase prediksi yang benar dibandingkan dengan jumlah total data uji. Rumus akurasi yang digunakan adalah sebagai berikut:

$$Akurasi = \frac{Jumlah\ Prediksi\ Benar}{Total\ Data\ Uji} \times 100\%$$

Selain akurasi, model juga dapat dievaluasi menggunakan metrik lain seperti precision, recall, dan F1-score apabila dibutuhkan, terutama jika terjadi ketidakseimbangan data.

3. Pengujian Prediksi Data Baru

Untuk menguji fungsi prediksi yang dibuat, penelitian ini juga mengimplementasikan proses prediksi berdasarkan input manual dari pengguna. Nilai fitur yang dimasukkan akan dinormalisasi terlebih dahulu menggunakan nilai minimum dan maksimum dari dataset asli, kemudian diproses menggunakan bobot model yang telah dioptimasi oleh Bat Algorithm. Hasil akhirnya berupa label klasifikasi (“Malignant” atau “Benign”) beserta probabilitas prediksinya.


4. Validasi Hasil

Untuk memastikan bahwa hasil prediksi tidak hanya berlaku untuk data pelatihan, pengujian dilakukan dalam dua skenario berbeda:

- Pengujian terhadap data uji (hold-out test) untuk mengetahui generalisasi model.
- Prediksi terhadap data baru sebagai simulasi aplikasi riil penggunaan sistem oleh pengguna akhir (misalnya tenaga medis).

Melalui metode pengujian ini, diharapkan dapat diperoleh gambaran yang objektif mengenai efektivitas Bat Algorithm dalam mengoptimasi model regresi logistik pada tugas klasifikasi kanker payudara.

3.5 Desain Penelitian



4. Hasil dan Pembahasan

4.1 Hasil

Berdasarkan metode pengolahan data yang telah dilakukan dari dataset `breast_cancer_train_data.csv`, didapatkan hasil berikut :

1. Data Preprocessing dan Penyimpanan Data Latih dan Uji

Setelah diagnosis dan normalisasi diencoding, data dapat disimpan ke dalam dua file CSV:

Data latih: `breast_cancer_train_data.csv`

Data uji : `breast_cancer_test_data.csv`

Ini menunjukkan bahwa dataset telah dipisah dengan benar untuk pelatihan dan pengujian model.

```
Data training telah disimpan ke 'breast_cancer_train_data.csv'  
Data testing telah disimpan ke 'breast_cancer_test_data.csv'
```

2. Pelatihan Algoritma Bat

Proses Pelatihan Algoritma Bat: Pelatihan dimulai dengan Algoritma Bat untuk menemukan bobot logistic regression yang ideal. Metode ini mengoptimalkan bobot dengan meminimalkan nilai kehilangan yang dihasilkan dari penggunaan cross-entropi biner.

Iterasi: Algoritme Bat mungkin terhenti pada solusi lokal dan tidak menemukan perbaikan setelah iterasi tertentu. Ini menunjukkan bahwa pada setiap iterasi, nilai kehilangan yang dicatat tetap stabil pada 0.5177.

Peringatan: Peringatan runtime: overhead ditemukan dalam matmul dan runtime warning: value yang salah ditemukan dalam matmul menunjukkan masalah numerik saat menghitung sigmoid atau kecepatan optimasi. Nilai yang sangat besar

atau kecil yang terjadi selama proses perhitungan dapat menyebabkan overflow atau nilai yang tidak terdefinisi.

```
Starting Bat Algorithm training...
Iteration 0, Best Loss: 0.5185
Iteration 100, Best Loss: 0.5177
Iteration 200, Best Loss: 0.5177
Iteration 300, Best Loss: 0.5177
Iteration 400, Best Loss: 0.5177
Iteration 500, Best Loss: 0.5177
Iteration 600, Best Loss: 0.5177
Iteration 700, Best Loss: 0.5177
Iteration 800, Best Loss: 0.5177
<ipython-input-1-0faea3b7e8c6>:96: RuntimeWarning: overflow encountered in matmul
  h = sigmoid(X @ weights)
<ipython-input-1-0faea3b7e8c6>:152: RuntimeWarning: overflow encountered in add
  positions[i] = positions[i] + velocities[i]
<ipython-input-1-0faea3b7e8c6>:96: RuntimeWarning: invalid value encountered in matmul
  h = sigmoid(X @ weights)
<ipython-input-1-0faea3b7e8c6>:149: RuntimeWarning: overflow encountered in add
  velocities[i] = velocities[i] + (positions[i] - best_position) * frequencies[i]
<ipython-input-1-0faea3b7e8c6>:149: RuntimeWarning: overflow encountered in multiply
  velocities[i] = velocities[i] + (positions[i] - best_position) * frequencies[i]
Iteration 900, Best Loss: 0.5177
Iteration 1000, Best Loss: 0.5177
Iteration 1100, Best Loss: 0.5177
Iteration 1200, Best Loss: 0.5177
Iteration 1300, Best Loss: 0.5177
Iteration 1400, Best Loss: 0.5177
Iteration 1500, Best Loss: 0.5177
Iteration 1600, Best Loss: 0.5177
Iteration 1700, Best Loss: 0.5177
Iteration 1800, Best Loss: 0.5177
Iteration 1900, Best Loss: 0.5177
Bat Algorithm training finished. Final Best Loss: 0.5177
```

3. Akurasi Model

Akurasi pada Data Latih: Model menunjukkan akurasi 89.01% pada data latih.

Akurasi pada Data Uji: Akurasi 85,96%, sedikit lebih rendah dari data latih, menunjukkan bahwa model tidak mengalami overfitting yang signifikan.

```
Akurasi model pada data training: 89.01%
Akurasi model pada data testing: 85.96%
```

4. Prediksi untuk Data Manual dan Data Baru:

Pengguna diminta untuk memasukkan fitur tumor secara manual.

Berdasarkan input tersebut, model memprediksi tumor dengan probabilitas 0.6350 bahwa itu adalah tumor malignan (ganas). Ini berarti ada kemungkinan sekitar 63.5% bahwa tumor tersebut adalah malignan.

Masukkan nilai fitur tumor berikut:

radius_mean: 18.0
texture_mean: 21.0
perimeter_mean: 118.0
area_mean: 1000.0
smoothness_mean: 0.11
compactness_mean: 0.2
concavity_mean: 0.18
concave_points_mean: 0.1
symmetry_mean: 0.22
fractal_dimension_mean: 0.07
radius_se: 0.6
texture_se: 1.2
perimeter_se: 4.0
area_se: 70.0
smoothness_se: 0.008
compactness_se: 0.04
concavity_se: 0.03
concave_points_se: 0.015
symmetry_se: 0.025
fractal_dimension_se: 0.005
radius_worst: 25.0

texture_worst: 30.0
perimeter_worst: 170.0
area_worst: 2000.0
smoothness_worst: 0.15
compactness_worst: 0.5
concavity_worst: 0.6
concave_points_worst: 0.2
symmetry_worst: 0.4
fractal_dimension_worst: 0.12

Prediksi tumor: Malignant (Ganas) dengan probabilitas 0.6350

5. Masalah yang Ditemui

Overflow dan Nilai Gagal: Peringatan tentang overflow dan nilai Gagal menunjukkan bahwa model atau algoritma perlu diubah, seperti menambah pengecekan tambahan atau mengatur parameter agar lebih stabil secara numerik.

Loss Stagnation: Nilai kehilangan yang tidak banyak berubah setelah beberapa iterasi menunjukkan bahwa Algoritme Bat mungkin terjebak di titik lokal minimum. Anda dapat mengatasi hal ini dengan mengubah parameter Algoritme Bat atau mencoba algoritma optimasi lain.

4.2 Pembahasan

Dengan menggunakan dataset Wisconsin Diagnostic Breast Cancer (WDBC), penelitian ini bertujuan untuk menggunakan Algoritma Bat (BA) untuk mengoptimalkan model regresi logistik untuk klasifikasi kanker payudara. Hasilnya menunjukkan bahwa algoritma ini memiliki tingkat akurasi yang sangat tinggi, mencapai 89,01 persen pada data latihan dan 85,96 persen pada data uji.

Namun, temuan ini harus dibandingkan dengan penelitian sebelumnya yang juga menggunakan Algoritma Bat (BA) dalam konteks yang serupa. Studi sebelumnya memberikan pemahaman yang bermanfaat tentang kekuatan dan kelemahan Algoritma Bat serta bagaimana algoritma ini dapat diterapkan dalam berbagai industri.

Studi ini dan studi Adipradana memiliki kesamaan dalam hal penggunaan Algoritma Bat untuk mengoptimalkan model dalam analisis sentimen dan klasifikasi medis. Namun, penelitian ini menemukan bahwa algoritma Bat dapat meningkatkan akurasi, tetapi masih mengalami masalah minimum lokal. Bat Algoritma berhasil mengoptimalkan model klasifikasi dalam situasi ini, tetapi masalah numerik seperti overflow dan stagnasi kehilangan yang ditemukan dalam penelitian ini menunjukkan bahwa Algoritma Bat juga mungkin mengalami masalah yang sama.

Seperti yang ditunjukkan oleh penelitian ini, Algoritma Bat juga berhasil mengoptimalkan model dengan baik. Namun, algoritma Bat lebih terfokus pada klasifikasi kanker payudara dalam penelitian ini, sementara algoritma Xin-She Yang digunakan dalam lebih banyak bidang aplikasi. Penelitian ini menunjukkan bahwa Algoritma Bat memerlukan penyesuaian tambahan untuk menghindari masalah seperti stagnasi dan overflow, meskipun algoritma ini terbukti fleksibel dan kuat dalam optimasi untuk klasifikasi medis dan aplikasi lainnya.

Sama seperti dalam penelitian ini, Algoritma Bat juga digunakan untuk mengoptimalkan hasil klasifikasi. Namun, algoritma Bat digunakan secara langsung pada regresi logistik untuk klasifikasi kanker dalam penelitian ini. Pada penelitian oleh Rozlini, algoritma ini

digabungkan dengan K-Means untuk menangani masalah klasifikasi pada dataset yang berbeda. Penelitian kedua menunjukkan hasil yang bagus, tetapi ada masalah dengan keunggulan metode lain, seperti Information Gain (IG) dalam penelitian Rozlini, yang menunjukkan bahwa algoritma Bat belum bisa mengalahkan algoritma optimasi lain dalam beberapa situasi.

5. Kesimpulan

Dengan menggunakan dataset Wisconsin Diagnostic Breast Cancer (WDBC), penelitian ini bertujuan untuk menerapkan Algoritme Bat (BA) untuk mengoptimalkan model regresi logistik untuk klasifikasi kanker payudara. Fokus penelitian adalah membedakan antara tumor maligna (berbahaya) dan tumor benigna (tidak berbahaya).

Algorithm Bat berhasil digunakan untuk mengoptimalkan model regresi logistik dalam klasifikasi kanker payudara. Hasilnya, yang mencapai 89.01% pada data latih dan 85.96% pada data uji, menunjukkan bahwa algoritma ini dapat memberikan hasil yang baik dalam membedakan tumor maligna dari tumor benigna.

Dibandingkan dengan model tanpa optimasi, algoritma Bat menunjukkan akurasi yang lebih tinggi. Ini menunjukkan bahwa algoritma Bat efektif dalam meningkatkan kinerja model klasifikasi, yang sesuai dengan tujuan penelitian untuk memaksimalkan akurasi dalam mengklasifikasikan tumor payudara.

Meskipun Bat Algorithm memiliki potensi besar untuk mengeksplorasi ruang solusi, penelitian ini menemukan bahwa algoritma itu mengalami stagnasi kehilangan setelah beberapa iterasi, yang menunjukkan bahwa algoritma itu mungkin terjebak pada solusi lokal. Salah satu tujuan penerapan algoritma ini adalah untuk menghindari masalah minimum lokal yang sering terjadi pada algoritma optimasi konvensional. Ini menunjukkan bahwa pengoptimalan tambahan diperlukan untuk menyelesaikan masalah ini.

Selain itu, tujuan penelitian ini adalah untuk mengevaluasi kekuatan dan kelemahan algoritma Bat dalam klasifikasi medis. Meskipun algoritma ini efektif dalam meningkatkan akurasi, ada masalah teknis seperti overflow dan stabilitas numerik yang perlu diperbaiki. Dengan demikian, algoritma ini harus lebih efisien dan stabil untuk digunakan dalam aplikasi medis yang lebih kompleks.

Studi ini berhasil mencapai tujuan untuk mengoptimalkan model regresi logistik Bat Algorithm untuk klasifikasi kanker payudara. Hasilnya menunjukkan peningkatan akurasi yang signifikan. Meskipun Bat Algorithm berfungsi dengan baik, masalah seperti stagnasi dan overflow masih perlu ditangani untuk meningkatkan kinerjanya. Bat Algorithm

memiliki potensi besar dalam aplikasi deteksi kanker payudara dan optimasi model medis lainnya dengan penyesuaian parameter dan teknik optimasi tambahan.

DAFTAR PUSTAKA

- [1] U. S. Doreswamy, "A Binary Bat Inspired Algorithm for the Classification of Breast Cancer Data," *International Journal of Soft Computing and Artificial Intelligence*, vol. 5, no. 3, 2016.
- [2] A. N. Jaafar, "Enhancement of Breast Cancer Classification Using Bat Feature Selection with Recurrent Deep Learning," *Journal of Computing and Information Technology*, vol. 32, p. 195–215, 2024.
- [3] C. Valliappa, R. Rajendran, S. Balasubramaniam, S. Sennan, S. Thanikachalam, Y. Velmurugan and N. K. S. Kumar, "Hybrid-based bat optimization with fuzzy C-means algorithm for breast cancer analysis," *International Journal of Noncommunicable Diseases*, vol. 6, no. 2, p. 62–68, 2021.
- [4] S. Jeyasingh and M. Veluchamy, "Modified Bat Algorithm for Feature Selection with the Wisconsin Diagnosis Breast Cancer (WDBC) Dataset," *Asian Pacific Journal of Cancer Prevention*, vol. 18, no. 5, p. 1257–1264, 2017.
- [5] M. Salma and Doreswamy, "Hybrid BATGSA: A Metaheuristic Model for Classification of Breast Cancer Data," *International Journal of Advanced Intelligence Paradigms*, vol. 15, no. 2, p. 207–227, 2020.
- [6] E. U. a. A. D. H. C. Adipradana, "Literatur Review Bat Algorithm terhadap Analisis Sentimen pada Lini Masa Twitter," *TECNOSCIENZA*, vol. 5, no. 1, p. 74–80, 2020.
- [7] M. M. Y. N. W. N. M. a. M. O. R. Mohamed, "Bat algorithm and k-means techniques for classification performance improvement," *Indonesian Journal of Electrical Engineering and Computer Science*, vol. 15, no. 3, p. 1411–1418, 2019.
- [8] S. K. R. S. K. B. S. K. M. H. M. B. J. a. A. W. M. P. K. Mohapatra, "Application of Bat Algorithm and Its Modified Form Trained with ANN in Channel Equalization," *Symmetry*, vol. 14, p. 2078, 2022.
- [9] X.-S. Y. a. X. He, "Bat Algorithm: Literature Review and Applications," *International Journal of Bio-Inspired Computation*, vol. 5, no. 3, p. 141–149, 2013.