

**PENGARUH *CUMULATIVE EXPLAINED VARIANCE* PADA
INCREMENTAL PRINCIPAL COMPONENT ANALYSIS
TERHADAP KLASIFIKASI *NAÏVE BAYES* 16S RRNA
BERBASIS K-MER**

TUGAS AKHIR



**ARAFI RAMADHAN MAULANA
122450002**

**PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2026**

**PENGARUH *CUMULATIVE EXPLAINED VARIANCE* PADA
INCREMENTAL PRINCIPAL COMPONENT ANALYSIS
TERHADAP KLASIFIKASI *NAÏVE BAYES* 16S RRNA
BERBASIS *K-MER***

TUGAS AKHIR

Diajukan sebagai syarat untuk memperoleh gelar Sarjana



**ARAFI RAMADHAN MAULANA
122450002**

**PROGRAM STUDI SAINS DATA
FAKULTAS SAINS
INSTITUT TEKNOLOGI SUMATERA
2026**

HALAMAN PENGESAHAN

Tugas Akhir Sarjana dengan judul "**Pengaruh *Cumulative Explained Variance* pada *Incremental Principal Component Analysis* terhadap Klasifikasi *Naïve Bayes* 16S rRNA Berbasis *k-mer***" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 30 April 2026

Penulis,




ARAFT RAMADHAN MAULANA
NIM. 122450002



Diperiksa dan disetujui oleh,

Pembimbing I



Tirta Setiawan, S.Pd., M.Si
NIP. 199008222022031003

Pembimbing II



Fajri Farid, M.Sc.
NIP. 199411122024061003

Disahkan oleh,
Koordinator Program Studi Sains Data
Fakultas Sains
Institut Teknologi Sumatera



Tirta Setiawan, S.Pd., M.Si
NIP. 199008222022031003

Sidang Tugas Akhir:

Penguji I : Yuliana, M.Cs.

Penguji II : Yoga Aji Sukma, S.Mat., M.Stat.


HALAMAN PERNYATAAN ORISINALITAS

Skripsi ini adalah karya saya sendiri dan semua sumber baik yang dikutip maupun yang dirujuk telah saya nyatakan benar.

Nama : ARAFI RAMADHAN MAULANA

NIM : 122450002

Tanda tangan :



Tanggal : 30 April 2026

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : ARAFI RAMADHAN MAULANA
NIM : 122450002
Program Studi : Sains Data
Fakultas : Sains
Jenis karya : Tugas Akhir

demikian pengembangan ilmu pengetahuan, menyetujui untuk memberikan Hak Bebas Royalti Noneksklusif (*Non-Exclusive Royalty Free Right*) kepada Institut Teknologi Sumatera atas karya ilmiah saya yang berjudul:


Pengaruh *Cumulative Explained Variance* pada *Incremental Principal Component Analysis* terhadap Klasifikasi *Naïve Bayes* 16S rRNA Berbasis *k*-mer

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/format-kan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan
Pada tanggal : 30 April 2026

Yang menyatakan



ARAFI RAMADHAN MAULANA

ABSTRAK

Pengaruh *Cumulative Explained Variance* pada *Incremental Principal Component Analysis* terhadap Klasifikasi *Naïve Bayes* 16S rRNA Berbasis *k*-mer

ARAFI RAMADHAN MAULANA (122450002)

Pembimbing I: Tirta Setiawan, S.Pd., M.Si

Pembimbing II: Fajri Farid, M.Sc.

Klasifikasi taksonomi bakteri menggunakan gen 16S rRNA menghadapi tantangan dimensi data tinggi akibat penggunaan representasi fitur berbasis *k*-mer. Dimensi fitur yang tinggi akan membebani sumber daya komputasi serta berpotensi memicu fenomena *curse of dimensionality*. Penelitian ini bertujuan menganalisis pengaruh variasi *Cumulative Explained Variance* (CEV) pada metode *Incremental Principal Component Analysis* (IPCA) terhadap kinerja klasifikasi algoritma *Naïve Bayes* pada tingkat *Phylum*. Dataset sekuens 16S rRNA wilayah V3-V4 dari basis data SILVA dikonversi menjadi fitur *k*-mer dengan panjang $k = 6$ (4.096 fitur). Reduksi dimensi dilakukan menggunakan IPCA dengan variasi target CEV mulai dari 0,50 hingga 0,95. Hasil eksperimen menunjukkan peningkatan target variansi tidak selalu berbanding lurus dengan peningkatan akurasi. Nilai CEV 0,60 ditetapkan sebagai titik optimal yang menghasilkan Akurasi tertinggi sebesar 96,89%, *Weighted F1-Score* 97,05%, dan AUC 0,9994. CEV 0,60 berhasil mereduksi dimensi sebesar 97,12% (menyisakan 118 komponen utama) dengan waktu komputasi selama 68,0 detik. Target CEV tinggi (0,95) justru menurunkan akurasi secara signifikan menjadi 81,12% akibat masuknya komponen variansi kecil yang bersifat *noise*. Studi ini menyimpulkan bahwa mempertahankan informasi penting dengan dimensi rendah lebih efektif dibandingkan memaksimalkan variansi total.

Kata kunci: 16S rRNA, *Cumulative Explained Variance*, IPCA, *k*-mer, *Naïve Bayes*.

ABSTRACT

The Effect of Cumulative Explained Variance in Incremental Principal Component Analysis on k-mer-Based 16S rRNA Naïve Bayes Classification

ARAFI RAMADHAN MAULANA (122450002)

Advisor I: Tirta Setiawan, S.Pd., M.Si

Advisor II: Fajri Farid, M.Sc.

Bacterial taxonomic classification using the 16S rRNA gene faces challenges regarding high dimensionality from k-mer feature representation. High dimensionality burdens computational resources and potentially triggers the curse of dimensionality. This study aims to analyze the effect of Cumulative Explained Variance (CEV) variations in Incremental Principal Component Analysis (IPCA) on Naïve Bayes classification performance at the Phylum level. The 16S rRNA sequence dataset (V3-V4 region) from the SILVA database was converted into k-mer features with length $k = 6$ (4.096 features). Dimensionality reduction was performed using IPCA with CEV targets ranging from 0,50 to 0,95. Experimental results show that increasing variance targets does not linearly correlate with increased accuracy. A CEV of 0,60 was determined as the optimal point, yielding the highest Accuracy of 96.89%, Weighted F1-Score of 97,05%, and AUC of 0,9994. CEV 0,60 successfully reduced dimensionality by 97,12% (retaining 118 principal components) with an computation time of 68,0 seconds. High CEV targets (0,95) significantly lowered accuracy to 81,12% due to the inclusion of small variance components acting as noise. This study concludes that retaining essential information with lower dimensions is more effective than maximizing total variance.

Keywords : 16S rRNA, Cumulative Explained Variance, IPCA, k-mer, Naïve Bayes.

MOTTO

Hidup Mulia atau Mati Syahid.

HALAMAN PERSEMBAHAN

Skripsi ini saya persembahkan dengan tulus untuk:

1. Diri saya sendiri yang telah bekerja keras, menjaga konsistensi, dan tetap bertahan menghadapi setiap tantangan hingga berhasil menyelesaikan tanggung jawab akademik ini tepat pada waktunya.
2. Kedua orang tua tercinta atas dukungan doa, kasih sayang, dan pengorbanan yang tidak terhitung, serta saudara-saudara saya yang selalu memberikan semangat selama saya menempuh pendidikan di Institut Teknologi Sumatera.
3. Lutfia Aisyah Putri yang telah setia mendampingi dan memberikan dukungan penuh di setiap tahapan, mulai dari seminar proposal, seminar hasil, hingga selesainya tugas akhir ini.
4. Bapak Tirta Setiawan, S.Pd., M.Si., Bapak Fajri Farid, M.Sc., Ibu Yuliana, M.Cs., dan Bapak Yoga Aji Sukma, S.Mat., M.Stat. selaku dosen pembimbing serta penguji atas bimbingan, waktu, dan ilmu yang diberikan selama proses penyusunan skripsi ini.
5. Teman-teman angkatan 2022 Program Studi Sains Data Institut Teknologi Sumatera atas bantuan, solidaritas, dan kebersamaan yang telah dilalui selama masa perkuliahan.

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Allah SWT atas segala limpahan berkah, rahmat, dan kekuatan-Nya sehingga skripsi ini dapat terselesaikan dengan baik. Skripsi ini disusun sebagai bagian dari perjalanan akademis untuk menyelesaikan pendidikan jenjang sarjana pada Institut Teknologi Sumatera. Penulis menyadari bahwa perjalanan ini bukanlah proses yang dilakukan sendirian, melainkan berkat dukungan dan doa dari berbagai pihak yang luar biasa. Penulis dengan ini mengucapkan terima kasih kepada:


1. Diri penulis sendiri yang telah berjuang dengan tangguh, menolak untuk menyerah pada rasa lelah, dan berhasil membuktikan bahwa setiap rintangan dalam penyusunan tugas akhir ini adalah proses pendewasaan yang berharga,
2. Kedua orang tua tercinta sebagai sumber kekuatan dan doa yang tidak pernah putus, terima kasih atas kasih sayang tulus serta dukungan moral dan materiil yang menjadi fondasi utama bagi penulis untuk mencapai titik ini,
3. Saudara-saudara penulis yang senantiasa memberikan keceriaan dan dorongan semangat, sehingga menjadi salah satu sumber utama dalam memulihkan semangat penulis,
4. Lutfia Aisyah Putri, sosok yang paling sabar dan setia menemani setiap langkah penulis, mulai dari titik awal seminar proposal, perjuangan di seminar hasil, hingga selesainya skripsi ini, terima kasih telah menjadi pendengar terbaik di masa-masa sulit,
5. Bapak Tirta Setiawan, S.Pd., M.Si. selaku dosen pembimbing pertama yang telah memberikan bimbingan dengan penuh kesabaran, memberikan arahan yang mencerahkan, serta membagi ilmu yang sangat berarti bagi perkembangan penulis,
6. Bapak Fajri Farid, M.Sc. selaku dosen pembimbing kedua yang selalu meluangkan waktu untuk memberikan saran-saran kritis namun membangun, membantu penulis melihat setiap kekurangan

menjadi sebuah penyempurnaan,

7. Ibu Yuliana, M.Cs. selaku dosen penguji pertama atas segala masukan, koreksi, dan pandangan baru yang sangat membantu dalam meningkatkan kualitas isi skripsi ini,
8. Bapak Yoga Aji Sukma, S.Mat., M.Stat. selaku dosen penguji kedua atas evaluasi yang mendalam dan arahan yang sangat membantu penulis pada penelitian ini,
9. Seluruh dosen Program Studi Sains Data yang telah menjadi mentor dalam membagi ilmu pengetahuan serta membentuk pola pikir penulis selama masa perkuliahan di kampus ini,
10. Seluruh teman-teman seperjuangan angkatan 2022 atas rasa solidaritas yang tinggi, diskusi yang menghidupkan semangat, serta memori indah yang membuat perjalanan kuliah ini terasa jauh lebih ringan dan bermakna.

Penulis menyadari bahwa penyusunan skripsi ini masih memiliki keterbatasan dan jauh dari kata sempurna. Akhir kata, penulis memohon maaf yang sebesar-besarnya atas segala kekurangan yang ada, dan berharap karya sederhana ini dapat memberikan manfaat bagi perkembangan ilmu pengetahuan di masa depan.

Lampung Selatan, 30 April 2026



Araf Rahman Maulana

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PENGESAHAN	iii
HALAMAN PERNYATAAN ORISINALITAS.....	iv
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI .	v
ABSTRAK.....	vi
ABSTRACT.....	vii
MOTTO.....	viii
HALAMAN PERSEMBAHAN	ix
KATA PENGANTAR	x
DAFTAR ISI	xii
DAFTAR GAMBAR.....	xv
DAFTAR TABEL.....	xvi
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan Penelitian	3
1.4 Batasan Masalah	3
BAB II TINJAUAN PUSTAKA	4
2.1 Penelitian Terkait	4
2.2 Gen 16S rRNA	5
2.3 Taksonomi Bakteri	6
2.4 <i>Preprocessing</i> Data	7
2.4.1 Integrasi Data	7
2.4.2 Pembersihan Data Sekuens	8
2.4.3 Pengelompokan Ulang	9
2.5 Representasi Data Berbasis <i>k-mer</i>	10

2.6	Pembagian Data Latih dan Uji.....	11
2.7	Reduksi Dimensi	12
2.8	<i>Cumulative Explained Variance</i> (CEV).....	16
2.9	Klasifikasi <i>Naïve Bayes</i>	17
2.9.1	Teorema Bayes	17
2.9.2	<i>Gaussian Naïve Bayes</i> untuk Fitur Kontinu	18
2.9.3	Aturan Keputusan	18
2.10	Evaluasi Kinerja	19
BAB III METODE PENELITIAN		22
3.1	Deskripsi Data	22
3.2	Pra-pemrosesan Data.....	23
3.2.1	Integrasi dan Distribusi Data.....	23
3.2.2	Pembersihan Sekuens	24
3.2.3	Pengelompokan Ulang.....	25
3.3	Ekstraksi Fitur Berbasis <i>k-mer</i>	26
3.4	Skenario Pengujian.....	26
3.5	Reduksi Dimensi dengan IPCA	27
3.6	Klasifikasi dan Evaluasi	27
3.7	Diagram Alir Penelitian.....	28
BAB IV HASIL DAN PEMBAHASAN		30
4.1	Karakteristik Data dan Pra-pemrosesan	30
4.1.1	Kualitas Sekuens DNA.....	30
4.1.2	Pengelompokan Kelas.....	33
4.2	Ekstraksi Fitur dan Transformasi Data.....	35
4.2.1	Representasi Sekuens DNA Asli.....	36
4.2.2	Mekanisme <i>Sliding Window</i> dan Pembentukan Fitur	36
4.2.3	Matriks Frekuensi <i>k-mer</i>	37
4.2.4	Karakteristik Dimensi dan <i>Sparsity</i> Matriks	37
4.2.5	Analisis Pola Motif Dominan	39
4.3	Analisis Pembagian Data Latih dan Data Uji.....	40
4.4	Reduksi Dimensi dan Analisis Variansi dengan IPCA .	41

4.5	Evaluasi Kinerja Model Klasifikasi pada Berbagai Target CEV	45
4.5.1	Pengaruh Variasi Target CEV terhadap Performa Model	46
4.5.2	<i>Trade-off</i> antara Performa Klasifikasi dan Kompleksitas Fitur	47
4.5.3	Analisis Tingkat Kepercayaan dan Fenomena Overconfidence.....	48
4.5.4	Penentuan Target CEV Optimal.....	50
BAB V	KESIMPULAN DAN SARAN.....	53
5.1	Kesimpulan	53
5.2	Saran	54
	DAFTAR PUSTAKA	55
	LAMPIRAN.....	60

DAFTAR GAMBAR

Gambar 2.1	Gen 16S rRNA	6
Gambar 2.2	Klasifikasi Tingkatan Takson	7
Gambar 2.3	Ilustrasi Proses Tokenisasi <i>k-mer</i> ($k=6$)	11
Gambar 3.1	Distribusi 20 Kelas <i>Phylum</i> Terbanyak	24
Gambar 3.2	Diagram Alir Penelitian	29
Gambar 4.1	Komposisi Nukleotida Sebelum (a) dan Sesudah (b) Eliminasi Basa Ambigu	31
Gambar 4.2	Histogram Distribusi Panjang Sekuens DNA Setelah Pembersihan	33
Gambar 4.3	Distribusi Sampel pada Kelas <i>Phylum</i> Setelah <i>Regrouping</i>	35
Gambar 4.4	DNA fragmen 16S rRNA sebelum Ekstraksi .	36
Gambar 4.5	Matriks Fitur <i>k-mer</i> Hasil Ekstraksi	37
Gambar 4.6	Histogram Distribusi Fitur per Sampel <i>Non-Zero k-mers</i>	38
Gambar 4.7	Lima Belas Motif <i>k-mer</i> Paling Dominan Berdasarkan Total Frekuensi Kemunculan . .	39
Gambar 4.8	Distribusi Sampel pada Kelas Mayoritas dan Minoritas	41
Gambar 4.9	Kurva Variansi Kumulatif Terhadap Jumlah Komponen Utama (IPCA)	42
Gambar 4.10	Matriks Vektor Eigen pada Model IPCA . . .	44
Gambar 4.11	Matriks Hasil Transformasi Kontinu pada Data Latih	45
Gambar 4.12	Grafik Tren Performa Model dan Waktu Komputasi Terhadap Target CEV	46
Gambar 4.13	Grafik Analisis <i>Trade-off</i> antara Akurasi dan Waktu Komputasi	48
Gambar 4.14	Grafik Analisis Keandalan Model	49
Gambar 4.15	Visualisasi <i>Radar Chart</i> Perbandingan Karakteristik Performa antar Skenario	51

DAFTAR TABEL

Tabel 2.1	Penelitian Terdahulu	4
Tabel 2.2	Kode IUPAC untuk Basa Standar (Tidak Ambigu)	8
Tabel 2.3	Kode IUPAC untuk Basa Ambigu	9
Tabel 3.1	Sampel Data Sekuens (FASTA)	22
Tabel 3.2	Sampel Data Taksonomi (TSV)	23
Tabel 3.3	Ilustrasi Pembersihan pada Sekuens <i>noise</i>	25
Tabel 3.4	Penerapan <i>Regrouping</i> pada Kelas Minoritas	26
Tabel 3.5	Ilustrasi Transformasi Sekuens ke Vektor Fitur ($k = 6$)	26
Tabel 4.1	Rincian Hasil Pengelompokan Ulang (<i>Regrouping</i>) Kelas Minoritas	34
Tabel 4.2	Jumlah Komponen Utama Berdasarkan Target CEV	42
Tabel 4.3	Rincian Nilai Eigen dan Proporsi Variansi pada Model CEV 0,60	43
Tabel 4.4	Rincian Nilai Metrik Evaluasi Model pada Berbagai Skenario CEV	46

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kemajuan teknologi sekuensing DNA telah memungkinkan analisis data genomik dalam skala besar, termasuk identifikasi dan klasifikasi mikroorganisme melalui gen 16S ribosomal RNA (rRNA) [1]. Gen 16S rRNA banyak digunakan dalam taksonomi mikroba karena mengandung variabel yang memungkinkan identifikasi organisme hingga tingkat tertentu, seperti *phylum*, *class*, *genus*, bahkan *species* [2]. Data sekuens 16S rRNA biasanya diubah menjadi representasi numerik berbasis *k-mer*, yaitu subsekuens sepanjang *k* nukleotida yang menunjukkan pola atau karakteristik genom [3]. Karena representasi berbasis *k-mer* menghasilkan data yang sangat besar, metode reduksi dimensi diperlukan untuk mendapatkan informasi penting dan mengurangi beban komputasi [4].

Principal Component Analysis (PCA) adalah salah satu metode yang paling banyak digunakan untuk reduksi dimensi [5]. Tetapi metode PCA tidak cocok untuk menangani *dataset* berukuran besar karena memerlukan pemrosesan semua data sekaligus [6]. Metode *Incremental Principal Component Analysis* (IPCA) diterapkan sebagai solusi yang memungkinkan pembelajaran bertahap tanpa harus memproses seluruh data secara sekaligus [7]. Parameter penting dalam IPCA adalah *Cumulative Explained Variance* (CEV), yang menunjukkan bagian dari variansi data secara keseluruhan yang dapat dijelaskan oleh sejumlah komponen utama yang digunakan [8]. Nilai CEV yang terlalu rendah dapat menyebabkan kehilangan informasi penting, sedangkan nilai yang terlalu tinggi dapat menyebabkan kelebihan fitur dan beban komputasi yang signifikan [9].

Optimasi klasifikasi pada data sekuens telah menjadi fokus berbagai penelitian terdahulu. Utami dkk. pada tahun 2014 menunjukkan

stabilitas algoritma *Naïve Bayes* pada data metagenom berbasis *k-mer*, meskipun akurasinya sangat bergantung pada representasi fitur [10]. Reduksi dimensi memiliki tantangan dalam pemilihan jumlah komponen yang penting. Studi oleh Zheng dan Rakovski pada tahun 2021 mengungkapkan bahwa nilai *Cumulative Explained Variance* (CEV) tinggi tidak selalu menjamin akurasi terbaik, karena komponen bervariasi rendah sering kali memiliki informasi penting [11]. Temuan ini didukung oleh Janecek dkk. pada tahun 2008 yang menyatakan bahwa hubungan antara seleksi fitur dan akurasi tidak selalu bersifat linear. Penerapan nilai CEV tanpa evaluasi berpotensi menghasilkan model yang tidak optimal.

Pemilihan nilai CEV yang tepat menjadi aspek penting untuk mencapai keseimbangan antara efisiensi komputasi dan kualitas informasi yang dipertahankan. Penelitian ini berfokus pada analisis pengaruh variasi nilai CEV pada IPCA terhadap kinerja algoritma *Naïve Bayes* dalam mengklasifikasikan data fragmen 16S rRNA berbasis *k-mer* pada tingkat *phylum*. *Naïve Bayes* dipilih dalam penelitian ini karena algoritma ini sederhana namun sangat efisien [12]. *Naïve Bayes* memiliki kinerja yang baik pada data berdimensi tinggi dan metode ini bersifat sederhana tetapi praktis, dengan efisiensi yang berasal dari asumsi independensi fitur [13].

1.2 Rumusan Masalah

Berdasarkan latar belakang sebelumnya, berikut adalah rumusan masalah penelitian ini:

1. Bagaimana pengaruh variasi target *Cumulative Explained Variance* (CEV) pada *Incremental Principal Component Analysis* (IPCA) terhadap kinerja klasifikasi dan efisiensi waktu komputasi model *Naïve Bayes*?
2. Bagaimana nilai *Cumulative Explained Variance* (CEV) yang paling optimal dalam memberikan hasil klasifikasi terbaik pada tingkat *phylum*?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini berdasarkan rumusan masalah adalah sebagai berikut:

1. Menganalisis pengaruh variasi target *Cumulative Explained Variance* (CEV) pada *Incremental Principal Component Analysis* (IPCA) terhadap kinerja klasifikasi dan efisiensi waktu komputasi model *Naïve Bayes*.
2. Menentukan nilai CEV optimal yang menghasilkan performa klasifikasi terbaik pada tingkat *phylum*.

1.4 Batasan Masalah

Batasan masalah penelitian ini ditetapkan sebagai berikut agar pembahasan tetap terarah:

1. Penelitian ini hanya menganalisis pengaruh variasi nilai *Cumulative Explained Variance* (CEV) pada metode *Incremental Principal Component Analysis* (IPCA) terhadap kinerja klasifikasi *Naïve Bayes*.
2. Metode klasifikasi yang digunakan terbatas pada *Naïve Bayes*, tanpa membandingkannya dengan algoritma klasifikasi lain.
3. Data yang digunakan merupakan fragmen sekuens 16S rRNA yang direpresentasikan dalam bentuk fitur *k-mer* dengan panjang $k = 6$. Variasi nilai k tidak dianalisis karena penelitian ini difokuskan pada parameter CEV.
4. Analisis dilakukan hanya pada tingkat taksonomi *phylum*, karena ukuran data yang besar menyebabkan keterbatasan sumber daya komputasi untuk memproses seluruh tingkat taksonomi.
5. Nilai *Cumulative Explained Variance* (CEV) pada IPCA divariasikan dalam rentang tertentu.
6. Evaluasi model menggunakan Akurasi, *Weighted F1-Score*, Presisi, *Recall*, AUC-ROC, serta *confidence score*.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terkait

Bagian ini memaparkan sejumlah penelitian terdahulu yang memiliki relevansi dengan topik penelitian. Rincian mengenai identitas penulis, tahun publikasi, judul, serta hasil penelitian disajikan dalam Tabel 2.1.

Tabel 2.1 Penelitian Terdahulu

No.	Penulis	Tahun	Judul Penelitian	Hasil Penelitian
1	Dian Kartika Utami, Wisnu Ananta, dan Agus Buono	2014	Klasifikasi Metagenom dengan <i>Naïve Bayes Classifier</i>	Penggunaan frekuensi <i>k-mer</i> dengan algoritma <i>Naïve Bayes</i> menghasilkan performa klasifikasi yang stabil pada data metagenom. Ukuran <i>k-mer</i> juga berpengaruh terhadap akurasi karena mencerminkan variasi komposisi nukleotida pada tiap tingkat taksonomi.
2	Hayssam Soueidan dan Macha Nikolski	2016	<i>Machine Learning for Metagenomics: Methods and Tools</i>	Metode berbasis <i>k-mer</i> efektif dan tetap menjadi teknik yang umum digunakan dalam analisis metagenom.


Tabel 2.1 (Lanjutan)

No.	Penulis	Tahun	Judul Penelitian	Hasil Penelitian
3	Jianwei Zheng dan Cyril Rakovski	2021	<i>On the Application of Principal Component Analysis to Classification Problems</i>	Pemilihan jumlah komponen PCA sangat penting dalam klasifikasi. Penelitian menunjukkan bahwa <i>Cumulative Explained Variance</i> (CEV) tidak selalu mencerminkan kemampuan komponen dalam meningkatkan akurasi, karena komponen dengan variansi rendah pun dapat memuat informasi yang relevan.
4	Andreas G. K. Janecek, Wilfried N. Gansterer, Michael A. Demel, dan Gerhard F. Ecker	2008	<i>On the Relationship Between Feature Selection and Accuracy</i>	Hubungan antara variansi komponen dan performa klasifikasi belum tentu linear.

2.2 Gen 16S rRNA

Gen 16S rRNA adalah penanda genetik yang banyak digunakan untuk mengidentifikasi dan mengelompokkan bakteri [2]. Gen ini terdapat pada semua prokariot, berperan penting dalam proses sel, sehingga

cocok untuk melihat hubungan kekerabatan mikroba [1]. Gen 16S rRNA memiliki panjang sekitar 1500 bp dan tersusun atas bagian konservatif yang memungkinkan penggunaan primer universal, serta sembilan daerah hipervariabel (V1–V9) yang berisi variasi sekuens [1]. Kombinasi ini membuat 16S rRNA efektif untuk penentuan taksonomi pada tingkat *phylum*.




Gambar 2.1 Gen 16S rRNA [14]

Keunggulan 16S rRNA dibanding penanda lain seperti 5S atau 23S berasal dari panjang sekuensnya yang pas, strukturnya yang stabil, dan variasi sekuensnya yang cukup untuk membedakan jenis mikroba [2]. Gen ini juga menjadi pilihan paling efektif ketika metode identifikasi berbasis ciri fisiologis atau biokimia tidak lagi memberikan hasil yang akurat [2]. Gen 16S rRNA penting dalam penelitian ini karena mampu membedakan mikroba pada tingkat pengelompokan besar, yaitu tingkat *phylum*. Gen ini juga dapat direpresentasikan dalam bentuk *k-mer* sehingga cocok digunakan sebagai fitur dalam metode pembelajaran mesin seperti IPCA dan *Naïve Bayes* [10].

2.3 Taksonomi Bakteri

Proses klasifikasi taksonomi melibatkan pembagian sekuens ke dalam kelompok berdasarkan peringkat hierarkis yang spesifik. Visualisasi struktur hierarki taksonomi ini disajikan pada Gambar 2.2, yang memperlihatkan urutan tingkatan dari *Kingdom*, *phylum*, *Class*, *Order*, *Family*, *Genus*, hingga *Species*. Pengelompokan sekuens dalam penelitian 16S rRNA difokuskan pada rentang taksonomi dari tingkat *phylum* hingga *genus* sesuai dengan data taksonomi yang tersedia pada

database [15]. Identifikasi yang akurat pada tingkatan tersebut sangat penting untuk mengestimasi jarak evolusi dan kelimpahan relatif mikroba di dalam lingkungan yang kompleks [15].



Gambar 2.2 Klasifikasi Tingkatan Takson [16]

2.4 *Preprocessing Data*

Data sekuens biologis mentah sering kali mengandung gangguan (*noise*) atau ketidakseimbangan distribusi yang dapat menurunkan kinerja model [17]. Tahapan pra-pemrosesan (*preprocessing*) diperlukan untuk meningkatkan kualitas data sebelum masuk ke tahap ekstraksi fitur [18]. Tahapan pra-pemrosesan dalam penelitian ini mencakup proses integrasi data, pembersihan sekuens, serta penanganan ketidakseimbangan kelas [18].

2.4.1 *Integrasi Data*

Integrasi data merupakan salah satu tahapan pra-pemrosesan (*preprocessing*) yang bertujuan untuk menyatukan dan menyelaraskan kumpulan data dari berbagai sumber atau format yang berbeda agar dapat diolah lebih lanjut secara komputasional [18]. Tahapan pra-pemrosesan, yang secara spesifik mencakup proses integrasi data, sangat diperlukan untuk menyaring *noise* dan meningkatkan kualitas data secara keseluruhan sebelum data mentah tersebut masuk ke tahap ekstraksi fitur [18].

Dataset dalam penelitian bioinformatika dan metagenomik sering kali terdiri atas data yang terpisah pada sistem penyimpanan yang berbeda dan bersifat heterogen. Representasi nukleotida umumnya disimpan di dalam format file sekuens primer (seperti FASTA), sedangkan informasi yang berkaitan dengan hierarki taksonominya tersimpan secara terpisah dalam file tabular pendukung (seperti TSV). Integrasi data bertugas memetakan dan menyatukan kedua sumber informasi ini melalui sebuah atribut penghubung atau kunci utama (*primary key*) yang saling beririsan (*intersection*), seperti ID identifikasi spesifik pada setiap sekuens.

2.4.2 Pembersihan Data Sekuens

Sekuens DNA standar tersusun atas empat basa nukleotida utama, yaitu Adenin (A), Sitosin (C), Guanin (G), dan Timin (T). Data sekunder hasil sekuensing sering kali memuat karakter lain seperti ‘N’, ‘R’, dan ‘Y’ yang merepresentasikan ketidakpastian pembacaan mesin sekuensing atau dikenal sebagai kode ambiguitas IUPAC (*IUPAC ambiguity codes*) [19]. Kode IUPAC terdiri atas dua kelompok, yaitu basa standar (tidak ambigu) dan basa ambigu yang menyatakan lebih dari satu kemungkinan nukleotida [20]. Tabel 2.2 dan 2.3 menyajikan pemisahan kedua kelompok tersebut beserta keterangannya.

Tabel 2.2 Kode IUPAC untuk Basa Standar (Tidak Ambigu) [20]

Simbol	Nama Basa	Keterangan
A	<i>Adenine</i>	Adenin
C	<i>Cytosine</i>	Sitosin
G	<i>Guanine</i>	Guanin
T	<i>Thymine</i>	Timin

Tabel 2.3 Kode IUPAC untuk Basa Ambigu [20]

Simbol	Makna (<i>Mnemonic</i>)	Basa yang Direpresentasikan
R	<i>PuRine</i>	A atau G
Y	<i>PYrimidine</i>	C atau T
S	<i>Strong interaction</i>	C atau G
W	<i>Weak interaction</i>	A atau T
K	<i>Keto</i>	T atau G
M	<i>aMino</i>	C atau A
B	<i>Not A (B follows A)</i>	C, T, atau G
D	<i>Not C (D follows C)</i>	A, T, atau G
H	<i>Not G (H follows G)</i>	A, C, atau T
V	<i>Not T or U (V follows U)</i>	A, C, atau G
N	<i>aNy</i>	A, C, T, atau G

Keberadaan karakter ambiguitas tersebut berpotensi mengganggu proses tokenisasi *k-mer* karena dapat menghasilkan kombinasi fitur yang tidak bermakna secara biologis dan menyebabkan ketidakakuratan [19]. Proses filtrasi diterapkan dengan menghapus seluruh karakter selain basa standar (A, T, G, dan C) dari dataset [21]. Langkah ini sesuai dengan *filtering* dalam analisis metagenomik untuk membuang gangguan (*noise*) dan memastikan bahwa hanya data berkualitas tinggi yang digunakan pada model klasifikasi [18], [22].

2.4.3 Pengelompokan Ulang

Tahapan pra-pemrosesan data dalam pembelajaran mesin terkadang menghadapi kendala teknis akibat keberadaan kelas dengan jumlah sampel yang sangat sedikit. Teori pelabelan ulang (*relabeling*) memperbolehkan modifikasi identitas kelas yang anggotanya terlalu sedikit tersebut agar sistem komputasi tidak mengalami error [23]. Penerapan teori ini dilakukan melalui langkah pengelompokan ulang (*re-grouping*), yaitu menggabungkan semua kelas berukuran sangat kecil menjadi satu entitas kelompok yang baru [23].

Tujuan utama dari penggabungan kelas ini untuk melengkapi batas minimal jumlah sampel yang diminta oleh berbagai fungsi algoritma, termasuk kalkulasi rasio pemotongan data. Kelengkapan batas minimal melalui entitas gabungan ini pada akhirnya memungkinkan komputer mengeksekusi pemotongan berstrata tanpa mengalami kegagalan sistem. Langkah ini secara komputasi untuk menyelamatkan model dari hambatan tanpa harus merusak struktur utama dataset [23].


2.5 Representasi Data Berbasis *k-mer*

Representasi data berbasis *k-mer* adalah langkah dalam analisis bioinformatika yang mengubah sekuens DNA panjang, seperti gen 16S rRNA, menjadi vektor numerik [17]. Istilah *k-mer* didefinisikan sebagai subsekuens dari DNA dengan panjang tetap k [24]. Proses transformasi ini, yang dikenal sebagai tokenisasi *k-mer*, melibatkan pemecahan sekuens menjadi himpunan *substring* berukuran k yang dapat membantu mengidentifikasi pola-pola yang terdapat pada sekuens [3]. Total *k-mer* yang dihasilkan dari sekuens dengan panjang N adalah $N - k + 1$ [25]. Kumpulan *k-mer* yang dihasilkan kemudian digunakan sebagai dasar perbandingan antar mikroorganisme [17].

Proses tokenisasi diikuti oleh ekstraksi fitur menggunakan *Count Vectorizer* untuk mengubah sekuens menjadi representasi numerik berdasarkan frekuensi setiap *k-mer* pada masing-masing sekuens [17]. Proses ini menghasilkan matriks fitur berdimensi tinggi yang kemudian digunakan sebagai input untuk model pembelajaran mesin [17].

Metode *k-mer* efektif, tetapi kompleksitas dan kebutuhan memori dapat meningkat tajam ketika jumlah *k-mer* bertambah [17]. Penentuan nilai k yang tepat menjadi langkah penting karena harus disesuaikan dengan panjang sekuens, tujuan analisis, dan kapasitas komputasi [24]. Penelitian ini menggunakan *k-mer* dengan panjang $k = 6$, yang menghasilkan $4^6 = 4096$ fitur [3]. Jumlah fitur tersebut kemudian direduksi menggunakan metode *Incremental Principal Component Analysis* (IPCA) [17]. Ilustrasi proses tokenisasi *k-mer* dengan panjang

$k = 6$ pada sekuens DNA pendek sepanjang $N = 11$ bp disajikan pada Gambar 2.3 untuk memberikan gambaran penerapan metode tersebut.



Gambar 2.3 Ilustrasi Proses Tokenisasi k -mer ($k=6$)

Pembentukan k -mer pada Gambar 2.3 memperlihatkan hasil sebanyak 6 k -mer dari sekuens $N = 11$ dan $k = 6$, sesuai dengan persamaan $N - k + 1$. Jumlah tersebut merupakan hasil dari proses *sliding window* yang bergeser satu nukleotida pada setiap langkah. Ekstraksi k -mer dilakukan menggunakan *sliding window* satu basa, dan jumlah total k -mer yang dihasilkan dari sekuens sepanjang N adalah $N - k + 1$ [25].

2.6 Pembagian Data Latih dan Uji

Proses pengujian model klasifikasi memerlukan pembagian data menjadi himpunan data latih dan data uji. Proporsi pemotongan data yang umum digunakan sebagai standar dalam pembelajaran mesin adalah rasio 80:20. Pembagian rasio ini mengalokasikan 80% data untuk fase pelatihan dan 20% sisanya untuk fase pengujian. Penetapan rasio pembagian ini secara teoretis memberikan keseimbangan optimal agar model memiliki ukuran data yang cukup untuk belajar, sekaligus menyisakan ruang yang memadai untuk validasi kinerja [26]. Metode pembagian berstrata (*stratified split*) bertugas membagi data tersebut agar setiap kelas taksonomi memiliki perwakilan yang proporsional di kedua himpunan sesuai rasio yang ditetapkan [27].

Aturan utama dari metode stratifikasi ini mewajibkan setiap kelas memiliki jumlah anggota minimal agar perhitungan persentase

pembagian bisa berjalan. Kelompok data yang anggotanya terlalu sedikit, misalnya hanya berisi satu atau dua sampel, akan membuat algoritma kesulitan melakukan pemotongan secara matematis. Kekurangan jumlah anggota ini memicu munculnya *deficit records*, yaitu kondisi di mana kelas tertentu tidak mendapat kuota pembagian sehingga menghasilkan himpunan uji yang kosong [28]. Kondisi partisi kosong tersebut pada akhirnya membuat komputer menolak mengeksekusi perintah dan memunculkan galat (*error*) pada sistem. Ilustrasi matematis dari kegagalan komputasi akibat jumlah sampel yang tidak memenuhi syarat rasio 80:20 ditampilkan melalui dua skenario berikut:

1. Contoh Kelas Mayoritas (Total 100 Sampel):

$$N_{\text{train}} = 100 \times 0,80 = 80 \text{ sampel}$$

$$N_{\text{test}} = 100 \times 0,20 = 20 \text{ sampel}$$

2. Contoh Kelas Minoritas Ekstrem (Total 1 Sampel):

$$N_{\text{train}} = 1 \times 0,80 = 0,8 \text{ sampel} \approx 0,8 \text{ sampel}$$

$$N_{\text{test}} = 1 \times 0,20 = 0,2 \text{ sampel} \approx 0,2 \text{ sampel}$$

Pembulatan nilai 0,2 oleh sistem komputasi akan menghasilkan 0 sampel pada himpunan uji. Kondisi tersebut tidak memenuhi syarat pembagian data dengan metode (*stratified split*), karena setiap kelas seharusnya memiliki minimal 1 sampel pada data latih dan 1 sampel pada data uji.

2.7 Reduksi Dimensi

Reduksi dimensi adalah teknik untuk menyederhanakan data yang kompleks dengan cara mengurangi jumlah variabelnya melalui transformasi linier, namun tetap mempertahankan informasi utama [11]. Teknik ini sangat penting untuk mengatasi masalah jumlah fitur

yang terlalu banyak yang dapat menurunkan akurasi klasifikasi dan memperlambat proses komputasi [29].

Metode spesifik yang diterapkan pada penelitian ini adalah *Incremental Principal Component Analysis* (IPCA) yang mengacu pada algoritma Ross, serta menjadi landasan implementasi pada pustaka *Scikit-learn* [30]. Algoritma ini bekerja melalui penggabungan dekomposisi nilai singular (SVD) dari data yang sudah ada (blok A) dengan data baru (blok B) untuk menghasilkan model yang diperbarui [31]. Rincian langkah matematis algoritma ini adalah sebagai berikut:

Langkah 1: Input dan Inisialisasi

Asumsikan model awal dari data sebelumnya (blok A) memiliki parameter N_A (jumlah sampel), μ_A (rata-rata), U_A (basis eigen), dan Σ_A (nilai singular). Data *batch* baru (blok B) selanjutnya masuk sebagai matriks X_B .

Langkah 2: Pembaruan Rata-rata (*Mean Update*)

Rata-rata global diperbarui terlebih dahulu untuk memusatkan data. Rata-rata baru μ_{baru} diperoleh melalui penghitungan rata-rata tertimbang [31]:

$$\mu_{baru} = \frac{N_A \mu_A + N_B \mu_B}{N_A + N_B} \quad (2.1)$$

Keterangan:

- μ_{baru} : Rata-rata gabungan dari seluruh data yang telah diproses
- N_A, N_B : Jumlah sampel pada data lama dan data baru
- μ_A, μ_B : Vektor rata-rata dari data lama dan data baru

Langkah 3: Pembentukan Vektor Koreksi Rata-rata

Algoritma menghitung vektor koreksi (v) untuk menangkap perubahan variansi akibat pergeseran pusat data [31]:

$$v = \frac{N_A N_B}{N_A + N_B} (\mu_B - \mu_A) \quad (2.2)$$

Keterangan:

$\mathbf{v}$: Vektor koreksi pergeseran rata-rata

$\sqrt{\frac{\dots}{\dots}}$: Akar kuadrat untuk mengurangi efek perbedaan jumlah data

Langkah 4: Augmentasi Matriks Data Baru

Data baru X_B dipusatkan (*centered*) menjadi $\tilde{X}_B$, kemudian digabungkan dengan vektor koreksi ($\mathbf{v}$) untuk membentuk matriks gabungan $\hat{X}_B$ [31]:

$$\hat{X}_B = [\tilde{X}_B \mid \mathbf{v}]^T \quad (2.3)$$

Keterangan:

$\hat{X}_B$: Matriks gabungan data baru dan informasi pergeseran rata-rata

T : Operasi transpose matriks

Langkah 5: Proyeksi dan Residu Ortogonal

Tahapan ini memisahkan informasi data baru menjadi proyeksi (mirip data lama) dan residu (informasi baru). Proyeksi data baru ke basis lama (U_A) dihitung dengan:

$$\tilde{X}_{proj} = U_A^T \hat{X}_B \quad (2.4)$$

Residu ortogonal ($\tilde{X}_{res}$) dihitung dengan mengurangi data gabungan dengan hasil proyeksinya:

$$\tilde{X}_{res} = \hat{X}_B - (U_A \tilde{X}_{proj}) \quad (2.5)$$

Keterangan:

$\tilde{X}_{proj}$: Komponen data baru yang sejajar dengan ruang fitur lama

$\tilde{X}_{res}$: Komponen data baru yang ortogonal (tegak lurus) terhadap ruang fitur lama

U_A : Matriks basis eigen dari tahap sebelumnya

Langkah 6: Dekomposisi Residu (*QR Decomposition*)

Dekomposisi QR dilakukan pada $\tilde{X}_{res}$ untuk mengekstraksi basis ortonormal baru:

$$\tilde{X}_{res} = \tilde{U}_B \tilde{\Sigma}_B \quad (2.6)$$

Keterangan:

$\tilde{U}_B$: Basis ortogonal baru dari residu data tambahan

$\tilde{\Sigma}_B$: Nilai singular yang terkait dengan residu tersebut

Langkah 7: Pembentukan Matriks R

Matriks R disusun untuk merepresentasikan struktur variansi gabungan:

$$R = \begin{bmatrix} \tilde{\Sigma}_A & \tilde{X}^{proj} \\ 0 & \tilde{\Sigma}_B \end{bmatrix} \quad (2.7)$$

Keterangan:

R : Matriks perantara struktur variansi gabungan

$\tilde{\Sigma}_A$: Matriks diagonal nilai singular data lama

0 : Blok matriks nol (menunjukkan ortogonalitas)

Langkah 8: SVD pada Matriks R

SVD dilakukan pada matriks R yang berukuran kecil untuk mendapatkan rotasi optimal baru:

$$R = \tilde{U} \tilde{\Sigma}_{baru} \tilde{V}^T \quad (2.8)$$

Keterangan:

Σ_{baru} : Matriks nilai singular akhir yang telah diperbarui

$\tilde{U}$: Matriks rotasi penghubung basis sementara dengan basis utama baru

Langkah 9: Pembaruan Basis Vektor Eigen (U)

Matriks komponen utama final (U_{baru}) dihitung dengan memproyeksikan rotasi $\tilde{U}$ kembali ke ruang fitur asli:

$$U_{baru} = U_A \tilde{U}_B \tilde{U} \quad (2.9)$$

Keterangan:

U_{baru} : Matriks vektor eigen yang telah diperbarui untuk seluruh data ($N_A + N_B$)

$[U_A \tilde{U}_B]$: Penggabungan basis lama dan basis residu baru

2.8 Cumulative Explained Variance (CEV)

Proses reduksi dimensi menggunakan *Incremental Principal Component Analysis* (IPCA) bertujuan menyederhanakan data dengan mentransformasi variabel asli menjadi kumpulan variabel baru yang tidak berkorelasi, yang disebut komponen utama (*principal components*). Pemilihan jumlah komponen utama yang tepat sangat penting untuk memastikan keseimbangan antara efisiensi komputasi dan menjaga informasi penting. Parameter utama yang digunakan dalam penentuan jumlah komponen tersebut adalah *Cumulative Explained Variance* (CEV).

Cumulative Explained Variance (CEV) didefinisikan sebagai jumlah kumulatif dari rasio variansi yang dijelaskan oleh k komponen utama pertama. Nilai ini mengindikasikan seberapa banyak informasi dari data asli yang masih dipertahankan setelah dimensi direduksi menjadi k komponen. Perhitungan nilai CEV dilakukan menggunakan persamaan matematis berikut:

$$CEV_k = \frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^d \lambda_j} \quad (2.10)$$

Keterangan:

CEV_k : Proporsi kumulatif variansi untuk k komponen utama

λ_i : Nilai eigen (*eigenvalue*) dari komponen ke- i

k : Jumlah komponen utama yang dipilih

d : Total dimensi awal data (jumlah fitur k -mer)

2.9 Klasifikasi *Naïve Bayes*

Klasifikasi *Naïve Bayes* merupakan metode pembelajaran mesin probabilistik yang berlandaskan pada Teorema Bayes dengan asumsi penyederhanaan bahwa setiap fitur bersifat independen satu sama lain terhadap kelas targetnya [32]. Algoritma ini tetap menunjukkan efisiensi komputasi yang tinggi meskipun diterapkan pada data berdimensi besar, di mana asumsi independensi tersebut mungkin tidak sepenuhnya terpenuhi [32]. Karakteristik data masukan pada penelitian ini, yaitu hasil reduksi dimensi IPCA yang berupa nilai numerik kontinu, memerlukan penggunaan varian distribusi probabilitas tertentu, yakni *Gaussian Naïve Bayes*.

2.9.1 Teorema Bayes

Landasan utama algoritma ini adalah perhitungan probabilitas posterior untuk menentukan peluang suatu data sampel X masuk ke dalam kelas tertentu. Persamaan Teorema Bayes yang digunakan untuk proses klasifikasi dirumuskan sebagai berikut:

$$P(C_k | X) = \frac{P(X | C_k) \cdot P(C_k)}{P(X)} \quad (2.11)$$

Keterangan:

- $P(C_k|X)$: Probabilitas posterior kelas C_k diberikan fitur X
 $P(X|C_k)$: Probabilitas *likelihood* fitur X muncul pada kelas C_k
 $P(C_k)$: Probabilitas prior kelas C_k
 $P(X)$: Probabilitas total fitur X (*evidence*)

2.9.2 Gaussian Naïve Bayes untuk Fitur Kontinu

Fitur yang dihasilkan dari proses IPCA berupa nilai numerik kontinu (bilangan riil), bukan data diskrit. Penanganan data jenis ini dilakukan dengan asumsi bahwa nilai fitur pada setiap kelas mengikuti distribusi normal atau *Gaussian* [33]. Perhitungan nilai *likelihood* $P(x_i|C_k)$ menggunakan fungsi kepadatan probabilitas (*Probability Density Function*) sebagai berikut:

$$P(x_i|C_k) = \frac{1}{\sqrt{2\pi}\sigma_k} \exp\left[-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right] \quad (2.12)$$

Keterangan:

- x_i : Nilai fitur ke- i dari hasil IPCA
 μ_k : Rata-rata (*mean*) fitur pada kelas C_k
 σ_k^2 : Variansi fitur pada kelas C_k

Model secara otomatis mempelajari parameter rata-rata (μ_k) dan variansi (σ_k^2) dari data latih untuk setiap kategori *phylum*.

2.9.3 Aturan Keputusan

Penentuan kelas akhir dilakukan dengan memilih kelas yang memiliki probabilitas posterior tertinggi. Prinsip keputusan ini dikenal sebagai *Maximum A Posteriori* (MAP) [32]. Penentuan label kelas untuk data baru dilakukan berdasarkan persamaan berikut:

$$\hat{y} = \underset{k \in \{1, \dots, K\}}{\operatorname{argmax}} \prod_{i=1}^n P(C_k) P(x_i | C_k) \quad (2.13)$$

Persamaan di atas menyatakan bahwa kelas terpilih ($\hat{y}$) adalah kelas yang memaksimalkan hasil kali antara probabilitas prior dan *likelihood* dari seluruh fitur yang diamati.

2.10 Evaluasi Kinerja

Model klasifikasi yang dibangun memerlukan penggunaan metrik evaluasi untuk mengukur dan menilai kinerja. Evaluasi dalam penelitian ini dilakukan melalui dua pendekatan. Pendekatan pertama menggunakan metrik berbasis *Confusion Matrix* (Tabel Kontingensi) yang dihitung dari komponen *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Pendekatan kedua melibatkan metrik berbasis probabilitas untuk mengukur kualitas pemisahan kelas dan tingkat keyakinan model.

Komponen dasar pada *Confusion Matrix* tersebut dapat diilustrasikan melalui studi kasus prediksi taksonomi pada *phylum* target tertentu, misalnya *Proteobacteria*, dengan penjabaran sebagai berikut:

1. *True Positive* (TP): Kondisi keberhasilan model saat memprediksi suatu sampel bakteri masuk ke dalam kelas target *Proteobacteria*, dan label asli dari sampel tersebut terbukti sebagai *Proteobacteria*.
2. *True Negative* (TN): Kondisi ketepatan model saat mengklasifikasikan suatu sampel bakteri sebagai kelompok di luar target *Proteobacteria*, dan label asli sampel tersebut memang bukan anggota *Proteobacteria*.
3. *False Positive* (FP): Kesalahan identifikasi oleh model yang memprediksi suatu sampel bakteri sebagai target *Proteobacteria*, padahal label asli sampel tersebut merujuk pada taksa *phylum* lain.
4. *False Negative* (FN): Kegagalan model saat memprediksi suatu sampel bakteri bukan bagian dari target *Proteobacteria*, padahal label asli dari sampel tersebut sebenarnya merupakan anggota dari kelas *Proteobacteria*.

Rincian seluruh metrik turunan dari tabel kontingensi dan probabilitas

tersebut adalah sebagai berikut:

1. Akurasi (*Accuracy*)

Akurasi menunjukkan seberapa banyak prediksi model yang benar dibandingkan dengan seluruh data uji, baik untuk kelas positif maupun negatif [34]. Penggunaan akurasi sebagai indikator evaluasi sangat relevan untuk menilai keberhasilan proses klasifikasi taksonomi pada tingkat *phylum*.

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.14)$$

2. Presisi (*Precision*)

Presisi menunjukkan ketepatan model saat menentukan bahwa sebuah data termasuk ke dalam kelas positif [34]. Tingginya nilai presisi menandakan bahwa model membuat sedikit kesalahan ketika memberikan prediksi positif (*minimizing False Positives*).

$$Presisi = \frac{TP}{TP + FP} \quad (2.15)$$

3. Recall (Sensitivitas)

Recall mengukur kemampuan model untuk menemukan seluruh data yang sebenarnya termasuk dalam kelas positif [34]. Nilai *recall* yang tinggi menunjukkan bahwa model mampu meminimalkan jumlah data positif yang terlewat.

$$Recall = \frac{TP}{TP + FN} \quad (2.16)$$

4. *Weighted F1-Score*

F1-Score merupakan rata-rata harmonik dari presisi dan *recall* yang berfungsi sebagai indikator keseimbangan performa model secara keseluruhan [34]. Data metagenomik sering kali berdistribusi jumlah sampel antar kelas taksonomi yang tidak seimbang, penggunaan variasi *Weighted F1-Score* sangat diperlukan [35]. Metrik ini beroperasi dengan menghitung nilai F1 untuk setiap

takson atau kelas secara independen, kemudian mengakumulasi menjadi nilai rata-rata dengan memberikan bobot yang proporsional sesuai dengan frekuensi kemunculan (jumlah sampel asli) dari masing-masing kelas tersebut [35].

$$Weighted F1-Score = \frac{\sum_{i=1}^K w_i \times 2 \frac{Presisi_i \times Recall_i}{Presisi_i + Recall_i}}{\sum_{i=1}^K w_i} \quad (2.17)$$

5. Kurva ROC dan AUC (*Area Under the Curve*)

Kurva ROC (*Receiver Operating Characteristic*) merupakan grafik dua dimensi yang memplot *True Positive Rate* (TPR) pada sumbu Y dan *False Positive Rate* (FPR) pada sumbu X untuk mengilustrasikan *trade-off* kinerja klasifikasi [36]. AUC (*Area Under the Curve*) merepresentasikan bagian luas area di bawah kurva ROC tersebut. Nilai AUC selalu berada dalam rentang 0 hingga 1,0, di mana nilai yang lebih tinggi mengindikasikan kinerja rata-rata klasifikasi yang lebih baik [36].

$$FPR = \frac{FP}{FP + TN} \quad (2.18)$$

6. *Confidence Score*

Confidence Score didefinisikan sebagai estimasi probabilitas untuk kelas yang diprediksi, yaitu label kelas yang memiliki estimasi probabilitas tertinggi [37]. Evaluasi ini penting untuk mendeteksi kondisi di mana model memiliki rata-rata keyakinan yang jauh melebihi tingkat akurasi, yang mengindikasikan bahwa model tersebut mengalami *overconfidence* [37].

$$ConfidenceScore = \max_k P(C_k | X) \quad (2.19)$$

BAB III

METODE PENELITIAN

3.1 Deskripsi Data

Penelitian ini menggunakan data sekunder berupa sekuens DNA gen 16S rRNA yang bersumber dari basis data SILVA (wilayah V3–V4). Dataset mentah terdiri atas dua file, yaitu sekuens DNA (.fasta) dan taksonomi (.tsv).

1. Data Sekuens (FASTA)

File FASTA memuat data sekuens nukleotida. Hasil pembacaan data menunjukkan terdapat total 398.508 baris data sekuens. Setiap entri terdiri dari *Feature ID* dan *Sequence*. Tabel 3.1 menampilkan sampel data dari file FASTA (4 data pertama dan 1 data terakhir).

Tabel 3.1 Sampel Data Sekuens (FASTA)

Feature ID	Sequence
CP013078.2406498.2408039	TGGGGAATTTTGGACAATGGGGGC...
CP015924.1224168.1225721	TGGGGAATATTGCACAATGGGCGC...
CP003278.287486.289015	TGGGGAATATTGCACAATGGGCGC...
LS483321.16842.18378	TAGGGAATCTTCGGCAATGGGGGC...
...	...
Z76660.1.1493	TGGGGAATATTGGACAATGGGCGA...

2. Data Taksonomi (TSV)

File TSV memuat informasi klasifikasi biologi. File ini memiliki total 436.680 baris data, yang lebih banyak dibandingkan data sekuens. Hal ini menunjukkan adanya ID taksonomi yang tidak memiliki pasangan sekuens dalam file FASTA. Tabel 3.2 menampilkan sampel data taksonomi.

Tabel 3.2 Sampel Data Taksonomi (TSV)


Feature ID	Taxon
CP013078.2406498.2408039	d__Bacteria; p__Proteobacteria; c__Gammaproteobacteria...
CP015924.1224168.1225721	d__Bacteria; p__Proteobacteria; c__Gammaproteobacteria...
CP003278.287486.289015	d__Bacteria; p__Proteobacteria; c__Gammaproteobacteria...
LS483321.16842.18378	d__Bacteria; p__Firmicutes; c__Bacilli; o__Lactobacillales...
...	...
Z76660.1.1493	d__Bacteria; p__Proteobacteria; c__Gammaproteobacteria...

3.2 Pra-pemrosesan Data

Tahapan pra-pemrosesan bertujuan meningkatkan kualitas data melalui langkah-langkah sistematis, mulai dari penggabungan data, pembersihan karakter *noise*, hingga penanganan distribusi kelas yang tidak seimbang.

3.2.1 Integrasi dan Distribusi Data

Tahap selanjutnya melibatkan penggabungan antara data FASTA dan TSV menggunakan atribut kunci *Feature ID*. Penerapan metode *intersection* (irisan) dipilih dalam proses ini karena jumlah data FASTA (398.508) lebih sedikit dibandingkan data TSV (436.680). Langkah ini memastikan hanya data dengan informasi lengkap, yaitu yang memiliki pasangan Sekuens dan Taksonomi, yang dipertahankan dalam dataset. Proses ekstraksi label taksonomi pada tingkat *Phylum* dilakukan dari kolom *Taxon* untuk dijadikan label kelas target. Dataset final yang dihasilkan dan siap digunakan dalam penelitian ini berjumlah 398.508 baris data dengan total 198 kelas unik.



Gambar 3.1 Distribusi 20 Kelas *Phylum* Terbanyak

Visualisasi pada Gambar 3.1 memperlihatkan pola distribusi data dengan karakteristik *imbalanced dataset*. Distribusi tertinggi terlihat pada kelas Proteobacteria dan Firmicutes dengan persentase masing-masing mencapai 26,7% dan 25,2%. Akumulasi kedua kelas mayoritas ini merepresentasikan lebih dari setengah total populasi data. Penurunan jumlah sampel secara drastis tampak pada kelas-kelas lainnya, di mana kelas minoritas dalam daftar 20 besar hanya memiliki proporsi di bawah 1%. Ketimpangan jumlah antar kelas ini menjadi karakteristik utama dari dataset SILVA yang digunakan.

3.2.2 Pembersihan Sekuens

Langkah ini untuk menstandarisasi sekuens DNA dengan menghapus karakter *IUPAC ambiguity codes* (selain A, T, G, C) yang merepresentasikan ketidakpastian hasil pembacaan mesin sekuensing.

Hasil pemindaian awal terhadap 398.508 sekuens menunjukkan bahwa terdapat 12.438 sekuens atau sekitar 3,12% dari total data yang mengandung karakter *noise*. Jumlah keseluruhan karakter non-standar yang terdeteksi mencapai 17.824 karakter. Seluruh karakter *noise* tersebut dihapus dari string sekuens agar tidak menghasilkan fitur *k-mer* yang tidak valid pada tahap ekstraksi fitur. Ilustrasi mekanisme pembersihan ditunjukkan pada Tabel 3.3.

Tabel 3.3 Ilustrasi Pembersihan pada Sekuens *noise*

Status	Contoh Sekuens	Tindakan
Data Mentah	ATGNCGYT...	Terdeteksi mengandung 'N' dan 'Y'
Proses	<i>Filtering</i>	Menghapus 17.824 karakter <i>noise</i>
Data Bersih	ATGCGT...	Sekuens murni (A, T, G, C)

3.2.3 Pengelompokan Ulang

Distribusi data memperlihatkan keberadaan total 198 kelas *Phylum* unik. Mayoritas sampel terpusat pada beberapa kelas dominan, sedangkan sebanyak 29 kelas *Phylum* teridentifikasi memiliki jumlah sampel yang sangat sedikit, yaitu di bawah atau sama dengan ambang batas 3 sampel (≤ 3).

Keberadaan 29 kelas minoritas ini menghambat penerapan metode pembagian data berbasis stratifikasi (*stratified split*). Strategi pengelompokan ulang (*re-grouping*) diterapkan sebagai solusi dengan menggabungkan seluruh kelas minoritas tersebut ke dalam satu kategori baru berlabel “Others”. Proses ini menghasilkan jumlah sebanyak 59 sampel pada kelas “Others”. Ilustrasi proses pengelompokan disajikan pada Tabel 3.4.

Tabel 3.4 Penerapan *Regrouping* pada Kelas Minoritas

Label Phylum Asli	Jumlah Sekuens	Label Baru (Final)
p__Proteobacteria	106,470	p__Proteobacteria
p__Firmicutes	100,595	p__Firmicutes
p__Bacteroidota	43,912	p__Bacteroidota
...	...	...
29 Kelas Minoritas Lainnya	≤ 3	Others (Total: 59 Sampel)

3.3 Ekstraksi Fitur Berbasis *k-mer*

Data sekuens yang telah melalui tahap pembersihan dikonversi menjadi representasi numerik menggunakan metode *k-mer*. Penelitian ini menetapkan panjang $k = 6$ sebagai parameter utama dalam proses ekstraksi. Proses ekstraksi dilakukan menggunakan metode *sliding window* dengan pergeseran satu basa. Setiap sekuens dipetakan menjadi vektor berdimensi $4^6 = 4096$ fitur. Nilai dalam vektor tersebut merepresentasikan frekuensi kemunculan setiap kombinasi 6-basa. Tabel 3.5 menyajikan ilustrasi transformasi dari teks DNA menjadi vektor fitur.

Tabel 3.5 Ilustrasi Transformasi Sekuens ke Vektor Fitur ($k = 6$)

ID Sekuens	Fitur Frekuensi (Total 4096 Fitur)			
	AAAAAA	AAAAAT	...	TTTTTT
CP013078...	5	2	...	4
CP015924...	0	1	...	2
LS483321...	12	4	...	1

3.4 Skenario Pengujian

Skenario pengujian dirancang untuk membandingkan kinerja klasifikasi pada berbagai tingkat reduksi dimensi. Proses dimulai dengan pembagian data menggunakan metode *Stratified Split* dengan rasio 80:20. Sebanyak 80% data digunakan sebagai data latih untuk melatih model, sedangkan 20% sisanya digunakan sebagai data uji.

3.5 Reduksi Dimensi dengan IPCA

Reduksi dimensi dilakukan pada fitur *k-mer* ($4^6 = 4096$ fitur) menggunakan metode *Incremental Principal Component Analysis* (IPCA). Penelitian ini menerapkan skema eksperimen berulang untuk menganalisis pengaruh jumlah informasi yang dipertahankan terhadap kinerja klasifikasi. Penerapan reduksi dimensi dilakukan secara iteratif dengan memvariasikan nilai target *Cumulative Explained Variance* (CEV) sebesar 0,50, 0,60, 0,70, 0,80, 0,90, dan 0,95. Pelaksanaan tahapan ini dipisahkan antara data latih dan data uji untuk mencegah kebocoran data (*data leakage*), dengan rincian sebagai berikut:

1. Penentuan Komponen Utama

IPCA memproses Data Latih untuk mempelajari struktur variansi dan menentukan arah komponen utama (*eigenvectors*).

2. Transformasi Dimensi Fitur

Vektor fitur asli diproyeksikan ke dalam ruang dimensi berdasarkan komponen utama yang telah ditentukan sebelumnya.

3.6 Klasifikasi dan Evaluasi

Klasifikasi dilakukan menggunakan algoritma *Gaussian Naïve Bayes* (GNB) pada data yang telah direduksi dimensinya. Proses ini melibatkan dua tahap:

1. Pelatihan Model

Model GNB dilatih menggunakan Data Latih hasil transformasi IPCA.

2. Pengujian Model


Model yang telah dilatih kemudian digunakan untuk memprediksi kelas taksonomi pada Data Uji hasil transformasi.

Evaluasi kinerja model pada setiap variasi CEV dilakukan menggunakan metrik utama yang mencakup *Weighted F1-Score*, *Precision*, *Recall*, dan *Accuracy*. Analisis terhadap performa model diperdalam dengan melibatkan Kurva ROC, nilai AUC (*Area Under*

the Curve), serta *Confidence Score* untuk memvalidasi kemampuan diskriminasi dan tingkat keyakinan prediksi. Hasil pengukuran dari seluruh metrik tersebut kemudian dianalisis untuk menentukan nilai CEV yang paling optimal.

3.7 Diagram Alir Penelitian

Rangkaian tahapan penelitian secara keseluruhan, mulai dari pra-pemrosesan hingga penentuan nilai CEV optimal, digambarkan secara rinci pada Gambar 3.2.



Gambar 3.2 Diagram Alir Penelitian

BAB IV


HASIL DAN PEMBAHASAN

4.1 Karakteristik Data dan Pra-pemrosesan


Penelitian ini menggunakan dataset sekuens 16S rRNA wilayah V3-V4 dari basis data SILVA. Data mentah biologi molekuler sering mengandung *noise* yang memerlukan penanganan sebelum ekstraksi fitur. Tahapan pra-pemrosesan dilakukan meliputi pembersihan karakter ambigu dan penanganan ketidakseimbangan kelas. Bagian ini menguraikan karakteristik data sebelum dan sesudah pra-pemrosesan serta dampaknya terhadap kualitas data.

4.1.1 Kualitas Sekuens DNA

Tahap awal pra-pemrosesan berfokus pada audit kualitas sekuens DNA untuk mengeliminasi karakter ambigu. Audit ini bertujuan mendeteksi keberadaan kode ambiguitas IUPAC (seperti 'N', 'R', 'Y', 'K', 'M') yang merepresentasikan ketidakpastian pembacaan nukleotida oleh mesin sekuensing. Keberadaan karakter ini dianggap sebagai *noise* yang dapat mengganggu pembentukan fitur *k-mer*. Mekanisme pembersihan dilakukan melalui *filtering* untuk menghapus karakter ambigu dan hanya menyisakan basa standar (A, T, G, C). Perbandingan kondisi data sebelum dan sesudah proses pembersihan disajikan dalam Gambar 4.1.



(a) Distribusi Nukleotida pada Data Mentah




(b) Distribusi Nukleotida pada Data Bersih

Gambar 4.1 Komposisi Nukleotida Sebelum (a) dan Sesudah (b) Eliminasi Basa Ambigu

Gambar 4.1(a) memperlihatkan distribusi karakter *noise* pada data mentah yang ditandai dengan batang berwarna merah. Proporsi *noise* ini, meskipun relatif kecil dibandingkan total jutaan basa A, T, G, dan C, terdeteksi jelas karena penggunaan skala logaritmik. Karakter ‘N’ teridentifikasi sebagai karakter ambigu dominan yang muncul akibat kegagalan pembacaan basa spesifik pada mesin sekuensing. Gambar 4.1(b) menunjukkan hasil setelah proses pembersihan, di mana seluruh karakter ambigu berhasil dibersihkan hingga nol (0%) dan hanya menyisakan 100% karakter standar. Integritas data utama tetap terjaga karena frekuensi A, T, G, dan C tidak mengalami penurunan antara kondisi sebelum dan sesudah pembersihan.

Keberadaan karakter ambiguitas pada data mentah berisiko menurunkan akurasi model. Penghapusan karakter ini penting karena kode ambigu dapat membentuk fitur *k-mer* buatan yang tidak valid secara biologis. Identifikasi dan eliminasi karakter ambigu merupakan langkah metodologis standar untuk mencegah bias pada analisis lanjutan [19]. Fitur berdimensi tinggi seringkali memuat *noise* yang dapat mengganggu kinerja klasifikasi dan klusterisasi [38]. Analisis selanjutnya dilakukan terhadap distribusi panjang sekuens bersih untuk memastikan keseragaman data. Visualisasi distribusi panjang sekuens ditampilkan pada Gambar 4.2.



Gambar 4.2 Histogram Distribusi Panjang Sekuens DNA Setelah Pembersihan

Histogram pada Gambar 4.2 memperlihatkan distribusi panjang sekuens bersih yang terpusat pada rentang tertentu. Mayoritas sekuens terpusat pada rentang panjang 400 hingga 430 bp dengan puncak kepadatan di sekitar garis rata-rata 416 bp. Konsistensi panjang sekuens di angka rata-rata ≈ 416 bp juga menjaga validitas data wilayah V3-V4. Penggunaan fragmen sekuens dengan panjang memadai terbukti memberikan akurasi klasifikasi yang lebih baik dibandingkan fragmen pendek karena stabilitas frekuensi *k-mer* [10].

4.1.2 Pengelompokan Kelas


Distribusi taksonomi pada data metagenomik secara alami menunjukkan sebaran sampel yang sangat bervariasi. Sebagian besar sampel terpusat pada beberapa *phylum* utama, sementara sebagian lainnya tersebar pada banyak *phylum* dengan frekuensi kemunculan yang sangat rendah. Keberadaan kelas dengan jumlah sampel yang terlampaui sedikit berisiko menyulitkan model dalam mengenali pola

spesifik pada kelompok tersebut. Strategi pengelompokan ulang (*regrouping*) diterapkan pada taksa-taksa bersampel rendah. Langkah ini bertujuan untuk menstabilkan ruang kelas dan memastikan terpenuhinya batas minimal sampel pada setiap kelas, sehingga pembagian data latih dan uji dapat dilakukan secara proporsional menggunakan metode *stratified*.

Tabel 4.1 Rincian Hasil Pengelompokan Ulang (*Regrouping*) Kelas Minoritas

Parameter Penanganan	Statistik Hasil
Kriteria Ambang Batas (<i>Threshold</i>)	Sampel ≤ 3
Jumlah Kelas Minoritas Terdampak	29 Phylum
Contoh Kelas Digabung	<i>Animalia</i> , <i>Alveolata</i> , <i>Picozoa</i>
Total Sampel dalam Kelas Baru (<i>Others</i>)	59 Sampel
Perubahan Total Kelas (Label)	198 $\rightarrow$ 170

Tabel 4.1 merangkum hasil penerapan penanganan distribusi data. Sebanyak 29 *phylum* teridentifikasi memiliki jumlah sampel yang sangat terbatas (kurang dari atau sama dengan 3), seperti *Animalia* (1 sampel) dan *Alveolata* (1 sampel). Seluruh kelas bersampel rendah ini kemudian digabungkan menjadi satu kategori baru bernama “*Others*”, yang secara akumulatif mencakup 59 sampel. Proses pengelompokan ini menyederhanakan dimensi target klasifikasi dari 198 menjadi 170 kelas tanpa perlu membuang data sampel yang bernilai informatif. Visualisasi struktur data final setelah pengelompokan disajikan pada Gambar 4.3.



Gambar 4.3 Distribusi Sampel pada Kelas *Phylum* Setelah *Regrouping*

Gambar 4.3 memperlihatkan posisi kelas *Others*” sebagai entitas gabungan yang mewakili taksa-taksa langka. Pembentukan kelas ini mencegah hilangnya informasi biologis dari sampel berfrekuensi rendah, sekaligus menghindarkan kelas-kelas tersebut menjadi entitas yang terlalu lemah untuk dipelajari secara individual oleh algoritma. Keberadaan kelas dengan sampel yang sedikit dapat membatasi kemampuan model dalam menggeneralisasi data. Algoritma cenderung berfokus pada meminimalkan kesalahan global, sehingga dapat menganggap kelas bersampel sangat rendah sebagai *noise* atau anomali [39]. Strategi pengelompokan taksa langka menjadi kategori *Others*” merupakan pendekatan standar untuk mengelola data berfrekuensi sangat jarang.

4.2 Ekstraksi Fitur dan Transformasi Data

Transformasi data sekuens menjadi representasi numerik merupakan tahapan penting sebelum dilakukan pemodelan statistik. Proses ini bertujuan untuk mengubah informasi biologis berupa urutan basa nitrogen menjadi struktur data yang dapat diolah oleh komputer.

4.2.1 Representasi Sekuens DNA Asli

Data dalam penelitian ini berupa fragmen sekuens 16S rRNA hasil pembersihan. Karakteristik data asli ini bersifat non-numerik (teks) yang terdiri dari kombinasi empat huruf basis nitrogen, yaitu Adenin (A), Sitosin (C), Guanin (G), dan Timin (T). Gambar 4.4 menampilkan contoh data sekuens asli sebelum dilakukan proses ekstraksi fitur.

	Feature ID	Sequence	Phylum
0	CP013078.2406498.2408039	TGGGGAATTTGGACAATGGGGGCAACCTGATCCAGCCATCCCGC...	Proteobacteria
1	CP015924.1224168.1225721	TGGGGAATATTGCACAATGGGCGCAAGCCTGATGCAGCCATGCCGC...	Proteobacteria
2	CP003278.287486.289015	TGGGGAATATTGCACAATGGGCGCAAGCCTGATGCAGCCATGCCGC...	Proteobacteria
3	LS483321.16842.18378	TAGGGAATCTTCGGCAATGGGGCAACCTGACCGAGCAACGCCGC...	Firmicutes
4	CP012870.431955.433510	TGGGGAATATTGCACAATGGGCGCAAGCCTGATGCAGCCATGCCGC...	Proteobacteria

Gambar 4.4 DNA fragmen 16S rRNA sebelum Ekstraksi

Sekuens fragmen tersebut memiliki panjang rata-rata kurang lebih 416 *base pairs* (bp). Informasi biologis pada tingkat ini masih berupa data kualitatif yang belum memiliki bobot matematis untuk diklasifikasikan secara langsung oleh model *Naive Bayes*.

4.2.2 Mekanisme *Sliding Window* dan Pembentukan Fitur

Metode *k-mer* mengekstraksi fitur melalui teknik (*sliding window*) pada sepanjang sekuens DNA. *Window* pengamatan dengan lebar $k = 6$ bergerak basis demi basis dari ujung awal hingga ujung akhir sekuens. *Window* pengamatan tersebut menangkap enam karakter secara berurutan pada setiap pergeseran satu langkah. Total jumlah *k-mer* yang dapat terbentuk dari sekuens dengan panjang L didefinisikan melalui persamaan berikut:

$$\text{Total } k\text{-mer} = L - k + 1 \quad (4.1)$$

Penggunaan panjang $k = 6$ menghasilkan ruang fitur sebanyak $4^6 = 4.096$ dimensi kolom unik. Setiap kombinasi huruf (misalnya: AAAAAA, AAAAAC, hingga TTTTTT) digunakan sebagai identitas

fitur unik dalam ruang vektor.

4.2.3 Matriks Frekuensi *k-mer*

Tahapan akhir ekstraksi menghasilkan matriks frekuensi yang merepresentasikan jumlah kemunculan setiap motif *k-mer* unik di dalam satu sampel bakteri. Gambar 4.5 menampilkan matriks hasil transformasi dari sekuens teks menjadi nilai numerik diskrit.


	aaaaaa	aaaaac	aaaaag	...	tttttc	tttttg	ttttt
Sampel_1	0	0	0	...	0	0	0
Sampel_2	0	0	0	...	0	0	0
Sampel_3	0	0	0	...	0	0	0
Sampel_4	0	0	0	...	0	0	0
Sampel_5	0	0	1	...	0	0	0

Gambar 4.5 Matriks Fitur *k-mer* Hasil Ekstraksi

Matriks tersebut merupakan wujud data sesudah ekstraksi di mana setiap baris mewakili satu sampel bakteri dan setiap kolom mewakili satu jenis motif *k-mer*. Angka di dalam sel matriks menunjukkan seberapa sering motif kolom tersebut muncul pada sampel tersebut. Proses transformasi ini berhasil mengonversi 398.508 sekuens teks menjadi matriks raksasa berukuran 398.508×4.096 .

4.2.4 Karakteristik Dimensi dan *Sparsity* Matriks

Hasil ekstraksi fitur *k-mer* membentuk representasi data berdimensi tinggi dengan tingkat kelangkaan (*sparsity*) yang signifikan. Untuk memahami karakteristik ruang fitur yang terbentuk, distribusi kepadatan fitur per sampel divisualisasikan dalam Gambar 4.6.




Gambar 4.6 Histogram Distribusi Fitur per Sampel *Non-Zero k-mers*

Histogram pada Gambar 4.6 memperlihatkan pola distribusi normal di mana rata-rata setiap sampel bakteri hanya mengandung 383 jenis *k-mer* unik. Data terpusat pada rentang 350 hingga 400 fitur per sampel, sementara sisi kanan grafik (fitur > 450) terlihat kosong. Kondisi *sparsity* yang tinggi ini terjadi akibat keterbatasan panjang sekuens DNA dalam dataset (≈ 416 bp). Panjang sekuens yang pendek membatasi jumlah kombinasi *k-mer* yang mungkin muncul, sehingga sebagian besar dari 4.096 fitur yang tersedia tetap kosong [38]. Kondisi ini berkaitan dengan “*curse of dimensionality*”, yaitu ketika jumlah fitur jauh lebih besar dibandingkan jumlah sampel yang tersedia. Ruang fitur yang sangat luas menyebabkan data menjadi jarang tersebar, sehingga perbedaan antar sampel menjadi kurang jelas. Kondisi tersebut dapat membuat model klasifikasi kesulitan dalam mempelajari pola secara stabil serta meningkatkan risiko *overfitting* [38].

4.2.5 Analisis Pola Motif Dominan

Analisis selanjutnya berfokus pada identifikasi fitur-fitur yang memiliki frekuensi kemunculan tertinggi di seluruh dataset. Pemetaan terhadap motif dominan bertujuan untuk menemukan pola sekuens yang menjadi ciri khas biologis pada data 16S rRNA. Lima belas motif *k-mer* dengan total frekuensi tertinggi disajikan pada Gambar 4.7.



Gambar 4.7 Lima Belas Motif *k-mer* Paling Dominan Berdasarkan Total Frekuensi Kemunculan

Gambar 4.7 menunjukkan bahwa motif “gccgcg” merupakan fitur yang paling sering muncul dengan frekuensi melebihi 700.000 kali, diikuti oleh motif “gtgaaa” dan “gaaagc”. Urutan motif-motif ini merepresentasikan nukleotida yang sangat sering ditemukan dalam populasi bakteri yang diteliti. Tingginya frekuensi kemunculan motif-motif tertentu mengindikasikan keberadaan daerah konservatif pada gen 16S rRNA wilayah V3-V4. Fitur-fitur dengan frekuensi tinggi ini memiliki peran penting dalam proses klasifikasi karena menyediakan informasi pembeda yang kuat antar kelompok taksonomi. Fragmen sekuens pendek dengan frekuensi kemunculan

yang stabil terbukti mampu memberikan akurasi klasifikasi yang optimal pada pendekatan *alignment-free* [10]. Fitur-fitur yang jarang muncul cenderung kurang informatif sehingga dapat diabaikan untuk mengurangi kompleksitas model sekaligus menjadi strategi reduksi dimensi yang efektif dalam penanganan data tidak seimbang [18].

4.3 Analisis Pembagian Data Latih dan Data Uji

Pembagian data merupakan tahapan penting untuk model klasifikasi memiliki kemampuan generalisasi yang baik pada data baru. Strategi pembagian diterapkan dengan proporsi 80% untuk data latih dan 20% untuk data uji. Mekanisme pembagian menggunakan teknik *stratified split* agar persentase jumlah sampel pada setiap *phylum* tetap seimbang antara kelompok latih dan uji. Penetapan jumlah minimal 4 sampel pada setiap kelas target dilakukan untuk memastikan ketersediaan perwakilan data pada kedua himpunan. Kalkulasi algoritma pembagian untuk ambang batas minimal ini dijabarkan sebagai berikut:

$$N_{\text{train}} = 4 \times 0,80 = 3,2 \text{ sampel} \quad (4.2)$$

$$N_{\text{test}} = 4 \times 0,20 = 0,8 \text{ sampel} \quad (4.3)$$

Perhitungan matematis menunjukkan bahwa proporsi awal menghasilkan nilai desimal sebesar 3,2 untuk data latih dan 0,8 untuk data uji. Nilai tersebut kemudian dibulatkan ke bilangan bulat terdekat, sehingga 3,2 dibulatkan menjadi 3 dan 0,8 dibulatkan menjadi 1. Hasil pembulatan ini membuat model memiliki 3 sampel untuk proses pelatihan dan 1 sampel untuk proses pengujian. Kondisi tersebut terlihat pada data penelitian pada Gambar 4.8, di mana kelas *Firestonebacteria*, *Fervidibacteria*, dan *Opalinata* terbagi menjadi 3 sampel data latih dan 1 sampel data uji.

	Phylum	Train (Jml)	Test (Jml)	Train (%)	Test (%)	Selisih (%)
0	Proteobacteria	85,176	21,294	26.7171885096	26.7170209029	0.0001676068
1	Firmicutes	80,476	20,119	25.2429377113	25.2427793531	0.0001583582
2	Bacteroidota	35,130	8,782	11.0192405413	11.0185440767	0.0006964646
3	...	...	...	...	...	...
4	Firestonebacteria	3	1	0.0009410111	0.0012546737	0.0003136625
5	Fervidibacteria	3	1	0.0009410111	0.0012546737	0.0003136625
6	Opalinata	3	1	0.0009410111	0.0012546737	0.0003136625

Gambar 4.8 Distribusi Sampel pada Kelas Mayoritas dan Minoritas


Visualisasi pada Gambar 4.8 menunjukkan selisih persentase (*gap*) yang sangat kecil antara data latih dan uji. Rasio tersebut membuktikan bahwa proses pembagian data telah dilakukan secara presisi. Keselarasan distribusi ini penting bagi model *Naive Bayes* dalam menghitung probabilitas setiap *phylum* secara adil berdasarkan proporsi aslinya.

4.4 Reduksi Dimensi dan Analisis Variansi dengan IPCA

Dataset hasil ekstraksi fitur memiliki dimensi awal sebesar 4.096 yang merepresentasikan seluruh kemungkinan kombinasi *k-mer* [38]. Ruang fitur yang sangat luas dibandingkan jumlah sampel dapat menyebabkan data tersebar semakin jarang (*sparsity*). Kondisi tersebut memicu fenomena *curse of dimensionality* yang mempersulit model dalam membedakan pola antar kelas secara akurat. Penerapan metode *Incremental Principal Component Analysis* (IPCA) menjadi solusi strategis untuk mereduksi dimensi data sekaligus mempertahankan informasi penting melalui mekanisme variansi kumulatif (*Cumulative Explained Variance*).

IPCA mentransformasi fitur asli menjadi sekumpulan komponen utama yang ortogonal dan terurut berdasarkan kontribusinya terhadap variansi data. Penentuan jumlah komponen optimal didasarkan pada target CEV yang diinginkan. Visualisasi hubungan antara penambahan jumlah komponen utama dan akumulasi informasi ditampilkan pada

Gambar 4.9.



Gambar 4.9 Kurva Variansi Kumulatif Terhadap Jumlah Komponen Utama (IPCA)

Gambar 4.9 memperlihatkan tren kenaikan variansi yang sangat tajam pada ratusan komponen pertama dan mulai melandai setelah melewati titik tertentu. Pola kurva ini mengindikasikan bahwa mayoritas informasi biologis yang relevan sebenarnya terpusat pada sejumlah kecil dimensi awal. Komponen-komponen dengan nilai variansi rendah pada bagian ekor kurva cenderung merepresentasikan *noise* yang dapat mengganggu batas keputusan pada proses klasifikasi [11]. Rincian jumlah komponen yang diperlukan untuk mencapai berbagai ambang batas target CEV dirangkum dalam Tabel 4.2.

Tabel 4.2 Jumlah Komponen Utama Berdasarkan Target CEV

Target CEV	Jumlah Komponen (k)	Reduksi Dimensi (%)
0,50 (50%)	60	98,54%
0,60 (60%)	118	97,12%
0,70 (70%)	234	94,29%
0,80 (80%)	474	88,43%
0,90 (90%)	1.030	74,85%
0,95 (95%)	1.622	60,40%

Data pada Tabel 4.2 memperlihatkan efisiensi metode IPCA dalam menyederhanakan ruang fitur. Persentase reduksi dimensi tersebut diperoleh melalui perhitungan rasio jumlah komponen terpilih (k) terhadap total fitur asli ($N_{\text{awal}} = 4.096$). Rumus kalkulasi efisiensi reduksi dimensi didefinisikan sebagai berikut:

$$\text{Reduksi Dimensi (\%)} = 1 - \frac{k}{4.096} \times 100\% \quad (4.4)$$

Penerapan target CEV 0,60 sebagai contoh membutuhkan penggunaan 118 komponen utama. Hasil kalkulasi menggunakan rumus tersebut adalah $(1 - 118/4096) \times 100\% = 97, 1191\ldots\%$, yang kemudian dibulatkan menjadi 97,12%. Kemampuan representasi data yang ringkas ini dalam mempertahankan pola informasi utama membuktikan bahwa sebagian besar fitur asli merupakan informasi redundan [38]. Penggunaan fitur yang jauh lebih kecil namun padat informasi terbukti menghasilkan kinerja yang lebih unggul dibandingkan penggunaan seluruh fitur yang tersedia [29]. Analisis terhadap struktur komponen dilakukan untuk memahami kontribusi setiap sumbu baru terhadap total variansi informasi. Tabel 4.3 menyajikan rincian statistik komponen pada skenario model terbaik.

Tabel 4.3 Rincian Nilai Eigen dan Proporsi Variansi pada Model CEV 0,60

Komponen	Nilai Eigen	Variansi (%)	Kumulatif (%)
PC1	17,1973	5,4538%	5,4538%
PC2	14,5842	4,6251%	10,0790%
PC3	10,8463	3,4397%	13,5187%
.	.	.	.
PC116	0,3992	0,1266%	59,7542%
PC117	0,3983	0,1263%	59,8805%
PC118	0,3952	0,1253%	60,0058%

Tabel 4.3 menunjukkan bahwa PC1 memiliki nilai eigen tertinggi sebesar 17,1973. Nilai eigen yang besar pada komponen awal mencerminkan pemusatan informasi pada dimensi tersebut. Proses pembentukan sumbu variansi ini direpresentasikan secara matematis melalui matriks vektor eigen (*eigenvectors*). Matriks vektor eigen yang memuat bobot model IPCA divisualisasikan pada Gambar 4.10.

	aaaaaa	aaaaac	aaaaag	...	tttttc	tttttg	tttttt
PC1	-0.00296	-0.00110	-0.00486	...	-0.00282	-0.00274	-0.00591
PC2	-0.00872	-0.00215	-0.02305	...	-0.00282	-0.00613	0.00028
PC3	-0.00271	-0.00171	-0.00129	...	-0.00079	-0.00116	-0.00723
...	...	...	...	...	...	...	...
PC1620	-0.00526	-0.00313	-0.02155	...	-0.02012	0.02809	0.01251
PC1621	0.00818	-0.06102	0.01477	...	0.00639	-0.03060	0.00361
PC1622	0.00180	0.01854	0.00503	...	-0.04345	-0.00118	0.00778

Gambar 4.10 Matriks Vektor Eigen pada Model IPCA

Gambar 4.10 memperlihatkan nilai bobot yang mengindikasikan seberapa besar kontribusi setiap fitur *k-mer* asli dalam membentuk komponen utama (PC). Proses reduksi dimensi dilakukan pada tahap ini dengan cara memotong baris matriks sesuai target CEV. Penggunaan target CEV 0,60 mengharuskan sistem untuk hanya mempertahankan 118 baris pertama (PC1 hingga PC118) dan membuang sisa komponen lainnya.

Matriks vektor eigen yang telah direduksi tersebut kemudian digunakan untuk mentransformasi sekuens data mentah. Operasi perkalian matriks antara data latih dengan matriks vektor eigen menghasilkan representasi ruang fitur baru. Hasil transformasi pada data latih ini ditampilkan dalam Gambar 4.11.

	PC1	PC2	PC3	...	PC1620	PC1621	PC1622
Sampel_1	2.2884	0.1340	-2.6903	...	0.0559	-0.0699	-0.0430
Sampel_2	-2.3397	-1.4345	1.4508	...	-0.0425	-0.4904	0.1781
Sampel_3	-1.8382	3.3250	2.2277	...	0.0208	-0.0298	-0.0150
...	...	...	...	...	...	...	...
Sampel_318804	-6.8347	6.0724	-6.2167	...	-0.0673	0.0932	0.0005
Sampel_318805	3.3090	1.0667	-1.1063	...	-0.1440	0.0431	-0.1158
Sampel_318806	-0.3556	2.2434	2.6929	...	0.1256	0.5359	0.1645

Gambar 4.11 Matriks Hasil Transformasi Kontinu pada Data Latih

Gambar 4.11 memperlihatkan keberhasilan transformasi data dari matriks frekuensi *k-mer* yang awalnya banyak berisi angka nol menjadi matriks fitur yang padat. Matriks hasil transformasi ini diisi oleh angka desimal kontinu dengan rentang nilai positif dan negatif. Struktur data yang padat membantu algoritma klasifikasi bekerja lebih efisien dalam mengenali pola dari setiap sampel bakteri.

4.5 Evaluasi Kinerja Model Klasifikasi pada Berbagai Target CEV


Tahap evaluasi ini bertujuan untuk menentukan titik keseimbangan optimal antara reduksi dimensi dan akurasi prediksi sekuens 16S rRNA. Pengujian dilakukan dengan membandingkan enam variasi target *Cumulative Explained Variance* (CEV) mulai dari 0,5 hingga 0,95. Metrik evaluasi difokuskan pada pengamatan akurasi, *Weighted F1-Score*, *Area Under Curve* (AUC), tingkat kepercayaan (*confidence*), serta efisiensi waktu komputasi.

Tabel 4.4 Rincian Nilai Metrik Evaluasi Model pada Berbagai Skenario CEV

Skenario	Akurasi	Precision	Recall	Weighted F1-Score	AUC	Confidence
CEV 0,5	0,9609	0,9687	0,9609	0,9634	0,9994	0,9900
CEV 0,6	0,9689	0,9743	0,9689	0,9705	0,9994	0,9900
CEV 0,7	0,9655	0,9734	0,9655	0,9678	0,9989	0,9900
CEV 0,8	0,9409	0,9618	0,9409	0,9474	0,9920	0,9900
CEV 0,9	0,8722	0,9139	0,8722	0,8844	0,9624	0,9900
CEV 0,95	0,8112	0,8721	0,8112	0,8298	0,9311	0,9900

4.5.1 Pengaruh Variasi Target CEV terhadap Performa Model

Pengujian performa model didasarkan pada hubungan antara jumlah informasi yang dipertahankan melalui komponen utama terhadap kemampuan klasifikasi *Naïve Bayes*. Tren perubahan kinerja model berdasarkan jumlah fitur (k) divisualisasikan melalui grafik pada Gambar 4.12.



Gambar 4.12 Grafik Tren Performa Model dan Waktu Komputasi Terhadap Target CEV

Akurasi tertinggi sebesar 96,89% tercapai pada target CEV 0,6 dengan jumlah komponen utama $k = 118$. Nilai *Weighted F1-Score* pada titik tersebut juga mencapai puncak sebesar 97,05%. Penambahan


komponen utama pada target CEV 0,7 hingga 0,95 justru menyebabkan penurunan hingga menyentuh akurasi terendah 81,12%. Waktu komputasi meningkat seiring bertambahnya dimensi fitur, mulai dari 68,0 detik (pada CEV 0,6) hingga 447,2 detik (pada CEV 0,95).

Target persentase varians yang dipasang terlalu tinggi terbukti memberikan dampak negatif pada hasil akurasi klasifikasi [11]. Komponen utama yang memiliki varians kecil pada target CEV 0,95 cenderung membawa banyak gangguan (*noise*) yang mengacaukan garis pembatas antar kelas *phylum* bakteri. Dimensi yang tetap tinggi akibat penggunaan target CEV yang besar menyebabkan ruang fitur kembali melebar. Kondisi tersebut meningkatkan risiko terjadinya fenomena *curse of dimensionality*, di mana informasi yang relevan bercampur dengan *noise* dan membuat model kesulitan membedakan pola antar kelas [38]. Pola informasi yang terpusat dan jelas menjadi faktor utama algoritma *Naïve Bayes* mampu memberikan performa terbaik pada dimensi yang rendah [32].

4.5.2 Trade-off antara Performa Klasifikasi dan Kompleksitas Fitur

Penentuan model terbaik memerlukan analisis terhadap keseimbangan antara akurasi prediksi dan efisiensi komputasi. Hasil eksperimen menunjukkan bahwa peningkatan jumlah komponen utama (k) untuk mencapai target persentase varians yang lebih tinggi tidak memberikan keuntungan linear terhadap kualitas klasifikasi [11]. Kondisi ini menciptakan titik temu (*trade-off*) di mana penambahan fitur pada level tertentu justru merugikan performa model sekaligus menambah waktu pemrosesan secara meningkat. Hubungan antara akurasi dan biaya waktu komputasi divisualisasikan melalui Gambar 4.13.

Puncak akurasi sebesar 96,89% tercapai pada CEV 0,6 dengan jumlah fitur yang sedikit ($k = 118$). Penggunaan waktu CEV 0,6 hanya membutuhkan 68,0 detik, yang jauh lebih efisien dibandingkan skenario dimensi tinggi lainnya. Strategi penggunaan subset fitur yang



Gambar 4.13 Grafik Analisis *Trade-off* antara Akurasi dan Waktu Komputasi


kecil terbukti mampu mempertahankan atau bahkan meningkatkan akurasi klasifikasi dibandingkan menggunakan seluruh dimensi data [36]. Penghematan waktu komputasi mencapai titik signifikan sebelum garis beban waktu menanjak tajam pada target CEV di atas 0,7.

Komponen utama dengan variansi kecil pada target CEV 0,95 cenderung menyertakan gangguan (*noise*) yang tidak relevan bagi pemisahan kelas *phylum* [11]. Peningkatan jumlah fitur hingga $k = 1622$ tanpa penambahan sampel yang proporsional memicu terjadinya penurunan performa akibat data yang semakin jarang (*sparse*) [38]. Kualitas model pada dimensi rendah tetap unggul karena *Naïve Bayes* bekerja sangat optimal pada distribusi fitur dengan tingkat ketidakpastian yang rendah [32]. CEV 0,6 dengan 118 komponen ditetapkan sebagai titik optimal (*sweet spot*) yang memberikan hasil klasifikasi paling akurat dengan beban komputasi minimal.

4.5.3 Analisis Tingkat Kepercayaan dan Fenomena Overconfidence

Evaluasi kestabilan model memerlukan analisis dibandingkan pengamatan akurasi semata untuk memastikan keandalan prediksi pada

data sekuens 16S rRNA. Gambar 4.14 menyajikan perbandingan metrik *Area Under Curve* (AUC), akurasi, dan tingkat kepercayaan (*confidence*) model terhadap variasi target CEV.



Gambar 4.14 Grafik Analisis Keandalan Model

Nilai AUC mencapai tingkat maksimal mendekati 1,0 pada rentang CEV 0,5 hingga 0,6. Penurunan kemampuan pembedaan antar kelas model mulai terdeteksi setelah melewati ambang batas CEV 0,7. Tingkat kepercayaan (*confidence*) model menunjukkan perilaku yang bertolak belakang dengan tetap bertahan secara stabil pada angka 0,99 (99%) di seluruh skenario pengujian. Fenomena penurunan kinerja pada nilai k yang besar menunjukkan indikasi *overconfidence*, di mana model dengan kompleksitas tinggi cenderung menghasilkan estimasi probabilitas yang tidak merepresentasikan tingkat kebenaran aktual, meskipun nilai *confidence* tetap tinggi, akurasi dan *Weighted F1-Score* justru mengalami penurunan [37].


Model memberikan estimasi probabilitas yang sangat tinggi namun tidak lagi mencerminkan tingkat kebenaran yang sesungguhnya [37]. Kecenderungan *Naïve Bayes* dalam menghasilkan nilai posterior yang ekstrem ini dipicu oleh pengulangan penghitungan informasi akibat

asumsi independensi fitur [32]. Pengikutsertaan komponen utama dengan variansi kecil pada dimensi tinggi sering kali hanya memasukkan pola gangguan (*noise*) yang mengaburkan batas keputusan, sehingga model memberikan hasil prediksi yang sangat yakin meskipun secara fakta salah [11].

Penggunaan metrik AUC dalam pengujian ini memberikan gambaran yang lebih objektif mengenai kemampuan model dalam meranking kelas secara relatif dibandingkan metrik akurasi sederhana [36]. Stabilitas AUC yang tetap berada di atas 0,93 membuktikan bahwa model sebenarnya masih memiliki kemampuan pembedaan kelas yang baik, meskipun ketepatan klasifikasi terganggu oleh peningkatan dimensi ruang fitur [36].

4.5.4 Penentuan Target CEV Optimal

Penentuan titik optimal dalam penelitian ini tidak hanya didasarkan pada satu metrik tunggal, melainkan melalui evaluasi menyeluruh yang mempertimbangkan keseimbangan antara performa klasifikasi, efisiensi dimensi, dan kesesuaian estimasi probabilitas model. Pemetaan karakteristik performa pada setiap skenario target *Cumulative Explained Variance* (CEV) dilakukan menggunakan visualisasi *Radar Chart*. Visualisasi tersebut memungkinkan pengamatan secara bersamaan terhadap enam metrik evaluasi utama, yaitu Akurasi, *Weighted F1-Score*, AUC, *Precision*, *Recall*, dan *Confidence*. Hasil visualisasi karakteristik performa disajikan dalam Gambar 4.15..



Gambar 4.15 Visualisasi *Radar Chart* Perbandingan Karakteristik Performa antar Skenario

Berdasarkan Gambar 4.15 di atas, terlihat pola karakteristik yang berbeda antar skenario. CEV 0,6 (ditandai dengan garis merah) membentuk pola heksagonal yang paling proporsional dengan cakupan area terluas dibandingkan variasi lainnya. Garis performa pada CEV 0,6 menyentuh titik terluar pada sumbu Akurasi (96,89%), *Weighted F1-Score* (97,05%), *Precision*, dan *Recall*, serta mempertahankan nilai AUC yang mendekati sempurna (0,9994). Pendekatan dengan target variasi tinggi, khususnya CEV 0,95 (garis merah muda), menunjukkan pola yang menyusut tajam ke arah dalam pada sumbu metrik kinerja aktual, namun tetap bertahan tinggi pada sumbu *Confidence*.

Fenomena penyusutan area pada CEV tinggi ini mengonfirmasi adanya redundansi informasi yang tidak berkontribusi secara efektif terhadap peningkatan kinerja model. Penambahan komponen utama untuk variasi 95% justru memasukkan fitur-fitur bervariasi kecil yang merepresentasikan *noise* biologis atau kesalahan sekuensing, bukan informasi pembeda antar *phylum* [11]. Prinsip *curse of dimensionality*

menjelaskan bahwa penambahan dimensi tanpa peningkatan jumlah sampel yang sebanding menyebabkan data menjadi semakin jarang (*sparse*). Kondisi tersebut membuat jarak antar sampel menjadi kurang informatif dan menyulitkan model dalam membentuk batas keputusan yang akurat [38].

Perbedaan yang lebar antara tingkat kepercayaan (*confidence*) yang tinggi dengan akurasi yang rendah pada CEV 0,95 (terlihat pada bentuk grafik radar yang tidak simetris) kembali menegaskan adanya masalah ketidaktepatan kalibrasi. Model yang ideal seharusnya memiliki keselarasan antara seberapa yakin model memprediksi dengan seberapa sering prediksi tersebut benar secara aktual.

CEV 0,6 menunjukkan titik terbaik di mana nilai *confidence* (0,9900) sangat mendekati akurasi aktualnya (0,9689). Hal ini menandakan bahwa estimasi probabilitas yang dihasilkan model benar-benar mencerminkan kemampuan aslinya [37]. Kesederhanaan model terpenuhi pada titik ini, karena performa maksimal berhasil dicapai dengan jumlah fitur yang minimal ($k = 118$), sehingga terhindar dari kompleksitas komputasi yang tidak perlu [29].

Berdasarkan visualisasi *radar chart*, dukungan teori mengenai dampak *noise* pada dimensi tinggi, serta stabilitas kalibrasi model, penelitian ini menetapkan CEV 0,6 dengan jumlah komponen utama $k = 118$ sebagai titik optimal. Titik ini merepresentasikan *sweet spot* yang memaksimalkan akurasi dan meminimalkan beban komputasi.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil pengujian dan analisis data yang telah dilakukan pada penelitian ini, kesimpulan yang dapat diambil untuk menjawab tujuan penelitian adalah sebagai berikut:

1. Variasi target *Cumulative Explained Variance* (CEV) pada metode *Incremental Principal Component Analysis* (IPCA) memberikan pengaruh yang signifikan namun tidak linear terhadap kinerja klasifikasi algoritma *Gaussian Naïve Bayes*. Peningkatan target CEV (penambahan jumlah komponen utama) terbukti tidak selalu berbanding lurus dengan peningkatan performa model. Penggunaan target CEV yang terlalu tinggi (seperti 0,95) secara drastis meningkatkan waktu komputasi hingga 447,2 detik dan justru menurunkan akurasi model menjadi 81,12%. Penurunan performa tersebut terjadi karena komponen utama tambahan pada batas akhir kurva variansi umumnya merepresentasikan *noise* yang memicu fenomena *curse of dimensionality* serta menyebabkan model mengalami *overconfidence*.
2. Nilai CEV 0,60 ditetapkan sebagai titik paling optimal dalam mengklasifikasikan data sekuens 16S rRNA taksonomi bakteri tingkat *phylum*. Penerapan ambang batas ini mampu memangkas 97,12% dimensi ruang fitur awal (dari 4.096 menjadi 118 komponen utama) namun tetap berhasil mencapai performa puncak dengan perolehan Akurasi sebesar 96,89%, *Weighted F1-Score* sebesar 97,05%, dan AUC mencapai 0,9994. Keseimbangan titik optimal ini dicapai dengan beban waktu komputasi yang sangat efisien selama 68,0 detik.

5.2 Saran

Penelitian ini memiliki potensi untuk dikembangkan lebih lanjut. Rekomendasi yang dapat diberikan untuk penelitian mendatang meliputi:

1. Penelitian lanjutan disarankan untuk menerapkan metode klasifikasi selain *Naïve Bayes*, seperti *Support Vector Machine* (SVM) atau *Deep Learning*, untuk memvalidasi konsistensi pola yang ditemukan pada algoritma dengan kompleksitas lebih tinggi.
2. Analisis terhadap variasi panjang *k-mer* selain $k = 6$ perlu dilakukan untuk mengkaji pengaruh panjang terhadap kekayaan informasi fitur dan dampaknya pada penentuan nilai CEV optimal.
3. Pengujian pada tingkat taksonomi yang lebih spesifik, seperti genus atau spesies, direkomendasikan untuk menguji metode dalam menangani kelas dengan tingkat kemiripan biologis yang lebih tinggi dibandingkan tingkat *phylum*.

DAFTAR PUSTAKA

- [1] A. Santos, R. van Aerle, L. Barrientos, dan J. Martinez-Urtaza, “computational methods for 16S metabarcoding studies using Nanopore sequencing data”, *Computational and Structural Biotechnology Journal*, vol. 18, hlmn. 296–305, 2020.
- [2] C. V. Akihary dan B. J. Kolondam, “Pemanfaatan gen 16S rRNA sebagai perangkat identifikasi bakteri untuk penelitian-penelitian di Indonesia”, *Pharmacon Jurnal Ilmiah Farmasi UNSRAT*, vol. 9, no. 1, hlmn. 16–22, 2020.
- [3] C. Fu, E. A. Niskanen, G.-H. Wei, Z. Yang, M. Sanvicente-Garcia, M. Gell, dan L. Cheng, “K-mer manifold approximation and projection for visualizing DNA sequences”, *Genome Research*, vol. 35, hlmn. 1234–1246, 2025.
- [4] H. Zhang, Y. Shi, Y. Wang, X. Yang, K. Li, S. K. Im, dan Y. Han, “Biological sequence representation methods and recent advances: A review”, *Biology*, vol. 14, no. 9, hlmn. 1137, 2025.
- [5] D. R. P. Sari, “Metode *Principal Component Analysis* (PCA) sebagai penanganan asumsi multikolinearitas: Studi kasus data produksi tapioka”, *Parameter: Jurnal Matematika, Statistika dan Terapannya*, vol. 2, no. 2, hlmn. 115–124, 2023.
- [6] V. Lippi dan G. Ceccarelli, “Incremental Principal Component Analysis: Exact implementation and continuity corrections”, 2019.
- [7] K. Krijnen, P. Blenkinsopp, R. M. A. Heeren, dan I. G. M. Anthony, “Processing next-generation mass spectrometry imaging data Principal Component Analysis at scale”, *Journal of the American Society for Mass Spectrometry*, vol. 35, hlmn. 3063–3069, 2024.
- [8] K. R. T. P. Sari, W. D. N. Prasetya, dan E. M. Indrawati, “Aplikasi *Principal Component Analysis* untuk mengetahui daya beli kendaraan bermotor masyarakat Indonesia”, *Jurnal Inkofar*, vol. 5, no. 1, hlmn. 10–20, 2021.

- [9] M. S. N. V. Delsen, A. Z. Wattimena, dan S. D. Saputri, “Penggunaan metode analisis komponen utama untuk mereduksi faktor-faktor inflasi di kota Ambon”, *Jurnal Ilmu Matematika dan Terapan*, vol. 11, no. 2, hlmn. 109–118, 2017.
- [10] D. K. Utami, W. Ananta, dan A. Buono, “Klasifikasi metagenom dengan metode Naïve Bayes Classifier”, *Jurnal Ilmu Komputer Agri-Informatika*, vol. 3, no. 1, hlmn. 9–18, 2014.
- [11] J. Zheng dan C. Rakovski, “On the application of Principal Component Analysis to classification problems”, *Data Science Journal*, vol. 20, no. 1, hlmn. 26, 2021.
- [12] M. Agustriya, M. Ula, dan Kurniawati, “Analisis kinerja algoritma klasifikasi Naïve Bayes menggunakan *Genetic Algorithm* dan *Bagging* untuk data publik risiko transaksi kartu kredit”, *JUSTIN Jurnal Sistem dan Teknologi Informasi*, vol. 12, no. 3, hlmn. 584–591, 2024.
- [13] S. S. Prasetyowati dan Y. Sibaroni, “Unlocking the potential of Naïve Bayes for spatio-temporal classification: A novel approach to feature expansion”, *Journal of Big Data*, vol. 11, hlmn. 106, 2024.
- [14] S. Noer, “Identifikasi bakteri secara molekular menggunakan 16S rRNA”, *EduBiologia: Biological Science and Education Journal*, vol. 1, no. 1, hlmn. 1–6, 2021.
- [15] N. Chaudhary, A. K. Sharma, P. Agarwal, A. Gupta, dan V. K. Sharma, “16S Classifier: A tool for fast and accurate taxonomic classification of 16S rRNA hypervariable regions in metagenomic datasets”, *PLOS ONE*, hlmn. 1–13, 2015.
- [16] M. Muda, *Urutan tingkatan takson dalam klasifikasi makhluk hidup dengan penjelasan terlengkap*, [https:// ipa.pelajaran. co. id/ urutan- tingkatan- takson/](https://ipa.pelajaran.co.id/urutan-tingkatan-takson/), Diakses pada 26 November 2025, Okt. 2025.
- [17] H. Soueidan dan M. Nikolski, “Machine learning for metagenomics: Methods and tools”, 2016.

- [18] E. Ibrahimi, M. B. Lopes, X. Dhamo, A. Simeon, R. Shigdel, K. Hron, B. Stres, D. D’Elia, M. Berland, dan L. J. Marcos-Zambrano, “Overview of data preprocessing for machine learning applications in human microbiome research”, *Frontiers in Microbiology*, vol. 14, hlmn. 1 250 909, 2023.
- [19] R. Schmieder, Y. W. Lim, F. Rohwer, dan R. Edwards, “TagCleaner: Identification and removal of tag sequences from genomic and metagenomic datasets”, *BMC Bioinformatics*, vol. 11, no. 1, hlmn. 341, 2010.
- [20] D. A. Rozak dan A. J. Rozak, “Using a color-coded ambigraphic nucleic acid notation to visualize conserved palindromic motifs within and across genomes”, *BMC Genomics*, vol. 15, hlmn. 52, 2014.
- [21] R. Lücking dan D. L. Hawksworth, “Formal description of sequence-based voucherless fungi: Promises and pitfalls, and how to resolve them”, *IMA Fungus*, vol. 9, no. 1, hlmn. 143–166, 2018.
- [22] R. Schmieder dan R. Edwards, “Quality control and preprocessing of metagenomic datasets”, *Bioinformatics*, vol. 27, no. 6, hlmn. 863–864, 2011.
- [23] Y. Li, N. Adams, dan T. Bellotti, “A relabeling approach to handling the class imbalance problem for logistic regression”, *Journal of Computational and Graphical Statistics*, vol. 31, no. 1, hlmn. 241–253, 2022.
- [24] C. Moeckel, M. Mareboina, M. A. Konnaris, C. S. Y. Chan, I. Mouratidis, A. Montgomery, N. Chantzi, G. A. Pavlopoulos, dan I. Georgakopoulos-Soares, “A survey of k-mer methods and applications in bioinformatics”, *Computational and Structural Biotechnology Journal*, vol. 23, hlmn. 2289–2300, 2024.
- [25] B. K. Sarkar, A. R. Sharma, M. Bhattacharya, G. Sharma, S. Lee, dan C. Chakraborty, “Determination of k-mer density in a DNA sequence and subsequent cluster formation algorithm based on

- the application of electronic filter”, *Scientific Reports*, vol. 11, hlmn. 13 701, 2021.
- [26] A. Gholamy, V. Kreinovich, dan O. Kosheleva, “Why 70/30 or 80/20 relation between training and testing sets: A pedagogical explanation”, University of Texas at El Paso, tech. rep., 2018.
 - [27] S. Raschka, “Model evaluation, model selection, and algorithm selection in machine learning”, *arXiv preprint arXiv:1811.12808*, 2018.
 - [28] J. Sadaiyandi, P. Arumugam, A. K. Sangaiah, dan C. Zhang, “Stratified sampling-based deep learning approach to increase prediction accuracy of unbalanced dataset”, *Electronics*, vol. 12, hlmn. 4423, 2023.
 - [29] A. G. K. Janecek, W. N. Gansterer, M. A. Demel, dan G. F. Ecker, “On the relationship between feature selection and classification accuracy”, di dalam *JMLR Workshop and Conference Proceedings*, vol. 4, 2008, hlmn. 90–105.
 - [30] F. Pedregosa dkk., “Scikit-learn: Machine Learning in Python”, *Journal of Machine Learning Research*, hlmn. 2825–2830, 2011.
 - [31] D. A. Ross, J. Lim, R.-S. Lin, dan M.-H. Yang, “Incremental learning for robust visual tracking”, *International Journal of Computer Vision*, vol. 77, no. 1, hlmn. 125–141, 2007.
 - [32] I. Rish, “An empirical study of the Naïve Bayes classifier”, IBM T.J. Watson Research Center, 2001, hlmn. 41–46.
 - [33] G. H. John dan P. Langley, “Estimating continuous distributions in Bayesian classifiers”, di dalam *Proceedings of the Eleventh Conference on Uncertainty in Artificial Intelligence (UAI 1995)*, 1995, hlmn. 338–345.
 - [34] S. A. R. Abadi, A. Mohammadi, dan S. Koohi, “PC-mer: An ultra-fast memory-efficient tool for metagenomics profiling and classification”, *PLoS ONE*, vol. 19, no. 8, hlmn. 1–20, 2024.
 - [35] M. C. Hinojosa Lee, J. Braet, dan J. Springael, “Performance metrics for multilabel emotion classification: Comparing micro,

- macro, and weighted f1-scores”, *Applied Sciences*, vol. 14, hlmn. 9863, 2024.
- [36] T. Fawcett, “An introduction to ROC analysis”, *Pattern Recognition Letters*, vol. 27, no. 8, hlmn. 861–874, 2006.
- [37] C. Guo, G. Pleiss, Y. Sun, dan K. Q. Weinberger, “On calibration of modern neural networks”, di dalam *Proceedings of the 34th International Conference on Machine Learning (ICML)*, PMLR, vol. 70, 2017, hlmn. 1321–1330.
- [38] D. Peng, Z. Gui, dan H. Wu, “Interpreting the curse of dimensionality from distance concentration and manifold effect”, Jan. 2024.
- [39] M. Carvalho, A. J. Pinho, dan S. Brás, “Resampling approaches to handle class imbalance: A review from a data perspective”, *Journal of Big Data*, vol. 12, no. 1, hlmn. 71, 2025.

LAMPIRAN

LAMPIRAN A. PERHITUNGAN EKSTRAKSI FITUR K-MER

Berikut adalah rincian perhitungan manual untuk proses ekstraksi fitur k-mer berdasarkan teori yang dipaparkan pada Bab II dan metode pada Bab III. Ilustrasi ini menggunakan parameter panjang k-mer ($k = 6$) sesuai dengan batasan masalah penelitian.

1. Definisi Variabel

Berdasarkan subbab 2.5, variabel yang digunakan adalah:

- a. S : Sekuens DNA input.
- b. N : Panjang total sekuens DNA (jumlah nukleotida).
- c. k : Panjang subsekuens (*window size*), ditetapkan $k = 6$.

2. Studi Kasus

Mengacu pada ilustrasi Gambar 2.3, digunakan contoh sekuens pendek sebagai berikut:

$$S = \text{ATGCACTACTG}$$

Maka diketahui:

$$N = 11 \quad (\text{Panjang karakter sekuens})$$

$$k = 6$$

3. Perhitungan Jumlah Token k-mer

Jumlah total k-mer yang dihasilkan dari sebuah sekuens dihitung menggunakan rumus:

$$\text{Total } k\text{-mer} = N - k + 1$$

Substitusi nilai:

$$\begin{aligned}\text{Total } k\text{-mer} &= 11 - 6 + 1 \\ &= 5 + 1 \\ &= 6 \text{ buah } k\text{-mer}\end{aligned}$$

4. Proses *Sliding Window* (Tokenisasi)

Proses pemecahan sekuens dilakukan dengan menggeser jendela sepanjang k satu per satu ke kanan (satu langkah pergeseran).

Indeks	Posisi Karakter	Ekstraksi <i>Substring</i>	Hasil k -mer
1	1 s.d 6	ATGCACTACTG	ATGCAC
2	2 s.d 7	ATGCACTACTG	TGCACT
3	3 s.d 8	ATGCACTACTG	GCACTA
4	4 s.d 9	ATGCACTACTG	CACTAC
5	5 s.d 10	ATGCACTACTG	ACTACT
6	6 s.d 11	ATGCACTACTG	CTACTG

5. Perhitungan Dimensi Vektor Fitur

Total kemungkinan fitur (dimensi) yang terbentuk dari kombinasi basa nukleotida (A, T, G, C) dengan panjang k dihitung dengan rumus:

$$\text{Dimensi Fitur} = 4^k$$

Untuk $k = 6$:

$$\begin{aligned}\text{Dimensi Fitur} &= 4^6 \\ &= 4 \times 4 \times 4 \times 4 \times 4 \times 4 \\ &= 4.096 \text{ fitur}\end{aligned}$$

6. Transformasi ke Vektor Frekuensi

Sesuai Subbab 3.3, setiap sekuens direpresentasikan sebagai vektor frekuensi. Misalkan V adalah vektor fitur sepanjang 4.096, dimana setiap indeks mewakili kombinasi k-mer unik (dari AAAAAA hingga TTTTTT).

Untuk sekuens contoh S , frekuensi kemunculan k-mer adalah sebagai berikut:

1. Frekuensi ATGCAC = 1
2. Frekuensi TGCACT = 1
3. Frekuensi GCACTA = 1
4. Frekuensi CACTAC = 1
5. Frekuensi ACTACT = 1
6. Frekuensi CTACTG = 1
7. Frekuensi k-mer lainnya = 0

Maka representasi vektornya (disederhanakan) adalah:

$$V_S = [0, \dots, 1, 1, 1, 1, 1, 1, \dots, 0]$$

**Nilai 1 ditempatkan pada indeks yang sesuai dengan k-mer yang muncul.*

LAMPIRAN B. PERHITUNGAN MANUAL IPCA

Lampiran ini menyajikan perhitungan manual algoritma *Incremental Principal Component Analysis* (IPCA) langkah demi langkah, termasuk penjabaran detail dekomposisi matriks (SVD). Data yang digunakan adalah simulasi data frekuensi k-mer dengan dimensi 4×6 yang dibagi menjadi dua *batch*.

1. Inisialisasi Data

Dimisalkan matriks X (4 sampel, 6 fitur) sebagai berikut:

$$X = \begin{bmatrix} 10 & 12 & 5 & 8 & 2 & 4 \\ 14 & 16 & 3 & 4 & 6 & 8 \\ 8 & 10 & 20 & 22 & 5 & 5 \\ 6 & 4 & 15 & 18 & 7 & 3 \end{bmatrix}$$

Data dibagi menjadi dua *batch* dengan rincian:

- Batch A* ($N_A = 2$): Sampel 1 dan 2.
- Batch B* ($N_B = 2$): Sampel 3 dan 4.

TAHAP 1: Pembelajaran Awal (*Batch A*)

Langkah 1.1: Input *Batch A*

$$X_A = \begin{bmatrix} 10 & 12 & 5 & 8 & 2 & 4 \\ 14 & 16 & 3 & 4 & 6 & 8 \end{bmatrix}$$

Langkah 1.2: Menghitung Rata-rata *Batch A* (μ_A)

$$\mu_A = \frac{1}{2} \sum_{i=1}^n x_i$$

$$\mu_A = \left[\frac{10+14}{2}, \frac{12+16}{2}, \frac{5+3}{2}, \frac{8+4}{2}, \frac{2+6}{2}, \frac{4+8}{2} \right]^{\#}$$

$$\mu_A = [12, 14, 4, 6, 4, 6]$$

Langkah 1.3: Pemusatan Data (Centering)

$$\tilde{X}_A = X_A - \mu_A$$

$$\tilde{X}_A = \begin{bmatrix} 10-12 & 12-14 & 5-4 & 8-6 & 2-4 & 4-6 \\ 14-12 & 16-14 & 3-4 & 4-6 & 6-4 & 8-6 \end{bmatrix}$$

$$\tilde{X}_A = \begin{bmatrix} -2 & -2 & 1 & 2 & -2 & -2 \\ 2 & 2 & -1 & -2 & 2 & 2 \end{bmatrix}$$

Langkah 1.4: Singular Value Decomposition (SVD)

Pada tahap ini, dilakukan dekomposisi $\tilde{X}_A$ untuk mendapatkan komponen utama awal. Rincian perhitungan adalah sebagai berikut:

a. Membentuk Matriks Kovariansi Kecil (C)

Perhitungan $C = \tilde{X}_A \cdot \tilde{X}_A^T$ menghasilkan matriks persegi 2×2 :

$$C = \begin{bmatrix} -2 & -2 & 1 & 2 & -2 & -2 \\ 2 & 2 & -1 & -2 & 2 & 2 \end{bmatrix} \cdot \begin{bmatrix} 1 & -1 \\ 2 & -2 \\ -2 & 2 \\ -2 & 2 \end{bmatrix}$$

$$C = \begin{bmatrix} 21 & -21 \\ -21 & 21 \end{bmatrix}$$

b. Mencari Nilai Eigen (λ)

Persamaan karakteristik $|C - \lambda I| = 0$ diselesaikan dengan cara:

$$\det \begin{bmatrix} 21 - \lambda & -21 \\ -21 & 21 - \lambda \end{bmatrix} = (21 - \lambda)^2 - (-21)^2 = 0$$

$$\lambda^2 - 42\lambda + 441 - 441 = 0 \rightarrow \lambda(\lambda - 42) = 0$$

Diperoleh hasil $\lambda_1 = 42$ dan $\lambda_2 = 0$.

c. Menghitung Nilai Singular (Σ_A)

Nilai singular merupakan akar dari nilai eigen non-nol:

$$\sigma_1 = \sqrt{42} \approx 6.48$$

Hasil perhitungan nilai singular adalah $\Sigma_A = [6.48]$.

d. Mencari Vektor Singular Kiri (U_A)

Pencarian vektor singular kiri menggunakan nilai eigen terbesar, yaitu $\lambda_1 = 42$. Sistem persamaan yang harus diselesaikan adalah:

$$(C - \lambda_1 I)x = 0$$

Substitusi $\lambda_1 = 42$ ke dalam matriks menghasilkan:

$$C - 42I = \begin{bmatrix} 21 - 42 & -21 \\ -21 & 21 - 42 \end{bmatrix} = \begin{bmatrix} -21 & -21 \\ -21 & -21 \end{bmatrix}$$

Penyelesaian sistem persamaan tersebut adalah:

$$\begin{bmatrix} -21 & -21 \\ -21 & -21 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Baris pertama persamaan menunjukkan:

$$-21x - 21y = 0 \rightarrow x + y = 0 \rightarrow x = -y$$

Pemilihan nilai $y = 1$ dilakukan agar diperoleh vektor eigen non-trivial, sehingga didapatkan:

$$x = -1 \rightarrow v = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Vektor singular disyaratkan berupa vektor satuan, sehingga diperlukan proses normalisasi:

$$\|v\| = \sqrt{(-1)^2 + (1)^2} = \sqrt{2}$$

$$u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} -1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} -0.707 \\ 0.707 \end{bmatrix}$$

Arah vektor eigen tidak mempengaruhi ortogonalitas maupun panjang vektor, sehingga vektor dapat dikalikan dengan skalar -1 untuk mempermudah pembacaan:

$$u_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \approx \begin{bmatrix} 0.707 \\ -0.707 \end{bmatrix}$$

Hasil akhirnya adalah:

$$U_A = \begin{bmatrix} 0.707 \\ -0.707 \end{bmatrix}$$

e. Mencari Vektor Singular Kanan / Komponen (V^T)

Perhitungan $V = \frac{1}{\sigma} \tilde{X}_A^T U_A$ dilakukan sebagai berikut:

$$V = \frac{1}{6.48} \begin{bmatrix} 1 & 1 \\ -2 & 2 \end{bmatrix} \begin{bmatrix} 0.707 \\ -0.707 \end{bmatrix}$$

$$V \approx \frac{1}{6.48} \begin{bmatrix} 1.414 & -2.828 \\ -2.828 & 2.828 \end{bmatrix} \approx \begin{bmatrix} 0.22 & -0.44 \\ -0.44 & 0.44 \end{bmatrix}$$

Hasil Tahap 1: Model menyimpan nilai parameter μ_A , U_A , dan Σ_A .

TAHAP 2: Pembelajaran Inkremental (*Batch B*)

Langkah 2.1: Input *Batch B*

Data *batch* baru diberikan sebagai berikut:

$$X_B = \begin{bmatrix} 8 & 10 & 20 & 22 & 5 & 5 \\ 6 & 4 & 15 & 18 & 7 & 3 \end{bmatrix}$$

Langkah 2.2: Menghitung Rata-rata *Batch B* (μ_B)

Perhitungan rata-rata dilakukan per kolom:

$$\mu_B = \left[\frac{8+6}{2}, \frac{10+4}{2}, \frac{20+15}{2}, \frac{22+18}{2}, \frac{5+7}{2}, \frac{5+3}{2} \right]$$

$$\mu_B = [7, 7, 17.5, 20, 6, 4]$$

Langkah 2.3: Pembaruan Rata-rata Global (μ_{baru})

Rata-rata global diperbarui menggunakan jumlah sampel *Batch A* dan *Batch B* (masing-masing 2 sampel):

$$\mu_{\text{baru}} = \frac{2\mu_A + 2\mu_B}{4}$$

Substitusi nilai dilakukan sebagai berikut:

$$\mu_{\text{baru}} = \frac{1}{4} \cdot 2[12, 14, 4, 6, 4, 6] + 2[7, 7, 17.5, 20, 6, 4]$$

$$\mu_{\text{baru}} = [9.5, 10.5, 10.75, 13, 5, 5]$$

Langkah 2.4: Menghitung Vektor Koreksi *Mean* (v)

Vektor koreksi dihitung menggunakan rumus:

$$v = \frac{n_A \cdot n_B}{n_A + n_B} (\mu_B - \mu_A)$$

Diketahui $n_A = n_B = 2$, sehingga persamaan menjadi:

$$v = \frac{2 \cdot 2}{4} (\mu_B - \mu_A) = 1 \cdot (\mu_B - \mu_A)$$

Perhitungan selisih rata-rata adalah:

$$\mu_B - \mu_A = [7-12, 7-14, 17.5-4, 20-6, 6-4, 4-6] = [-5, -7, 13.5, 14, 2, -2]$$

Hasil akhir vektor koreksi adalah:

$$v = [-5, -7, 13.5, 14, 2, -2]$$

Langkah 2.5: Membentuk Matriks Gabungan ($\hat{X}_B$)

Pemusatan data X_B terhadap μ_B dilakukan terlebih dahulu:

$$\begin{aligned} X_B - \mu_B &= \begin{bmatrix} 8-7 & 7-7 & 10-7 & 20-7 & 17.5-7 & 22-7 & 20-7 & 5-7 & 6-7 & 5-7 & 4-7 \\ 6-7 & 4-7 & 15-7 & 17.5-7 & 18-7 & 20-7 & 7-7 & 6-7 & 3-7 & 4-7 & 4-7 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 3 & 13 & 10.5 & 15 & 13 & -2 & -1 & -2 & -3 \\ -1 & -3 & 8 & 10.5 & 11 & 13 & 0 & -1 & -4 & -3 & -3 \end{bmatrix} \end{aligned}$$

Penggabungan vektor koreksi v dilakukan pada baris ketiga:

$$\hat{X}_B = \begin{bmatrix} 1 & 3 & 2.5 & 2 & -1 & 1 \\ -1 & -3 & -2.5 & -2 & 1 & -1 \\ -5 & -7 & 13.5 & 14 & 2 & -2 \end{bmatrix}$$

Langkah 2.6: Proyeksi ke Ruang Fitur Lama

Proyeksi dilakukan dengan mengalikan matriks gabungan $\hat{X}_B$ dengan vektor basis fitur lama V :

$$\tilde{X}_{\text{proj}} = \hat{X}_B \cdot V$$

dengan

$$V = [0.44, 0.44, -0.22, -0.44, 0.44, 0.44]^T.$$

Perhitungan per baris:

1. Baris 1 (Sampel 3):

$$\begin{aligned} & (1)(0.44) + (3)(0.44) + (2.5)(-0.22) + (2)(-0.44) + (-1)(0.44) + (1)(0.44) \\ & = 0.44 + 1.32 - 0.55 - 0.88 - 0.44 + 0.44 = 0.33 \end{aligned}$$

2. Baris 2 (Sampel 4):

$$\begin{aligned} & (-1)(0.44) + (-3)(0.44) + (-2.5)(-0.22) + (-2)(-0.44) + (1)(0.44) + (-1)(0.44) \\ & = -0.44 - 1.32 + 0.55 + 0.88 + 0.44 - 0.44 = -0.33 \end{aligned}$$

3. Baris 3 (Vektor Koreksi *Mean*):

$$\begin{aligned} & (-5)(0.44) + (-7)(0.44) + (13.5)(-0.22) + (14)(-0.44) + (2)(0.44) + (-2)(0.44) \\ & = -2.20 - 3.08 - 2.97 - 6.16 + 0.88 - 0.88 = -14.41 \end{aligned}$$

Hasil vektor proyeksi:

$$\tilde{X}_{\text{proj}} = \begin{bmatrix} 0.33 \\ -0.33 \\ -14.41 \end{bmatrix} \approx \begin{bmatrix} 0 \\ 0 \\ -14.41 \end{bmatrix}$$

Catatan: Nilai 0.33 dan -0.33 relatif sangat kecil dibandingkan nilai

komponen dominan -14.41, sehingga diperlakukan sebagai noise dan dibulatkan menjadi 0 untuk penyederhanaan matriks R.

Langkah 2.7: Menghitung Residu ($\tilde{X}_{res}$)

Residu merupakan selisih data asli dengan rekonstruksinya.

$$\tilde{X}_{res} = \hat{X}_B - (\tilde{X}_{proj} \cdot V^T)$$

a. Rekonstruksi Baris 3 (yang signifikan):

$$\begin{aligned} & -14.41 \times [0.44, 0.44, -0.22, -0.44, 0.44, 0.44] \\ & \approx [-6.34, -6.34, 3.17, 6.34, -6.34, -6.34] \end{aligned}$$

b. Pengurangan Elemen (Baris 3):

1. Kol 1: $-5 - (-6.34) = 1.34$
2. Kol 2: $-7 - (-6.34) = -0.66$
3. Kol 3: $13.5 - 3.17 = 10.33$
4. Kol 4: $14 - 6.34 = 7.66$
5. Kol 5: $2 - (-6.34) = 8.34$
6. Kol 6: $-2 - (-6.34) = 4.34$

**Proyeksi ≈ 0 pada Baris 1 dan 2 menyebabkan nilai residu sama dengan data awal.*

Matriks residu yang dihasilkan adalah:

$$\tilde{X}_{res} = \begin{bmatrix} 1 & 3 & 2.5 & 2 & -1 & 1 \\ -1 & -3 & -2.5 & -2 & 1 & -1 \\ 1.34 & -0.66 & 10.33 & 7.66 & 8.34 & 4.34 \end{bmatrix}$$

Langkah 2.8: Pembentukan Matriks R

Matriks R menggabungkan energi lama (Σ_A), proyeksi baru, dan energi residu baru.

$$R = \begin{bmatrix} \Sigma_A & \tilde{\Sigma}_B^T \\ 0 & \tilde{\Sigma}_B \end{bmatrix}$$

Komponen R:

1. $\Sigma_A = 6.48$ (Energi *Batch A*).
2. $\tilde{\Sigma}_B^T = [0, 0, -14.41]$ (Vektor proyeksi baris).
3. $\tilde{\Sigma}_B$: Dihitung dari norma (panjang vektor) setiap baris matriks residu.
 - a. Norm Baris 1: $\sqrt{1^2 + 3^2 + 2.5^2 + 2^2 + (-1)^2 + 1^2} \approx 4.7$
 - b. Norm Baris 2: $\sqrt{(-1)^2 + (-3)^2 + \dots} \approx 4.7$
 - c. Norm Baris 3: $\sqrt{1.34^2 + (-0.66)^2 + 10.33^2 + 7.66^2 + 8.34^2 + 4.34^2} \approx 16.0$

Susunan Matriks R (2×4) adalah sebagai berikut:

$$R = \begin{bmatrix} 6.48 & 0 & 0 & -14.41 \\ 0 & 4.7 & 4.7 & 16.0 \end{bmatrix}$$

**Baris pertama memuat proyeksi ke komponen lama, baris kedua memuat energi baru (residual) yang belum terjelaskan.*

Langkah 2.9: SVD pada Matriks R (Langkah 8 Modul)

Langkah ini bertujuan untuk mendapatkan nilai singular baru (Σ_{baru}) dan matriks rotasi ($\tilde{U}$) dengan melakukan SVD pada matriks R yang berukuran kecil (2×4).

$$R = \begin{bmatrix} 6.48 & 0 & 0 & -14.41 \\ 0 & 4.7 & 4.7 & 16.0 \end{bmatrix}$$

a. Menghitung Matriks Kovariansi RR^T

$$RR^T = R \cdot R^T = \begin{bmatrix} 6.48 & 0 & 0 & -14.41 \\ 0 & 4.7 & 4.7 & 16.0 \\ -14.41 & 16.0 & 0 & 4.7 \\ 0 & 4.7 & 4.7 & 16.0 \end{bmatrix}$$

Perhitungan elemen matriks:

1. $Elemen_{1,1} = (6.48)^2 + (-14.41)^2 = 41.99 + 207.64 \approx 249.6$
2. $Elemen_{2,2} = (4.7)^2 + (4.7)^2 + (16.0)^2 = 22.09 + 22.09 + 256 \approx 300.2$
3. $Elemen_{1,2} = Elemen_{2,1} = (6.48)(0) + \dots + (-14.41)(16.0) \approx -230.6$

Hasil matriks kovariansi adalah:

$$RR^T = \begin{bmatrix} 249.6 & -230.6 \\ -230.6 & 300.2 \end{bmatrix}$$

b. Menentukan Nilai Eigen (Σ_{baru}) Persamaan karakteristik $\det(RR^T - \lambda I) = 0$:

$$(249.6 - \lambda)(300.2 - \lambda) - (-230.6)^2 = 0$$

$$\lambda^2 - 549.8\lambda + (74929.9 - 53176.3) = 0$$

$$\lambda^2 - 549.8\lambda + 21753.6 = 0$$

Pencarian akar kuadrat (λ) menggunakan rumus abc :

$$\lambda_{1,2} = \frac{549.8 \pm \sqrt{302280 - 87014}}{2} = \frac{549.8 \pm 464}{2}$$

$$1. \lambda_1 \approx 506.9$$

$$2. \lambda_2 \approx 42.9$$

Nilai singular baru (Σ_{baru}) adalah akar dari λ :

$$\sigma_1 = \sqrt{506.9} \approx 22.5 \quad (\text{Komponen Utama 1})$$

$$\sigma_2 = \sqrt{42.9} \approx 6.5 \quad (\text{Komponen Utama 2})$$

c. Menentukan Matriks Rotasi ($\tilde{U}$) Matriks rotasi $\tilde{U}$ dibentuk dari vektor eigen RR^T . Kasus $\lambda_1 = 506.9$ menghasilkan persamaan:

$$(249.6 - 506.9)x - 230.6y = 0 \rightarrow -257.3x = 230.6y$$

Hubungan yang diperoleh adalah $x \approx -0.9y$. Normalisasi vektor satuan menghasilkan:

$$\tilde{u}_1 \approx \begin{bmatrix} -0.67 \\ 0.74 \end{bmatrix}$$

Kasus $\lambda_2 = 42.9$ mengharuskan vektor eigen kedua ortogonal terhadap yang pertama:

$$\tilde{u}_2 \approx \begin{bmatrix} 0.74 \\ 0.67 \end{bmatrix}$$

Matriks rotasi $\tilde{U}$ yang terbentuk adalah:

$$\tilde{U} = \begin{bmatrix} -0.67 & 0.74 \\ 0.74 & 0.67 \end{bmatrix}$$

Langkah 2.10: Pembaruan Basis Vektor Eigen

Langkah terakhir adalah memproyeksikan matriks rotasi kembali ke ruang fitur asli berdimensi 4.096 (dalam contoh ini dimensi 6) untuk mendapatkan U_{baru} .

Rumus yang digunakan adalah:

$$U_{baru} = [U_A, \tilde{U}_B] \cdot \tilde{U}$$

Keterangan variabel:

1. U_A : Basis komponen lama (6×1).
2. $\tilde{U}_B$: Basis residual baru yang dinormalisasi. Pada Langkah 2.7,

vektor residu dominan (baris 3) memiliki norm ≈ 16.0 .

a. Normalisasi Residu ($\tilde{U}_B$) Vektor residu (dari perhitungan Langkah 2.7 baris 3) adalah:

$$\text{residu} = [1.34, -0.66, 10.33, 7.66, 8.34, 4.34]^T$$

$$\tilde{U}_B = \frac{\text{residu}}{16.0} \approx [0.08, -0.04, 0.64, 0.48, 0.52, 0.27]^T$$

b. Perhitungan U_{baru} Matriks gabungan basis [$U_A, \tilde{U}_B$] berukuran 6×2 adalah:

$$\text{BasisGabungan} = \begin{bmatrix} 0.44 & 0.08 \\ 0.44 & -0.04 \\ -0.22 & 0.64 \\ -0.44 & 0.48 \\ 0.44 & 0.52 \\ 0.44 & 0.27 \end{bmatrix}$$

Perkalian dengan $\tilde{U}$ dilakukan sebagai berikut:

$$U_{baru} = \begin{bmatrix} 0.44 & -0.04 \\ 0.44 & -0.04 \\ -0.22 & 0.64 \\ -0.44 & 0.48 \\ 0.44 & 0.52 \\ 0.44 & 0.27 \end{bmatrix} \cdot \begin{bmatrix} 0.44 & 0.08 \\ -0.67 & 0.74 \\ 0.74 & 0.67 \end{bmatrix}$$

Contoh perhitungan baris 1 (Fitur 1):

1. $U_{baru(1,1)} = (0.44)(-0.67) + (0.08)(0.74) = -0.29 + 0.06 = -0.23$
2. $U_{baru(1,2)} = (0.44)(0.74) + (0.08)(0.67) = 0.32 + 0.05 = 0.37$

Penyelesaian perhitungan untuk seluruh baris menghasilkan 2 Komponen Utama (PC) baru yang telah memperhitungkan data *Batch A* dan *Batch B*.

Ringkasan Hasil Akhir IPCA

Penyelesaian seluruh proses iterasi menghasilkan parameter berikut yang disimpan model IPCA untuk tahap klasifikasi Naïve Bayes:

1. *Global Mean* (μ_{baru}):

$$[9.5, 10.5, 10.75, 13, 5, 5]$$

2. *Explained Variance* (Σ_{baru}^2):

$$\lambda_1 = 506.9, \quad \lambda_2 = 42.9$$

3. *Komponen Utama* (U_{baru}): Matriks berukuran 6×2 yang digunakan untuk mentransformasi data uji.

LAMPIRAN C. PENENTUAN CEV DAN KLASIFIKASI NAÏVE BAYES

Lampiran ini menyajikan perhitungan nilai riil berdasarkan output IPCA pada Lampiran B. Data dilatih menggunakan 4 sampel yang dibagi menjadi dua kelas (Kelas A: Sampel 1-2, Kelas B: Sampel 3-4), kemudian diuji menggunakan satu data uji baru.

1. Hasil Perhitungan *Cumulative Explained Variance* (CEV)

Perhitungan didasarkan pada nilai eigen yang diperoleh pada tahap akhir IPCA:

$$\text{Diketahui: } \lambda_1 = 506.9 \quad \text{dan} \quad \lambda_2 = 42.9$$

1. Total Variansi:

$$Total = 506.9 + 42.9 = 549.8$$

2. CEV Komponen 1:

$$CEV_1 = \frac{506.9}{549.8} = 0.92197 \approx 92.2\%$$

3. CEV Komponen 2:

$$CEV_2 = \frac{506.9 + 42.9}{549.8} = \frac{549.8}{549.8} = 100\%$$

Target $CEV \geq 0.90$ mengindikasikan bahwa penggunaan satu komponen sebenarnya sudah memadai.

2. Transformasi Data Latih ke Ruang Fitur Baru

Matriks transformasi (U_{baru}) hasil IPCA adalah:

$$U_{baru} \approx \begin{bmatrix} -0.24 & 0.38 \\ -0.32 & 0.30 \\ 0.62 & 0.27 \\ 0.65 & -0.00 \\ 0.09 & 0.67 \\ -0.10 & 0.51 \end{bmatrix}$$

Contoh Detail Perhitungan: Sampel 1 untuk Fitur PC1

Diketahui:

- Data Mentah Sampel 1 (X_1): [10, 12, 5, 8, 2, 4]
- Rata-rata Global (μ_{gl}): [9.5, 10.5, 10.75, 13, 5, 5]
- Bobot U_{baru} Kolom 1: [-0.24, -0.32, 0.62, 0.65, 0.09, -0.10]^T

Langkah 1: Pemusatan Data ($X_{center} = X_1 - \mu_{gl}$)

$$x_1 = 10 - 9.5 = 0.5$$

$$x_2 = 12 - 10.5 = 1.5$$

$$x_3 = 5 - 10.75 = -5.75$$

$$x_4 = 8 - 13 = -5$$

$$x_5 = 2 - 5 = -3$$

$$x_6 = 4 - 5 = -1$$

Langkah 2: Perkalian Dot Product ($X_{center} \cdot U_{col1}$)

$$\begin{aligned} PC1 &= (0.5 \times -0.24) + (1.5 \times -0.32) + (-5.75 \times 0.62) \\ &\quad + (-5 \times 0.65) + (-3 \times 0.09) + (-1 \times -0.10) \\ &= (-0.12) + (-0.48) + (-3.565) + (-3.25) + (-0.27) + (0.10) \\ &= -7.585 \approx -7.60 \end{aligned}$$

**Perhitungan untuk PC2 dilakukan dengan cara yang sama menggunakan Kolom 2 U_{baru}.*

Tabel Hasil Transformasi Seluruh Sampel

Sampel	Kelas	Fitur 1 (PC1)	Fitur 2 (PC2)
Sampel 1	A	-7.60	-3.40
Sampel 2	A	-13.70	3.52
Sampel 3	B	12.11	1.71
Sampel 4	B	9.19	-1.82

3. Pelatihan Parameter Gaussian Naïve Bayes

Berikut adalah rincian perhitungan parameter *Mean* (μ) dan *Variansi* (σ^2) untuk Kelas A.

1. Menghitung Rata-rata (μ_A) pada PC1

Diketahui nilai PC1 Kelas A: $x_1 = -7.60$, $x_2 = -13.70$. Jumlah data $N = 2$.

$$\mu_{A,PC1} = \frac{\sum x}{N} = \frac{-7.60 + (-13.70)}{2} = \frac{-21.30}{2} = -10.65$$

2. Menghitung Variansi (σ_A^2) pada PC1

Diketahui: $\mu = -10.65$. Rumus variansi sampel $\frac{\sum (x-\mu)^2}{N-1}$.

$$(x_1 - \mu)^2 = (-7.60 - (-10.65))^2 = (3.05)^2 = 9.3025$$

$$(x_2 - \mu)^2 = (-13.70 - (-10.65))^2 = (-3.05)^2 = 9.3025$$

$$\sigma^2 = \frac{9.3025 + 9.3025}{2 - 1} = 18.605 \approx 18.62$$

**Parameter untuk fitur PC2 dan Kelas B dihitung dengan langkah yang sama. Hasil rekapitulasi parameter:*

- Kelas A: $\mu = [-10.65, 0.06]$, $\sigma^2 = [18.62, 23.93]$
- Kelas B: $\mu = [10.65, -0.06]$, $\sigma^2 = [4.26, 6.23]$

4. Pengujian Klasifikasi Data Baru (Likelihood)

Data uji (X_{test}) diproses menjadi nilai fitur: $PC1 = -9.44$ dan $PC2 = -1.80$. Perhitungan probabilitas menggunakan fungsi densitas Gaussian:

$$P(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

A. Perhitungan Detail $P(PC1|Kelas A)$

Diketahui:

- Nilai Uji (x): -9.44
- Mean Kelas A (μ): -10.65
- Variansi Kelas A (σ^2): 18.62

Langkah 1: Hitung Bagian Koefisien (Depan)

$$\text{Koef} = \frac{1}{\sqrt{2 \cdot 3.14159 \cdot 18.62}} = \frac{\sqrt{1}}{116.99} = \frac{1}{10.816} \approx 0.0924$$

Langkah 2: Hitung Bagian Eksponen (Pangkat)

$$\text{Pembilang} = (x - \mu)^2 = (-9.44 - (-10.65))^2 = (1.21)^2 = 1.4641$$

$$\text{Penyebut} = 2 \cdot \sigma^2 = 2 \cdot 18.62 = 37.24$$

$$\text{Pangkat} = -\frac{1.4641}{37.24} \approx -0.0393$$

Langkah 3: Hasil Akhir Probabilitas

$$\begin{aligned} P(PC1|A) &= 0.0924 \times e^{-0.0393} \\ &= 0.0924 \times 0.9614 \\ &\approx 0.088 \end{aligned}$$

B. Perhitungan Singkat $P(PC2|Kelas A)$

Diketahui: $x = -1.80$, $\mu = 0.06$, $\sigma^2 = 23.93$.

$$\begin{aligned} P(PC2|A) &= \frac{1}{\sqrt{2\pi(23.93)}} \cdot \exp -\frac{(-1.80 - 0.06)^2}{2(23.93)} \\ &= \frac{1}{12.26} \cdot \exp -\frac{3.4596}{47.86} \\ &= 0.0815 \cdot 0.9302 \approx 0.076 \end{aligned}$$

5. Keputusan Final (Posterior)

Nilai *Posterior* dihitung dengan mengalikan probabilitas setiap fitur dengan probabilitas prior (asumsi $P(A) = 0.5$).

1. Posterior Kelas A:

$$\begin{aligned} Score_A &= P(A) \times P(PC1|A) \times P(PC2|A) \\ &= 0.5 \times 0.088 \times 0.076 \\ &= 0.003344 \end{aligned}$$

2. Posterior Kelas B: Untuk Kelas B, nilai $x = -9.44$ sangat jauh dari rata-rata $\mu = 10.65$ (selisih > 20).


$$P(PC1|B) \approx 0.0000 \rightarrow Score_B \approx 0.0000$$

Kesimpulan: Karena $Score_A(0.0033) > Score_B(0.0000)$, data uji diklasifikasikan sebagai KELAS A.

LAMPIRAN D. KARAKTERISTIK HASIL IPCA

1. Distribusi Bobot Vektor Eigen pada Model IPCA


Visualisasi pada bagian ini menyajikan sebaran nilai bobot dari 4.096 fitur k -mer pembentuk komponen utama pertama (PC1) dan kedua (PC2).



Gambar D.1 Histogram Distribusi Bobot k -mer pada Vektor Eigen (Model IPCA)

2. Distribusi Gaussian pada Hasil Transformasi Data Latih

Bagian ini menampilkan histogram sebaran nilai koordinat dari 318.806 sampel latih setelah dikalikan dengan matriks vektor eigen di atas.



Gambar D.2 Histogram Distribusi Sampel Latih Hasil Transformasi IPCA